

چکیده

طبقه‌بندی پوشش زمین بویژه در مناطق شهری یکی از مهم‌ترین کاربردهای تصاویر پلاریمتری SAR (PolSAR) محسوب می‌شود. به منظور استفاده از پتانسیل بالای اطلاعاتی این تصاویر ویژگی‌های متعددی را می‌توان از آن‌ها استخراج کرد. اگرچه هر یک از این ویژگی‌ها می‌تواند اطلاعات مناسبی را درباره عوارض مختلف فراهم کند ولی هیچ‌یک به تنهایی برای توصیف کامل یک عارضه کافی نمی‌باشد و از طرفی امکان استفاده از تمامی ویژگی‌ها وجود ندارد. بنابراین انتخاب ویژگی نقش مهمی در طبقه‌بندی تصاویر پلاریمتری ایفا می‌کند. هدف از این تحقیق، تعیین زیرمجموعه ویژگی بهینه از داده پلاریمتری به منظور بهبود طبقه‌بندی پوشش زمینی می‌باشد. در این راستا سه گام اساسی در طبقه‌بندی اتخاذ شده است: ۱) استخراج ویژگی در قالب سه گروه ویژگی‌های داده اصلی، ویژگی‌های تجزیه هدف، و تفکیک‌کننده‌های PolSAR؛ ۲) انتخاب ویژگی در چارچوب بهینه‌سازی تک‌هدفه و چندهدفه؛ و ۳) طبقه‌بندی با استفاده از ویژگی‌های انتخابی بهینه. در انتخاب ویژگی تک‌هدفه، روش‌های تلفیقی از الگوریتم ژنتیک (GA) و شبکه‌های عصبی پرسپترون چند لایه (MLP) و همچنین ماشین‌های بردار پشتیبان (SVMs) به منظور بیشینه کردن دقت طبقه‌بندی بکار گرفته شد. در انتخاب ویژگی چندهدفه به منظور کمینه‌سازی خطای طبقه‌بندی و همزمان تعداد ویژگی‌های انتخابی PolSAR، الگوریتم ژنتیک با مرتب‌سازی نامغلوب ۲ (NSGA-II) در مرحله جستجو و دو طبقه‌بندی‌کننده ماشین بردار پشتیبان و سیستم استنتاج عصبی-فازی تطبیقی (ANFIS) در مرحله ارزیابی مورد استفاده قرار گرفت. برای بررسی عملکرد الگوریتم‌ها از تصویر پلاریمتری شهر سانفرانسیسکو مربوط به سنجنده فضابرد رادارست ۲ استفاده شد. نتایج حاصل کارایی برتر الگوریتم‌های چندهدفه را نسبت به سایر روش‌های مورد استفاده نشان می‌دهد. برای الگوریتم چندهدفه با طبقه‌بندی‌کننده SVM تعداد ویژگی ۱۶ و دقت کلی ۹۵/۸۷ و برای الگوریتم چندهدفه با طبقه‌بندی‌کننده ANFIS تعداد ویژگی ۱۴ و دقت کلی ۹۷/۳ حاصل شد.

واژگان کلیدی: داده پلاریمتری، طبقه‌بندی، بهینه‌سازی چندهدفه، ماشین بردار پشتیبان، سیستم

استنتاج عصبی-فازی تطبیقی

فهرست

فصل اول: مقدمه	۱
۱-۱ کلیات و پیش‌درآمد	۲
۲-۱ پیشینه تحقیق	۳
۳-۱ ضرورت تحقیق	۵
۴-۱ اهداف تحقیق	۱۰
۵-۱ روش تحقیق	۱۰
۶-۱ ساختار پایان‌نامه	۱۱
فصل دوم: مروری بر اصول پلاریمتری و ویژگی‌های پلاریمتری SAR	۱۲
۱-۲ اصول کلی پلاریمتری	۱۳
۲-۲ ویژگی‌های پلاریمتری	۱۴
۱-۲-۲ ویژگی‌های اصلی	۱۵
۲-۲-۲ ویژگی‌های تفکیک‌کننده PolSAR	۱۶
۳-۲-۲ ویژگی‌های تجزیه هدف	۲۰
فصل سوم: روش‌های پیشنهادی در تعیین ویژگی‌های بهینه PolSAR	۴۲
۱-۳ مقدمه	۴۳
۲-۳ انتخاب ویژگی تک‌هدفه	۴۴
۱-۲-۳ روش جستجو: الگوریتم ژنتیک (GA)	۴۵
۲-۲-۳ تابع هدف	۴۷
۳-۳ انتخاب ویژگی چندهدفه	۵۵
۱-۳-۳ روش جستجو: الگوریتم ژنتیک با مرتب‌سازی نامغلوب ۲ (NSGA-II)	۵۸
۲-۳-۳ تابع هدف	۶۲

۴-۳	روش‌های مبنا	۶۶
فصل چهارم: پیاده‌سازی الگوریتم‌ها و بررسی نتایج		
۴-۴	۱- مقدمه	۶۸
۴-۴	۲- مجموعه داده و پیش‌پردازش	۶۹
۴-۴	۳- نتایج پیاده‌سازی الگوریتم‌های پیشنهادی	۷۲
۴-۴	۴- سایر تحقیقات انجام شده با استفاده از ویژگی‌ها و الگوریتم‌های مختلف بر روی تصویر پلاریمتریک منطقه شهری سانفرانسیسکو	۸۴
۴-۵	۵- تحلیل و بررسی برخی ویژگی‌های بهینه انتخاب شده در طبقه‌بندی پوشش زمین شهری ...	۸۶
فصل پنجم: نتیجه‌گیری و پیشنهادات		
۵-۱	۱- بحث و نتیجه‌گیری	۹۴
۵-۲	۲- پیشنهادات	۹۵
مراجع		
پیوست‌ها		۹۹
پیوست‌ها		۱۰۵

فهرست اشکال

- شکل ۱-۲. انتشار موج الکترومغناطیس. بردار میدان الکتریکی (قرمز) شامل مولفه‌های افقی (سبز) و عمودی (آبی) (LEE AND POTTIER, 2009) ۱۳
- شکل ۲-۲. بیضی پلاریزاسیون (ELACHI AND VAN ZYL, 2006) ۱۴
- شکل ۳-۲. تفسیر زاویه آلفا (HELLMANN, 2001) ۳۳
- شکل ۴-۲. مکانیزم پراکنش زوج (تصویر راست)، پراکنش پراکنده (تصویر وسط)، پراکنش فرد (تصویر چپ) (VAN ZYL, 1989) ۳۸
- شکل ۱-۳. طرح کلی روش پیشنهاد شده در این تحقیق به منظور بهبود طبقه‌بندی پوشش زمین تصاویر POLSAR ۴۴
- شکل ۲-۳. فلوچارت الگوریتم انتخاب ویژگی تک‌هدفه ۴۵
- شکل ۳-۳. ساختار شبکه عصبی با یک لایه میانی ۴۸
- شکل ۴-۳. توابع فعالسازی به ترتیب از راست به چپ: خطی، سیگموئید (لگاریتمی)، سیگموئید (تانژانت هایپربولیک)، تابع آستانه ۴۸
- شکل ۵-۳. خط‌های تفکیک‌کننده دو کلاس ۵۱
- شکل ۶-۳. تفکیک‌کننده بهینه برای دو کلاس کاملاً جدا (BURGES, 1998) ۵۲
- شکل ۷-۳. تفکیک‌کننده بهینه برای دو کلاس دارای همپوشانی (BURGES, 1998) ۵۳
- شکل ۸-۳. چهار حالت ارتباط بین تک راه‌حل SOGA و مجموعه راه‌حل‌های نامغلوب MOGA (EMMANOUILIDIS ET AL., 2000) ۵۷
- شکل ۹-۳. فلوچارت الگوریتم انتخاب ویژگی چندهدفه ۵۸
- شکل ۱۰-۳. فلوچارت الگوریتم NSGA-II ۵۹
- شکل ۱۱-۳. طرح کلی الگوریتم NSGA-II، PT جمعیت اولیه، QT جمعیت فرزندان در نسل T و FI نشان‌دهنده FRONT است (DEB ET AL., 2006) ۵۹
- شکل ۱۲-۳. مثالی از راه‌حل‌های مغلوب و بهینه پارتو در یک فضای جستجوی دو هدفه ۶۲
- شکل ۱۳-۳. ساختار ANFIS با دو ورودی و یک خروجی (JANG, 1993) ۶۴

شکل ۳-۱۴. ساختار ANFIS مورد استفاده در این تحقیق با ۷ ویژگی ورودی	۶۶
شکل ۴-۱. منطقه سانفرانسیسکو. الف) تصویر GOOGLE EARTH منطقه، ب) تصویر PAULI RGB	
منطقه که در آن $ SHH - SVV $ با رنگ قرمز، $ SHV $ با رنگ سبز و $ SHH + SVV $ با رنگ آبی نشان داده شده است.	۷۰
شکل ۴-۲. نتیجه طبقه‌بندی نهایی حاصل از الگوریتم WISHART	۷۴
شکل ۴-۳. نتیجه طبقه‌بندی نهایی حاصل از SVM با مجموعه ویژگی کامل	۷۵
شکل ۴-۴. نتیجه طبقه‌بندی نهایی حاصل از GASVM	۷۵
شکل ۴-۵. نتیجه طبقه‌بندی نهایی حاصل از GAMLP	۷۶
شکل ۴-۶. مجموعه پارتو بهینه در MOGA-SVM	۷۷
شکل ۴-۷. مجموعه پارتو بهینه در MOGA-ANFIS	۷۷
شکل ۴-۸. نتیجه طبقه‌بندی نهایی حاصل از MOGA-SVM	۸۱
شکل ۴-۹. نتیجه طبقه‌بندی نهایی حاصل از MOGA-ANFIS	۸۲
شکل ۴-۱۰. مقایسه روش‌های مختلف طبقه‌بندی از نظر دقت کلی	۸۳
شکل ۴-۱۱. مقایسه روش‌های مختلف طبقه‌بندی از نظر تعداد ویژگی	۸۳
شکل ۴-۱۲. نتیجه طبقه‌بندی کننده ترکیبی از PCA و شبکه عصبی (ZHANG ET AL., 2009)	۸۴
شکل ۴-۱۳. نتیجه حاصل از روش پیشنهادی در (KIRANYAZ ET AL., 2012)	۸۵
شکل ۴-۱۴. نتیجه طبقه‌بندی کننده ترکیبی از PSO و شبکه عصبی RBF (INCE ET AL., 2012)	۸۵
شکل ۴-۱۵. نتیجه طبقه‌بندی کننده ترکیبی از GA و MLP (HADDADI ET AL., 2011)	۸۶
شکل ۴-۱۶. ویژگی‌های پلاریمتریک بهینه حاصل از MOGA-SVM برای طبقه‌بندی پوشش زمین	۸۸
شکل ۴-۱۷. برخی ویژگی‌های پلاریمتریک بهینه حاصل از MOGA-ANFIS در طبقه‌بندی پوشش زمین	۸۹
شکل ۴-۱۸. پل GOLDEN GATE. سمت راست: ویژگی آلفا، سمت چپ: ترکیب رنگی PAULI	۹۲
شکل ۴-۱۹. نتیجه طبقه‌بندی پل در MOGA-ANFIS	۹۳

فهرست جداول

جدول ۱-۴. تعداد نمونه‌های آموزش و تست	۷۳
جدول ۲-۴. ویژگی‌های پلاریمتری مورد استفاده در این تحقیق	۷۱
جدول ۳-۴. مقایسه‌ای از نتایج روش‌های تک‌هدفه و روش‌های مبنا	۷۴
جدول ۴-۴. ویژگی‌های POLSAR راه‌حل انتخابی در MOGA-SVM	۷۸
جدول ۵-۴. دقت کلی و ضریب کاپا به ازای ترکیبات مختلف ویژگی‌های بهینه در الگوریتم MOGA-ANFIS	۷۸
جدول ۶-۴. ماتریس خطای طبقه‌بندی. دقت تولیدکننده، دقت کاربر، دقت کلی و ضریب کاپا در GASVM	۸۰
جدول ۷-۴. ماتریس خطای طبقه‌بندی. دقت تولیدکننده، دقت کاربر، دقت کلی و ضریب کاپا حاصل از راه‌حل انتخابی در MOGA-SVM	۸۰
جدول ۸-۴. ماتریس خطای طبقه‌بندی. دقت تولیدکننده، دقت کاربر، دقت کلی و ضریب کاپا حاصل از راه‌حل انتخابی در MOGA-ANFIS	۸۱

فصل اول: مقدمه

۱-۱ کلیات و پیش‌درآمد

فراهم کردن اطلاعات پوشش زمین دقیق و به‌هنگام در مدیریت شهرها از اهمیت فوق‌العاده بالایی برخوردار است. سنجش از دور^۱ SAR به عنوان یکی از روش‌های نوین با قابلیت امکان تصویربرداری در شرایط مختلف آب و هوایی و در طول شبانه‌روز می‌تواند مدیریت شهری را در کسب اطلاعات مناسب و قابل اعتماد یاری دهد.

معمولاً مناطق شهری بسیار ناهمگن^۲ هستند و مکانیزم‌های پراکندگی مختلفی را شامل می‌شوند. برخوردهای پیچیده بین سیگنال‌های راداری و عوارض شهری، ساختار بسیار متغیر این مناطق، که ترکیبی از عوارض ساخت بشر، عوارض طبیعی و دیگر المان‌های غیر قابل پیش‌بینی مانند وسایل نقلیه می‌باشد، شباهت‌های پراکندگی در کلاس‌های پوشش زمین و ... موجب شده است که طبقه‌بندی تصویر SAR شهری چالشی بزرگ در حوزه پوشش و کاربری اراضی محسوب شود (Franceschetti *et al.*, 2006).

ظهور سیستم‌های SAR فضاگرد با رزولوشن بالا امکان استخراج اطلاعات جزئی را از پوشش زمین در مناطق شهری فراهم کرده است. مجموعه ماهواره‌های رادارست از جمله اولین سری ماهواره‌های فضاگرد سنجش از دور فعال هستند که از سنجنده SAR جهت تولید تصاویر استفاده کرده‌اند. نشان داده شده است که داده رادارست ۱ پتانسیل خوبی برای تهیه نقشه پوشش زمین منطقه شهری دارد، اما تنها حاوی اطلاعات پلاریزاسیون HH می‌باشد (Ban and Hu, 2007). با پرتاب ماهواره رادارست ۲ در سال ۲۰۰۷ امکان تولید داده‌های پلاریمتری برای این مجموعه ماهواره‌ها نیز فراهم گشت. رادارست ۲ یکی از پیشرفته‌ترین ماهواره‌های تجاری باند C (۵/۴۰۵ گیگاهرتز) است که می‌تواند تصاویر پلاریمتری شامل هر چهار کانال HH، VH، HV و VV را دریافت کند.

داده‌های پلاریمتری به دلیل داشتن خصوصیات امواج میکروویو و دارا بودن اطلاعاتی به مراتب بیشتر نسبت به داده‌های معمولی SAR، نقش مهمی را در کاربردهای مختلف سنجش از دور مانند طبقه‌بندی پوشش زمین ایفا کرده‌اند. با توسعه ماهواره‌های سنجش از دور پلاریمتری SAR، استخراج

^۱ Synthetic Aperture Radar

^۲ heterogeneous

اطلاعات از تصاویر این ماهواره‌ها به یک موضوع تحقیقاتی مهم برای سالیان اخیر تبدیل شده است. ایجاد سیستم‌های کاملاً پلاریمتریک علاوه بر آنکه منجر به افزایش میزان اطلاعات بدست آمده از سنسورهای SAR شده است، پیچیدگی آنالیز و تفسیر داده را نیز بیشتر کرده است. به منظور استفاده از داده‌های پلاریمتری ویژگی‌های متعددی را می‌توان از آن‌ها استخراج کرد. ویژگی‌های پلاریمتری به سه دسته تقسیم می‌شوند (Maghsoudi *et al.*, 2012): (۱) پارامترهای اصلی، (۲) تفکیک‌کننده‌های^۱ PolSAR و (۳) پارامترهای الگوریتم‌های تجزیه هدف^۲ که خود به دو دسته همدوس^۳ و ناهمدوس^۴ تقسیم‌بندی می‌شوند. روش‌های همدوس براساس ماتریس پراکندگی^۵ و روش‌های ناهمدوس براساس ماتریس‌های همبستگی^۶ یا کواریانس می‌باشند. اگرچه هر یک از این ویژگی‌ها می‌تواند اطلاعات مناسبی را درباره عوارض مختلف فراهم کند ولی هیچ‌یک به تنهایی برای توصیف کامل یک عارضه کافی نمی‌باشد. از طرفی به علت وجود ویژگی‌های اضافی^۷ و نامناسب^۸، استفاده از تمامی ویژگی‌های استخراج شده عملاً منجر به کاهش کارایی طبقه‌بندی می‌شود. بنابراین نیاز به توسعه روش‌های جدید برای تعیین ویژگی‌های بهینه در تهیه نقشه پوششی شهری از داده پلاریمتریک می‌باشد.

۲-۱ پیشینه تحقیق

تاکنون تحقیقات زیادی در زمینه بکارگیری ترکیبات مختلف ویژگی‌های پلاریمتری در کاربردهای گوناگون سنجش از دور صورت گرفته است، اما مجموعه‌ای منحصر به فرد از این ویژگی‌ها نمی‌توان ارائه داد (صالحی، ۱۳۹۱). همچنین تحقیقات زیادی بر مبنای استفاده از تنها ویژگی‌های تجزیه همدوس یا ناهمدوس در طبقه‌بندی انجام شده است (Alberga *et al.*, 2004; Cloude and Pottier, 1997; Ferro-Famil *et al.*, 2001). از آنجا که ویژگی‌های استخراج شده از روش‌های تجزیه همدوس و ناهمدوس می‌توانند مکمل یکدیگر باشند در طبقه‌بندی پوشش زمین بهتر است ویژگی‌های هر دو

¹ PolSAR discriminators

² Target Decomposition

³ coherent

⁴ incoherent

⁵ Scattering

⁶ Coherency

⁷ redundant

⁸ irrelevant

دسته در نظر گرفته شود. بر همین اساس در سال‌های اخیر محققان در الگوریتم‌های پیشنهادی خود از پارامترهای بیشتری به عنوان ویژگی‌های ورودی استفاده کرده و هر دو دسته الگوریتم‌های تجزیه را بکار برده‌اند. Haddadi و همکاران (2011) روشی بر مبنای الگوریتم ژنتیک^۱ (GA) و شبکه‌های عصبی مصنوعی^۲ به منظور طبقه‌بندی تصاویر پلاریمتری SAR پیشنهاد کردند. انتخاب بهترین ویژگی‌ها از ۵۷ پارامتر استخراج شده از تصویر شهر سانفرانسیسکو از سنجنده هواپرد^۳ AirSAR در باند L انجام گرفت. لازم به ذکر است که زاویه فرود^۴ داده مورد استفاده در این تحقیق از برد نزدیک^۵ تا برد دور^۶، در محدوده ۵ درجه تا ۶۰ درجه قرار دارد و همین مسئله می‌تواند منجر به اختلاف دقت طبقه‌بندی در سمت چپ و راست تصویر شود. روش‌های مختلفی برای طبقه‌بندی تصاویر پلاریمتری سنجنده‌های هواپرد مانند AirSAR ارائه شده است (Chen et al., 2003; Zhang et al., 2009)، اما تحقیقات کمی در این زمینه با استفاده از سیستم‌های پیشرفته فضاپرد مانند رادارست^۷ وجود دارد.

در آنالیزی شی‌گرا، Qi و همکاران (2012) ۶۶ ویژگی از تصاویر پلاریمتری رادارست^۷ را برای طبقه‌بندی پوشش و کاربری زمین بکار گرفتند. نتایج آن‌ها افزایش دقت طبقه‌بندی را بویژه در مناطق ساخته‌شده نسبت به طبقه‌بندی‌کننده بر مبنای توزیع ویشارت (Lee et al., 2001) و روش‌های رایج طبقه‌بندی مانند نزدیکترین همسایه نشان داد. به علت حضور نویز اسپکل^۸ در داده SAR، موفقیت روش‌های شی‌گرا بسیار وابسته به نتیجه قطعه‌بندی^۹ اشیاء می‌باشد و طبقه‌بندی شی‌گرا نیازمند توسعه روش‌های موجود قطعه‌بندی تصاویر PolSAR می‌باشد.

روش‌های انتخاب ویژگی غیرپارامتریک^۹ (NFS) و انتخاب ویژگی کلاس‌مبنا^{۱۰} (CBFS) توسط Maghsoudi و همکاران (2012) به منظور انتخاب ویژگی از ۵۸ پارامتر اولیه تصاویر رادارست^۷ در طبقه‌بندی جنگل بکار گرفته شد. NFS انتخاب ویژگی را براساس تعریفی غیرپارامتریک از تابع

^۱ genetic algorithm

^۲ Artificial Neural Networks

^۳ airborne

^۴ incidence angle

^۵ near range

^۶ far range

^۷ speckle

^۸ segmentation

^۹ nonparametric feature selection

^{۱۰} class-based feature selection

ارزیابی انجام می‌دهد. در CBFS انتخاب ویژگی به طور جداگانه برای هر کلاس انجام شده و سپس طبقه‌بندی‌کننده روی هر زیرمجموعه ویژگی انتخابی آموزش می‌بیند، بنابراین تعداد طبقه‌بندی‌کننده‌ها به تعداد کلاس‌ها می‌باشد. در نهایت از طریق یک مکانیزم ترکیب خروجی طبقه‌بندی‌کننده‌ها ترکیب می‌شوند. نتایج این الگوریتم‌ها نشان داد که مرحله انتخاب ویژگی دقت طبقه‌بندی جنگل را در مقایسه با طبقه‌بندی‌کننده با مجموعه ویژگی کامل و طبقه‌بندی‌کننده ویشارت به طور قابل توجهی بهبود می‌دهد. در این تحقیق، به علت پیچیدگی محیط شهری به بررسی و ارزیابی پتانسیل داده رادارست ۲ در طبقه‌بندی این مناطق پرداخته شده و ویژگی‌های اولیه بیشتری به منظور استفاده کامل از پتانسیل داده پلاریمتری در تمییز کلاس‌ها بکار برده شده است.

۳-۱ ضرورت تحقیق

از آنجا که با افزایش تعداد ویژگی‌ها، مشکلاتی مانند افزایش تعداد داده‌های آموزشی مورد نیاز در طبقه‌بندی، افزایش حافظه مورد نیاز و کاهش سرعت پردازش داده ایجاد می‌شود، امکان استفاده از تمامی ویژگی‌های استخراج شده از تصاویر PolSAR در طبقه‌بندی پوشش زمین وجود ندارد. از طرف دیگر، عملکرد طبقه‌بندی‌کننده به شدت وابسته به مجموعه ویژگی‌های استفاده شده در آن می‌باشد و تنها ویژگی‌های مناسب می‌تواند منجر به طبقه‌بندی صحیح شود. کاهش تعداد ویژگی‌ها می‌تواند منجر به کاهش خطای تفکیک شود، به این علت که با کم شدن تعداد ویژگی‌ها، تعداد پارامترهای تفکیک‌کننده که باید تخمین زده شود و در نتیجه پیچیدگی تفکیک‌کننده کاهش می‌یابد.

فرآیند انتخاب ویژگی شامل دو مولفه اصلی است: استراتژی جستجو و تابع ارزیابی (تابع هدف). هدف از بکارگیری یک استراتژی جستجو، یافتن راه‌حلی است که به طور موثر تابع هدف اتخاذ شده را بهینه کند. یک جستجوی جامع برای راه‌حل بهینه تمامی ترکیبات ممکن از ویژگی‌ها را مورد بررسی قرار می‌دهد و از دید محاسباتی حتی برای تعداد ویژگی‌های کم روشی غیر قابل کنترل^۱ محسوب می‌شود (Jain and Zongker, 1997). برای حل این مشکل روش‌هایی مانند SFS^۲ و SBS^۳ بدون

^۱ intractable

^۲ sequential forward selection

^۳ sequential backward selection

لزوم بررسی همه ترکیبات ممکن ویژگی‌ها ارائه شده است (Pudil *et al.*, 1994). اشکال جدی این روش‌ها آن است که اجازه برگشت به عقب^۱ نمی‌دهند. در SFS، وقتی ویژگی‌ها انتخاب می‌شوند، نمی‌توان آن‌ها را کنار گذاشت. به همین نحو در SBS، وقتی ویژگی‌ها حذف می‌شوند، نمی‌توان آن‌ها را مجدداً به زیرمجموعه ویژگی انتخاب شده اضافه کرد. برای توسعه این روش‌ها، دو روش جستجوی ترتیبی^۲ SFFS و^۳ SBFS ارائه شده است (Pudil *et al.*, 1994). نشان داده شده است که این روش‌ها برای مسائل انتخاب ویژگی با ابعاد بالا مناسب نیستند (Kudo and Sklansky, 2000). همچنین از آنجا که این روش‌ها تصمیم‌گیری محلی^۴ دارند، نمی‌توان انتظار داشت راه‌حل‌های بهینه سراسری^۵ را پیدا کنند. روش‌های جستجوی کلاسیک مانند گرادیان نزولی^۶ نیز محلی هستند. بهینه‌ای که این روش‌ها به دنبال آن می‌باشند در همسایگی نقطه فعلی بهترین است. اگر تابع چند بهینه محلی داشته باشد و یا مشتق‌پذیر نباشد این روش‌ها با مشکل مواجه خواهند شد.

در سال‌های اخیر، بهره‌گیری از الگوریتم‌های تکاملی در علوم و مهندسی به طور چشم‌گیری افزایش پیدا کرده است. این الگوریتم‌ها، با داشتن قابلیت حل مسائل بهینه‌سازی در حالت سراسری، توانایی خود را در بهینه‌سازی مسائل ناپیوسته، مشتق ناپذیر و نویزی به اثبات رسانده‌اند. همچنین این الگوریتم‌ها، دارای قابلیت حل مسائل چندهدفه^۷ پیچیده می‌باشند. از جمله این روش‌ها می‌توان به الگوریتم ژنتیک اشاره کرد که به طور رایج برای جستجوی بهترین زیرمجموعه ویژگی بکار گرفته شده است (Dash and Liu, 2003).

روش‌های انتخاب ویژگی را می‌توان براساس تابع ارزیابی به دو دسته فیلترمبنا و پوششی^۸ تقسیم کرد (Kohavi and John, 1997). فیلترها معیارهای مبتنی بر فاصله را به عنوان تابع ارزیابی در نظر می‌گیرند. در این روش‌ها انتخاب ویژگی مستقل از عملکرد طبقه‌بندی‌کننده انجام می‌گیرد و با وجود سرعت بالا ممکن است زیرمجموعه ویژگی بهینه حاصل نشود. معمولاً این روش‌ها به تخمین ضعیفی

¹ backtracking

² sequential forward floating selection

³ sequential backward floating selection

⁴ local

⁵ global

⁶ gradient descent

⁷ multiobjective

⁸ wrapper

از تفکیک پذیری منجر می شوند. روش های پوششی دقت طبقه بندی را به عنوان معیار عملکرد هر زیرمجموعه ویژگی در نظر می گیرند. در این روش ها با وجود دقت بالا، پیچیدگی و هزینه محاسباتی بیشتر از دسته اول می باشد.

معمولا الگوریتم های انتخاب ویژگی تنها دقت طبقه بندی را به عنوان تابع هدف و معیار ارزیابی هر زیر مجموعه ویژگی در نظر می گیرند و تعیین ویژگی های بهینه در قالب یک مسئله بهینه سازی تک هدفه انجام می گیرد. همان طور که اشاره شد، این الگوریتم ها به زمان زیادی برای رسیدن به یک راه حل خوب نیاز دارند. یک الگوریتم تک هدفه موثر راه حلی با کیفیت بالا برای یک تابع هدف تولید می کند. در مسائل تک هدفه، مقدار کمینه یا بیشینه یک تابع هدف، کیفیت پاسخ بدست آمده را به طور کامل منعکس می کند. اما در برخی موارد، لازم است که چندین تابع هدف تعریف شده و به طور همزمان مقدار بهینه آن ها تعیین شود.

در ایجاد یک مدل طبقه بندی مناسب علاوه بر دقت لازم است همزمان معیارهایی مانند پیچیدگی مدل نیز در نظر گرفته شود (Igel, 2005). یک مدل با عملکرد تعمیم دهی^۱ بالا و خطای طبقه بندی پائین معمولا بهترین انتخاب نیست، بویژه اگر یک مدل بسیار پیچیده از نظر محاسباتی داشته باشیم (Narzisi, 2007). از طرفی هدف از انتخاب ویژگی فراهم کردن حداقل تعداد ویژگی های مناسب برای رسیدن به عملکرد مشابه یا حتی بهتر در مقایسه با بکارگیری تمام ویژگی ها می باشد. رسیدن به ترکیبی از ویژگی های PoISAR که بالاترین دقت طبقه بندی را با کمترین تعداد ویژگی ها ایجاد کند می تواند منجر به حل یک مسئله بهینه سازی چندهدفه شود. تحقیقات مختلفی در زمینه انتخاب ویژگی تک هدفه تصاویر پلاریمتری صورت گرفته است، اما در این تحقیق بکارگیری روش های چندهدفه نیز در تعیین ویژگی های بهینه این تصاویر مورد بررسی قرار می گیرد.

علاوه بر مسئله تعیین تعداد و نوع ویژگی های پلاریمتری، بکارگیری طبقه بندی کننده مناسب نیز در انتخاب ویژگی های بهینه و بهبود طبقه بندی بسیار حائز اهمیت است. طرح های طبقه بندی موفق تنها وابسته به اطلاعات موجود در ویژگی های پلاریمتری نمی باشد و به طور قابل توجهی مربوط به

¹ generalization

روش طبقه‌بندی است.

طبقه‌بندی‌کننده‌های پارامتریک به علت نیاز به تخمین توزیع آماری کلاس‌ها و عدم توازن بین تعداد ویژگی‌ها و تعداد نمونه‌های آموزشی، با پدیده هیوز^۱ مواجه می‌شوند که منجر به برآزش بیش از حد^۲ داده آموزشی و در نتیجه توانایی تعمیم ضعیف طبقه‌بندی‌کننده می‌شود. به منظور رفع مشکلات این طبقه‌بندی‌کننده‌ها، طبقه‌بندی‌کننده‌های غیر پارامتریک مختلفی در سال‌های اخیر ارائه شده‌اند، از جمله: شبکه‌های عصبی مصنوعی، ماشین‌های بردار پشتیبان^۳ (SVM) و شبکه‌های عصبی فازی.

شبکه‌های عصبی که اولین بار توسط Pottier و همکاران (1991) برای طبقه‌بندی تصویر پلاریمتریک SAR استفاده شدند نیازی به دانش قبلی درباره توزیع آماری داده ورودی ندارند، اگرچه این شبکه‌ها معمولاً به آهستگی همگرا شده و عملکرد آن‌ها به مسائلی از قبیل اندازه داده آموزشی، ساختار شبکه و مقداردهی اولیه وابسته است. علاوه بر این، آموزش این شبکه‌ها براساس روش‌های گرادیان مبنا انجام می‌شود و بنابراین می‌توانند به آسانی در بهینه محلی گرفتار شوند. Hara و همکاران (1994) با استفاده از شبکه‌های عصبی مصنوعی و المان‌های ماتریس کواریانس در طبقه‌بندی پوشش زمین به نتایجی بهتر از سایر روش‌های مورد استفاده دست یافتند. تاکنون الگوریتم‌هایی ترکیبی نیز از شبکه‌های عصبی پرسپترون چند لایه^۴ (MLP) و الگوریتم ژنتیک (Haddadi *et al.*, 2011) و شبکه‌های عصبی با تابع پایه شعاعی^۵ (RBF) و الگوریتم بهینه‌سازی ازدحام ذرات^۶ (PSO) (Ince *et al.*, 2012) به منظور انتخاب ویژگی و طبقه‌بندی پوشش زمین تصاویر پلاریمتریک بکار گرفته شده است.

تاکنون مطالعات زیادی نشان داده‌اند که طبقه‌بندی با ماشین‌های بردار پشتیبان ارائه شده توسط Vapnik در سال 1995، می‌تواند از سایر روش‌های طبقه‌بندی غیرپارامتریک مانند شبکه‌های عصبی و همچنین روش‌های پارامتریک مانند طبقه‌بندی‌کننده حداکثر احتمال دقیق‌تر باشد (Foody and

¹ hughes phenomenon

² overfitting

³ support vector machines

⁴ multi-layer perceptron

⁵ radial basis function

⁶ particle swarm optimization

برخلاف شبکه‌های عصبی مانند MLP، RBF و شبکه‌های فازی عصبی به جای کمینه‌سازی خطای طبقه‌بندی، ریسک عدم طبقه‌بندی صحیح را به عنوان تابع هدف در نظر گرفته و مقدار بهینه آن را بدست می‌آورند. آن‌ها در مقابل مینیمم‌های محلی مقاوم هستند. مزیت دیگر آن است که نیاز به تکرار آموزش طبقه‌بندی کننده با مقداردهی‌های اولیه تصادفی و ساختارهای مختلف وجود ندارد. علاوه بر این، همانند شبکه‌های عصبی غیرپارامتریک است. SVM توزیع آماری خاصی برای داده فرض نمی‌کند و از آنجا که داده سنجش از دور و به طور خاص پارامترهای پلاریمتری معمولاً توزیع آماری معلومی ندارد این یک ویژگی مهم محسوب می‌شود، همچنین در مواردی که پارامترها ناهمگن هستند عملکرد خوبی از خود نشان داده است (Lardeux *et al.*, 2009). ماشین بردار پشتیبان تنها به نقاط کمی برای تعریف ابرصفحه تفکیک کننده متکی است، بنابراین حساسیت چندانی به اندازه نمونه آموزشی ندارد و دقت بهتری در مقایسه با شبکه‌های عصبی مصنوعی با استفاده از اندازه نمونه آموزشی بسیار کمتر می‌تواند ایجاد کند (Mountrakis *et al.*, 2011).

SVM در مطالعات متعددی به عنوان یک مدل طبقه‌بندی کارآمد با ترکیبات مختلف از ویژگی‌های PolSAR در طبقه‌بندی تصاویر PolSAR بکار گرفته شده است (Lardeux *et al.*, 2009; Shimoni *et al.*, 2009). همچنین Maghsoudi و همکاران (2012) در طرح پیشنهادی خود برای تهیه نقشه پوششی جنگل از تصاویر رادارست ۲، SVM را به عنوان طبقه‌بندی کننده بکار بردند. در طی فرآیند انتخاب ویژگی با حذف ویژگی‌های نامناسب عملکرد یادگیری ماشین بردار پشتیبان بهبود می‌یابد (Frohlich *et al.*, 2003).

الگوریتم‌های عصبی فازی با قابلیت انعطاف پذیری بالا عدم قطعیت موجود در داده‌ها را نیز در تصمیم‌گیری نهایی مد نظر قرار می‌دهند که این یک ویژگی مهم بویژه در مورد تصاویر سنجش از دوری محسوب می‌شود. یکی از قدرتمندترین این الگوریتم‌ها، سیستم استنتاج عصبی- فازی تطبیقی^۱ (ANFIS) است که تا به حال برای انتخاب ویژگی تصاویر PolSAR بکار گرفته نشده است. مدلسازی پیکسل‌های مبهم، استفاده از مزایای شبکه‌های عصبی و سیستم‌های استنتاج فازی در یک مدل،

¹ Adaptive Neuro Fuzzy Inference System

یادگیری سریع و صحیح، و توانایی تعمیم خوب موجب محبوبیت این سیستم‌های عصبی فازی در دهه‌های گذشته شده است.

۴-۱ اهداف تحقیق

پیچیدگی استفاده از داده‌های پلاریمتری و تعداد زیاد ویژگی‌هایی که از این داده‌ها استخراج می‌شود، می‌تواند استفاده از آن‌ها را با وجود پتانسیل بالای اطلاعاتی محدود سازد. لذا هدف اصلی این تحقیق تعیین مناسب‌ترین ویژگی‌های پلاریمتری SAR به منظور بهبود طبقه‌بندی پوشش زمینی در منطقه پیچیده شهری با استفاده از تصاویر پلاریمتریک می‌باشد. در راستای این هدف اصلی و برای رسیدن به بالاترین دقت طبقه‌بندی و همزمان انتخاب حداقل ویژگی‌های مؤثر که در روند طبقه‌بندی شرکت داده می‌شوند، به بررسی قابلیت روش‌های بهینه‌سازی چندهدفه و عملکرد آن‌ها در مقایسه با روش‌های تک‌هدفه پرداخته شده است. همچنین به منظور مطالعه تاثیر طبقه‌بندی‌کننده در تعیین ویژگی‌های بهینه و در نتیجه نقشه طبقه‌بندی نهایی از دو طبقه‌بندی‌کننده SVM و ANFIS استفاده شده و نتایج مورد بررسی قرار گرفته است. لازم به ذکر است به عنوان هدف فرعی دیگری از این تحقیق در انتها به تحلیل و بررسی برخی ویژگی‌های پلاریمتری بهینه پرداخته شده است.

۵-۱ روش تحقیق

به منظور تحقق اهداف این پایان‌نامه، روش‌های پیشنهادی در قالب دو طرح انتخاب ویژگی تک‌هدفه و چندهدفه ارائه شده است. روش‌های تلفیقی از الگوریتم ژنتیک (GA) و شبکه‌های عصبی پرسپترون چند لایه (MLP) و همچنین ماشین‌های بردار پشتیبان (SVMs) تحت عناوین GAML و GASVM، به منظور بیشینه کردن دقت طبقه‌بندی در راستای طرح تک‌هدفه بکار گرفته می‌شود. در انتخاب ویژگی چندهدفه از دو روش MOGA-SVM و MOGA-ANFIS تلفیقی از الگوریتم ژنتیک با مرتب‌سازی نامغلوب ۲ (NSGA-II) و دو طبقه‌بندی‌کننده ماشین بردار پشتیبان و سیستم استنتاج عصبی-فازی تطبیقی (ANFIS) استفاده خواهد شد. روش‌های پیشنهادی بر مبنای حداقل‌سازی دو تابع هدف می‌باشند: (۱) خطای کلی طبقه‌بندی، و (۲) تعداد ویژگی‌های انتخابی PolSAR. توصیف جزئی‌تر این روش‌ها در فصل سوم شرح داده خواهد شد.


۶-۱ ساختار پایان نامه

در فصل اول به مروری بر پیشینه کارهای انجام شده در زمینه انتخاب پارامترهای بهینه در طبقه‌بندی تصاویر پلاریمتری SAR، انگیزه و اهداف این پایان نامه پرداخته شد. در فصل دوم مروری کوتاه بر کلیات پلاریمتری و ویژگی‌های PolSAR خواهیم داشت. روش‌های انتخاب ویژگی GASVM، GAMLP، MOGA-SVM و MOGA-ANFIS و همچنین روش‌های مبنا در فصل سوم شرح داده می‌شود. در ابتدای فصل چهارم توصیف مجموعه داده و گام‌های پیش‌پردازش خواهد آمد و در ادامه الگوریتم‌ها برای انتخاب ویژگی و طبقه‌بندی داده پلاریمتری مورد استفاده قرار می‌گیرند و نتایج آن‌ها بررسی می‌گردد؛ و در نهایت در فصل پنجم نتیجه‌گیری این پژوهش و پیشنهادات برای کارهای آینده ارائه خواهد شد.

فصل دوم: مروری بر اصول پلاریمتری و ویژگی‌های پلاریمتری SAR

۱-۲ اصول کلی پلاریمتری

امواج الکترومغناطیس از دو میدان الکتریکی و مغناطیسی که بر یکدیگر و بر جهت انتشار عمود هستند، تشکیل شده است که رفتار این امواج را می‌توان با استفاده از معادلات ماکسول بیان کرد (Lee and Pottier, 2009). بر اساس معادلات ماکسول، با تغییر زمانی میدان الکتریکی، میدان مغناطیسی و با تغییر زمانی میدان مغناطیسی، میدان الکتریکی حاصل می‌شود (شکل ۱-۲).



شکل ۱-۲. انتشار موج الکترومغناطیس. بردار میدان الکتریکی (قرمز) شامل مولفه‌های افقی (سبز) و عمودی (آبی) (Lee and Pottier, 2009)

خصوصیات برداری دامنه میدان الکتریکی مطابق معادله (۱-۲) نشان داده می‌شود (Elachi and van Zyl, 2006):

$$A = a_h e^{i\delta_h} \hat{h} + a_v e^{i\delta_v} \hat{v} \quad (1-2)$$


دو بردار متعامد تشکیل‌دهنده میدان الکتریکی، \hat{h} و \hat{v} خصوصیات میدان الکتریکی را توصیف می‌کنند. مطابق رابطه (۱-۲) \hat{h} معرف مولفه افقی میدان الکتریکی که از تجزیه میدان الکتریکی در صفحه عمود بر انتشار موج و \hat{v} معرف مؤلفه قائم میدان الکتریکی و در صفحه انتشار موج قرار گرفته است. دامنه‌های a_h و a_v و همچنین فازهای نسبی δ_h و δ_v اعدادی حقیقی می‌باشند.

همان‌طور که در شکل ۱-۲ مشاهده می‌شود نقطه انتهایی بردار میدان الکتریکی با زمان تغییر می‌کند، به شکل و مکان هندسی این نقطه (در صفحه عمود بر جهت انتشار) که یک تابع برحسب زمان است پلاریزاسیون می‌گویند. معادله این مکان هندسی مطابق رابطه (۲-۲) می‌باشد به طوری که

$$E_h = a_h \cos \delta_h, \quad E_v = a_v \cos \delta_v \quad (\text{Elachi and van Zyl, 2006}):$$

$$\left(\frac{E_h}{a_h}\right)^2 + \left(\frac{E_v}{a_v}\right)^2 - 2\frac{E_h}{a_h}\frac{E_v}{a_v}\cos(\delta_h - \delta_v) = \sin^2(\delta_h - \delta_v) \quad (2-2)$$

عبارت ذکر شده، معادله یک بیضی پلاریزاسیون را نشان می‌دهد که در شکل ۲-۲ نمایش داده شده است.



شکل ۲-۲. بیضی پلاریزاسیون (Elachi and van Zyl, 2006)

بیضی پلاریزاسیون توسط دو مؤلفه، زاویه جهت‌گیری^۱ بیضی ψ ($0 \leq \psi \leq \pi$) و زاویه بیضویت^۲ χ ($-\pi/4 \leq \chi \leq \pi/4$) که در شکل ۲-۲ نشان داده شده است، قابل توصیف می‌باشد. تحت شرایط خاص، بیضی می‌تواند به یک دایره و یا یک خط راست تبدیل شود، که در این صورت پلاریزاسیون دایره‌ای و یا خطی بدست خواهد آمد. در پلاریزاسیون خطی، زاویه بیضویت برابر با صفر و در پلاریزاسیون دایره‌ای، زاویه بیضویت برابر با ۴۵ درجه می‌باشد.

۲-۲ ویژگی‌های پلاریمتری

سیستم‌های پلاریمتری و یا سیستم‌های راداری با پلاریزاسیون چهارگانه^۳، قابلیت ارسال و دریافت امواج را در پلاریزاسیون خطی افقی (h) و قائم (v) دارند. ثبت اطلاعات دامنه و فاز چهار ویژگی hh ، hv ، vh و vv در قالب ماتریس‌های پلاریمتری منبعی بسیار مفید جهت شناخت پراکنش‌های راداری اهداف مختلف می‌باشد. برای استفاده از این اطلاعات ویژگی‌های مختلفی از داده پلاریمتری استخراج می‌شود که می‌توان آن‌ها را به سه دسته تقسیم کرد (Maghsoudi et al., 2012): (۱) ویژگی‌هایی که مستقیماً از داده اصلی بدست می‌آیند، (۲) تفکیک‌کننده‌های PolSAR و (۳) ویژگی‌های حاصل از

^۱ orientation

^۲ ellipticity

^۳ quad polarization

الگوریتم‌های تجزیه هدف.

۲-۲-۱ ویژگی‌های اصلی

اساسی‌ترین منبع اطلاعاتی سیستم‌های پلاریمتر، ماتریس پراکندگی می‌باشد که به ازای کوچکترین واحد رزولوشن تصاویر راداری قابل اندازه‌گیری است. در سیستم‌های پلاریمتری با ارسال امواج همدوس در پلاریزاسیون افقی و عمودی و دریافت همزمان در این دو پلاریزاسیون، چهار حالت پلاریمتری (hh , hv , vh , vv) در ماتریس پراکندگی ذخیره می‌شود. این ماتریس ارتباط میدان الکتریکی تابشی و بازتابی را با استفاده از رابطه (۲-۳) برقرار می‌کند (Kozlov et al., 2004).

$$\begin{pmatrix} E_h \\ E_v \end{pmatrix}^{sc} = \frac{e^{ikr}}{r} \begin{pmatrix} S_{hh} & S_{hv} \\ S_{vh} & S_{vv} \end{pmatrix} \begin{pmatrix} E_h \\ E_v \end{pmatrix}^{ill} \quad (2-3)$$

$$[S] = \begin{pmatrix} S_{hh} & S_{hv} \\ S_{vh} & S_{vv} \end{pmatrix}$$

در این معادله E_h و E_v معرف مؤلفه‌های افقی و قائم میدان الکتریکی، ill معرف میدان الکتریکی تابشی، sc معرف میدان الکتریکی پراکنده شده، r نماینده فاصله عارضه هدف تا گیرنده آنتن و k عدد موج می‌باشد و ماتریس S که از المان‌های S_{hh} , S_{hv} , S_{vh} و S_{vv} تشکیل شده است به عنوان ماتریس پراکندگی معرفی می‌شود (Zebker and Van Zyl, 1991). المان‌های این ماتریس را اعداد مختلط تشکیل می‌دهند و حاوی اطلاعات دامنه و فاز چهار ویژگی پلاریمتری می‌باشند. در بسیاری از کاربردهای سنجش از دور راداری، در صورت منطبق بودن آنتن‌های فرستنده و گیرنده، ماتریس پراکندگی را متقارن در نظر می‌گیرند به طوری که S_{vh} و S_{hv} برابر خواهند بود. ماتریس پراکندگی تنها برای توصیف پراکنده‌سازهای خالص^۱ بکار برده می‌شود و قادر به توصیف پراکنده‌سازهای غیرمنفرد^۲ نیست (Cloude and Pottier, 1996). پراکنده‌سازهای غیرمنفرد به علت حضور نویز اسپکل، تنها از لحاظ آماری قابل توصیف هستند. به منظور کاهش نویز، نمایش مرتبه دوم ماتریس پراکندگی یعنی ماتریس‌های میانگین کواریانس $\langle [C] \rangle$ و همبستگی $\langle [T] \rangle$ برای آنالیز این پراکنده‌سازها بکار می‌رود. با در نظر گرفتن دو بردار هدف \underline{h} حاوی المان‌های ماتریس پراکندگی و \underline{k}

^۱ pure

^۲ distributed

حاوی پارامترهای Pauli، این دو ماتریس از روابط (۴-۲) و (۵-۲) بدست می‌آیند.

$$\underline{h} = [S_{hh} \quad \sqrt{2}S_{hv} \quad S_{vv}]^T, \quad \langle [C] \rangle = \langle \underline{h}, \underline{h}^{*T} \rangle = \begin{bmatrix} \langle |S_{hh}|^2 \rangle & \sqrt{2}\langle S_{hh}S_{hv}^* \rangle & \langle S_{hh}S_{vv}^* \rangle \\ \sqrt{2}\langle S_{hv}S_{hh}^* \rangle & 2\langle |S_{hv}|^2 \rangle & \sqrt{2}\langle S_{hv}S_{vv}^* \rangle \\ \langle S_{vv}S_{hh}^* \rangle & \sqrt{2}\langle S_{vv}S_{hv}^* \rangle & \langle |S_{vv}|^2 \rangle \end{bmatrix} \quad (۴-۲)$$

$$\underline{k} = \frac{1}{\sqrt{2}} [S_{hh} + S_{vv} \quad S_{hh} - S_{vv} \quad 2S_{hv}]^T \quad (۵-۲)$$

$$\langle [T] \rangle = \langle \underline{k}, \underline{k}^{*T} \rangle = \frac{1}{2} \begin{bmatrix} \langle |S_{hh} + S_{vv}|^2 \rangle & \langle (S_{hh} + S_{vv})(S_{hh} - S_{vv})^* \rangle & 2\langle (S_{hh} + S_{vv})S_{hv}^* \rangle \\ \langle (S_{hh} - S_{vv})(S_{hh} + S_{vv})^* \rangle & \langle |S_{hh} - S_{vv}|^2 \rangle & 2\langle (S_{hh} - S_{vv})S_{hv}^* \rangle \\ 2\langle S_{hv}(S_{hh} + S_{vv})^* \rangle & 2\langle S_{hv}(S_{hh} - S_{vv})^* \rangle & 4\langle |S_{hv}|^2 \rangle \end{bmatrix}$$

در این روابط، علامت $\langle \dots \rangle$ نشان‌دهنده میانگین‌گیری مکانی، و علائم "*" و "T" به ترتیب نشانگر مزدوج مختلط و ترانپوز می‌باشد.

۲-۲-۲ ویژگی‌های تفکیک‌کننده PolSAR

کمیت‌های مختلفی از داده SAR به عنوان شاخص برای تمییز انواع سطوح یا پوشش‌های زمین استخراج شده است. از جمله این تفکیک‌کننده‌ها می‌توان به توان کل^۱، ماکزیمم و مینیمم توان دریافتی، پلاریزاسیون کسری^۲، ماکزیمم و مینیمم درجه پلاریزاسیون^۳، ماکزیمم و مینیمم شدت کل پراکنده شده، ضرایب وابستگی^۴ و ضریب تغییر^۵ اشاره کرد که در ادامه به شرح آن‌ها خواهیم پرداخت.

۱-۲-۲-۲ توان کل

این پارامتر توان کل دریافتی از چهار کانال سیستم رادار را بیان می‌کند که در سیستم‌های SAR مونواستاتیک^۶ با مقارن در نظر گرفتن ماتریس پراکنش از طریق معادله (۶-۲) بدست می‌آید.

$$SPAN = |S_{hh}|^2 + |S_{vv}|^2 + 2|S_{hv}|^2 \quad (۶-۲)$$

^۱ total power

^۲ fractional polarization

^۳ degree of polarization

^۴ correlation coefficients

^۵ coefficient of variation

^۶ monostatic

توان کل نسبت به دیگر ویژگی‌های اطلاعاتی، نویز اسپکل کمتری دارد (Small, 1991) و از آنجا که متناسب با روشنایی تصویر می‌باشد از آن برای نمایش داده‌های پلاریمتری استفاده می‌شود.

۲-۲-۲-۲ ماکزیمم و مینیمم توان دریافتی

ماکزیمم و مینیمم توان دریافتی به ازای زوایای پلاریزاسیون مختلف (ψ, χ) موج ارسالی برای تفکیک پوشش‌های مختلف زمینی استفاده شده است (Evans *et al.*, 1988). اگرچه محاسبه این پارامترها از نظر محاسباتی مقرون به صرفه نیست، اما برای تفکیک مناطق مختلف در تصاویر پلاریمتریک مفید است.

۳-۲-۲-۲ پلاریزاسیون کسری

پلاریزاسیون کسری به عنوان معیاری از خلوص پلاریزاسیون سیگنال بازگشتی استفاده می‌شود. این پارامتر با رابطه (۷-۲) ارائه شده است:

$$F = \frac{(P_{max} - P_{min})}{(P_{max} + P_{min})} \quad (7-2)$$

که در آن P_{min} و P_{max} ماکزیمم و مینیمم توان دریافتی هستند (Durden *et al.*, 1989). اگر $F = 1$ باشد، متوسط بازگشت کاملاً قطبیده^۱ است و تغییر پلاریزاسیون آنتن (فرستنده و گیرنده) موجب تغییر نسبتاً زیاد در متوسط توان بازگشتی می‌گردد. در حالت $F = 0$ ، متوسط بازگشت ناقطبیده^۲ است و تغییر پلاریزاسیون آنتن توان بازگشتی را تغییر نخواهد داد.

۴-۲-۲-۲ ماکزیمم و مینیمم درجه پلاریزاسیون

درجه پلاریزاسیون نسبت بین شدت بخش قطبیده و شدت کل پراکنده شده می‌باشد. درجه پلاریزاسیون برای امواج کاملاً قطبیده یک و برای امواج ناقطبیده صفر است (Lee and Pottier, 2009).

^۱ fully polarized

^۲ unpolarized

$$dop = \frac{\sqrt{S_1^2 + S_2^2 + S_3^2}}{S_0} \quad (۸-۲)$$

S_0 متناسب با شدت کل موج، S_1 اختلاف بین توان مربوط به پلاریزاسیون‌های افقی و قائم، و پارامترهای S_2 و S_3 اختلاف فاز بین مولفه‌های قائم و افقی میدان الکتریکی می‌باشد. یک روش محاسباتی تحلیلی نیز برای محاسبه درجه پلاریزاسیون ماکزیمم و مینیمم پیشنهاد شده است (Touzi et al., 1992).

درجه پلاریزاسیون می‌تواند به عنوان فاکتوری مهم در طبقه‌بندی استفاده شود. برای مثال، سطوح بدون پوشش گیاهی یا ساختمان‌ها به این علت که تقریباً بازتاب تک‌انعکاسی^۱ یا دو انعکاسی^۲ دارند مقادیر بالای درجه پلاریزاسیون را شامل می‌شوند، درحالی‌که جنگل‌ها و مراتع به علت داشتن بازتاب‌های مختلف چندگانه^۳ درجه پلاریزاسیون پائینی دارند (Chang and Oh, 2007).

۵-۲-۲-۲ ماکزیمم و مینیمم شدت کل پراکنده شده

Touzi و همکاران (1992) شدت کل پراکنده شده را به مولفه‌های کاملاً قطبیده و کاملاً ناقطبیده تقسیم کردند، و برای هرکدام ماکزیمم و مینیمم محاسبه شد. آن‌ها نشان دادند که این پارامترها می‌توانند همراه با درجه پلاریزاسیون و پارامترهای دیگر برای تفکیک عوارض استفاده شوند. Maghsoudi و همکاران (2012) به این علت که ماکزیمم شدت پراکنده شده کاملاً ناقطبیده و ضریب پلاریزاسیون کسری از یکدیگر مستقل نیستند، تنها مولفه مینیمم این پارامتر را برای تهیه نقشه جنگل بکار بردند.

۶-۲-۲-۲ ضرایب وابستگی

ضریب وابستگی بین دو کانال، میزان وابستگی بین آن‌ها در رادار پلاریمتری می‌باشد. ضریب وابستگی یک عدد مختلط است و به صورت رابطه (۹-۲) محاسبه می‌شود.

¹ single-bounce
² double-bounce
³ multiple

$$\rho_{hh-vv} = \frac{\langle S_{hh} S_{vv}^* \rangle}{\sqrt{\langle |S_{hh}|^2 \rangle \langle |S_{vv}|^2 \rangle}} \quad (9-2)$$

مقدار کم برای این پارامتر حاکی از پراکندگی حجمی^۱ غالب، و مقدار زیاد آن می‌تواند ناشی از پراکندگی سطحی^۲ باشد. این دو کانال عمدتاً hh و vv هستند، اما این ضریب برای دو کانال hh و hv و همچنین vv و hv نیز می‌تواند محاسبه شود.

$$\rho_{hh-hv} = \frac{\langle S_{hh} S_{hv}^* \rangle}{\sqrt{\langle |S_{hh}|^2 \rangle \langle |S_{hv}|^2 \rangle}} \quad (10-2)$$

$$\rho_{vv-hv} = \frac{\langle S_{vv} S_{hv}^* \rangle}{\sqrt{\langle |S_{vv}|^2 \rangle \langle |S_{hv}|^2 \rangle}}$$

این سه ضریب وابستگی بصورت تابعی از پارامترهای سطح هدف گزارش شده‌اند. اگر این ضرایب یک باشد سیگنال‌های دریافتی از دو کانال به صورت خطی به هم وابسته‌اند، به عنوان مثال در یک بازتاب‌دهنده سه‌وجهی^۳ ایده‌آل. همچنین در صورت وجود نویز در یکی از کانال‌ها و یا در صورتی که امواج دریافتی پلاریزاسیون جزئی داشته باشند این ضرایب از یک کمتر خواهد بود. از المان‌های پلاریزاسیون دایره‌ای چپ و راست نیز یک ضریب همبستگی بدست می‌آید که این ضریب نیز تابعی از پارامترهای سطح می‌باشد. نشان داده شده است که این پارامتر برای سطوح خاک بدون پوشش گیاهی و تشخیص زبری خاک مناسب می‌باشد (Mattia et al., 1997). رابطه (۱۱-۲) چگونگی محاسبه این ضریب همبستگی را بیان می‌کند.

$$\rho_{rr-ll} = \frac{\langle S_{RR} S_{LL}^* \rangle}{\sqrt{\langle |S_{RR}|^2 \rangle \langle |S_{LL}|^2 \rangle}} \quad (11-2)$$

چهار ضریب وابستگی بین پلاریزاسیون‌ها پارامترهای مهمی در داده PolSAR هستند و از آنجا که این ضرایب تابعی از پارامترهای هدف می‌باشند می‌توان از آن‌ها به عنوان ویژگی در طبقه‌بندی استفاده کرد.

Kim و همکاران (2000) دو ضریب وابستگی، C_d و C_s ، را به عنوان ویژگی در طبقه‌بندی پیشنهاد

¹ volume scattering

² surface scattering

³ trihedral corner reflector

کرده‌اند که در رابطه (۲-۱۲) نشان داده شده است. اما این دو ضریب معادل دو المان از ماتریس همبستگی می‌باشند، لذا نیازی به استفاده مجدد از این پارامترها همزمان با المان‌های ماتریس همبستگی در فرآیند طبقه‌بندی نیست.

$$C_d = \langle (S_{hh} - S_{vv})(S_{hh} - S_{vv})^* \rangle \quad (۲-۱۲)$$

$$C_s = \langle (S_{hh} + S_{vv})(S_{hh} + S_{vv})^* \rangle$$

۲-۲-۲-۷ ضریب تغییر

پارامتر ضریب تغییر به صورت نسبت مینیمم توان دریافتی به ماکزیمم آن تعریف می‌شود (Van Zyl *et al.*, 1987). این پارامتر برای نشان دادن ناهمگنی مکانی عارضه هدف، حاصل از تغییر ویژگی‌های پراکندگی پیکسل‌های همسایه و یا برای نشان دادن حضور چندین پراکندگی معرفی شده است. مناطق شهری و پارک‌ها ضریب تغییر بالاتری نسبت به اقیانوس‌ها دارند (Evans *et al.*, 1988).

۲-۲-۳ ویژگی‌های تجزیه هدف

الگوریتم‌های تجزیه هدف به تفسیر فرآیند پراکنش و اطلاعات فیزیکی موجود در مشاهدات پراکنشی مرتبط با سطوح مختلف کمک می‌کنند. بر مبنای نوع ماتریسی که در تجزیه استفاده می‌شود می‌توان این الگوریتم‌ها را به دو دسته همدوس و ناهمدوس تقسیم‌بندی کرد (Pottier and Ferro-Famil, 2005). ویژگی‌های تجزیه هدف همدوس براساس ماتریس پراکندگی و ویژگی‌های تجزیه هدف ناهمدوس براساس ماتریس‌های همبستگی یا کواریانس می‌باشند. ویژگی‌های هر دو دسته به نحوی مکانیزم‌های پراکندگی را توصیف می‌کنند و می‌توانند نقش مکملی در شناسایی اهداف طبیعی و عوارض ساخت بشر داشته باشند. به طور کلی روش‌های تجزیه همدوس برای عوارض ساخت بشر مانند ساختمان، جاده و راه‌آهن مناسب هستند، درحالی‌که روش‌های ناهمدوس، عوارض طبیعی مانند جنگل و زمین‌های کشاورزی را بهتر توصیف می‌کنند. در ادامه از روش‌های همدوس به بررسی الگوریتم‌های تجزیه Pauli و Krogager پرداخته و از روش‌های ناهمدوس الگوریتم‌های تجزیه Touzi و Yamaguchi, Freeman, Cloude-Pottier, VanZyl, Holm, Cloude, Barnes, Huynen بررسی می‌شود.

۲-۳-۱ تجزیه همدوس

یکی از تئوری‌های تجزیه هدف روش‌های تجزیه همدوس می‌باشد. در این روش‌ها ماتریس پراکندگی جهت مشخص کردن خصوصیات پراکنشی عارضه هدف تنها زمانی که امواج فرودی و پراکنده شده کاملاً قطبیده باشند، استفاده می‌شود. بنابراین، این روش جهت بررسی خصوصیات اهداف همدوس بکار گرفته شده است که این پراکنده‌سازها به اهداف منفرد^۱ یا خالص نیز معروفند.

هدف از تجزیه‌های همدوس بیان ماتریس پراکندگی $[S]$ به صورت ترکیبی از ماتریس‌های مبنا مربوط به مکانیزم‌های پراکندگی استاندارد^۲ می‌باشد. در حالت واقع، ماتریس پراکندگی اندازه‌گیری شده مرتبط با پراکنش عارضه‌های پیچیده است که در حالت‌های خاصی این ماتریس مرتبط با پراکنش عارضه‌های ساده و استاندارد می‌باشد، مانند بازتاب‌دهنده‌های سه‌وجهی که جهت کالیبره نمودن تصاویر SAR بکار برده می‌شوند. با این وجود، در حالت کلی آنالیز مستقیم این ماتریس جهت بررسی خصوصیات فیزیکی عارضه‌های هدف، امری بسیار پیچیده است. به همین دلیل ماتریس پراکندگی به صورت ترکیبی از پراکنش عارضه‌های مبنا نشان داده می‌شود (Pottier and Ferro, 2005).

$$[S] = \sum_{i=1}^k c_i [S]_i \quad (2-13)$$

در رابطه (۲-۱۳)، $[S]_i$ ماتریس پراکنش اهداف استاندارد نظیر کره، صفحه، ساختارهای سه‌وجهی و ساختارهای دووجهی می‌باشد و c_i وزن اهداف استاندارد در ماتریس پراکنش اندازه‌گیری شده را تعیین می‌کند.

تجزیه Pauli

تجزیه Pauli ماتریس پراکندگی $[S]$ را به صورت ترکیبی از ماتریس‌های Pauli بیان می‌کند (Cloude and Pottier, 1996). ماتریس‌های Pauli $\{[S]_a, [S]_b, [S]_c, [S]_d\}$ را می‌توان به صورت رابطه (۲-۱۴) نمایش داد (Borgeaud *et al.*, 1989):

¹ single target
² canonical

$$[S]_a = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad [S]_b = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \quad (۱۴-۲)$$

$$[S]_c = \frac{1}{\sqrt{2}} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \quad [S]_d = \frac{1}{\sqrt{2}} \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

در سیستم مونواستاتیک مبنای Pauli به $\{[S]_a, [S]_b, [S]_c\}$ کاهش می‌یابد:

$$[S] = \begin{bmatrix} S_{hh} & S_{hv} \\ S_{hv} & S_{vv} \end{bmatrix} = \alpha[S]_a + \beta[S]_b + \gamma[S]_c \quad (۱۵-۲)$$

که در آن

$$\alpha = \frac{S_{hh} + S_{vv}}{\sqrt{2}}, \beta = \frac{S_{hh} - S_{vv}}{\sqrt{2}}, \gamma = \sqrt{2}S_{hv} \quad (۱۶-۲)$$

ماتریس $[S]_a$ متناظر با ماتریس پراکندگی یک کره، یک صفحه و یا یک سه‌وجهی می‌باشد. $[S]_a$ به پراکنش تک انعکاسی یا فرد^۱ اشاره دارد و ضریب مختلط α در رابطه (۱۶-۲) سهم $[S]_a$ در ماتریس پراکندگی نهایی را ارائه می‌دهد. شدت این ضریب یعنی $|\alpha|^2$ ، توان پراکنده شده بوسیله این اهداف را مشخص می‌کند. ماتریس $[S]_b$ مکانیزم پراکندگی یک دووجهی (توجیه شده در صفر درجه) را ارائه می‌دهد و به پراکنش دو انعکاسی یا زوج^۲ اشاره دارد. β ضریب مختلط این مکانیزم پراکندگی و $|\beta|^2$ توان پراکنده شده با این نوع اهداف را نشان می‌دهد. $[S]_c$ مربوط به مکانیزم پراکندگی دوسطحی^۳ (توجیه شده در ۴۵ درجه) می‌باشد که بهترین نمونه آن پراکنش حجمی ایجاد شده توسط تاج پوشش گیاهی^۴ جنگل است. ضریب مختلط γ سهم $[S]_c$ از پراکنش است و $|\gamma|^2$ توان پراکنده شده توسط این نوع پراکنده‌سازها می‌باشد.

تجزیه Krogager

در الگوریتم تجزیه Krogager جداسازی ماتریس پراکندگی به صورت ترکیبی از کره، دوسطحی و helix معرفی شده که دو مولفه آخر یک زاویه توجیه را ارائه می‌کنند (Krogager, 1990). ماتریس پراکندگی در این روش به صورت رابطه (۱۷-۲) تجزیه می‌شود:

¹ odd bounce
² even bounce
³ diplane
⁴ canopy

$$S_{(H,V)} = e^{j\varphi} \{ e^{j\varphi_s} k_s [S]_{sphere} + k_d [S]_{diplane(\theta)} + k_h [S]_{helix(\theta)} \} \quad (17-2)$$

$$= e^{j\varphi} \left\{ e^{j\varphi_s} k_s \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} + k_d \begin{bmatrix} \cos 2\theta & \sin 2\theta \\ \sin 2\theta & -\cos 2\theta \end{bmatrix} + k_h e^{\mp j2\theta} \begin{bmatrix} 1 & \pm j \\ \pm j & -1 \end{bmatrix} \right\}$$

هر دو تجزیه Pauli و Krogager تعداد یکسان شش پارامتر مستقل دارند؛ در تجزیه Pauli ضرایب مختلط α ، β و γ و در تجزیه Krogager سه زاویه θ ، φ_s ، φ و سه ضریب حقیقی k_d ، k_h ، k_s . فاز مطلق φ شامل اطلاعاتی راجع به هدف می‌باشد، اما از آنجا که مقدار آن وابسته به فاصله رادار و هدف است به عنوان یک پارامتر نامناسب در نظر گرفته شده و تعداد پارامترهای مستقل تجزیه Krogager به پنج پارامتر $\{ \varphi_s, \theta, k_s, k_d, k_h \}$ کاهش می‌یابد. θ زاویه توجیه مولفه دوسطحی و helix است. پارامترهای φ_s و k_s مولفه کروی تجزیه را مشخص می‌کنند. فاز φ_s جابجایی کره را نسبت به مولفه دوسطحی و helix ارائه می‌دهد، پارامتر k_s سهم مولفه کره در ماتریس پراکندگی نهایی و ضرایب k_d ، k_h متناظر با سهم مولفه‌های helix و دوسطحی بیان می‌شوند. در نتیجه $|k_s|^2$ ، $|k_d|^2$ و $|k_h|^2$ به ترتیب توان پراکنده شده به وسیله مولفه‌های کره، دوسطحی و helix از تجزیه Krogager تفسیر می‌شوند (Pottier and Ferro-Famil, 2005).

تجزیه‌های همدوس تنها آنالیز اهداف خالصی که پاسخ پراکنش آن‌ها کاملاً با اندازه‌گیری ماتریس $[S]$ تعیین شده را بکار می‌گیرند. در نتیجه هنگام کار با تصاویر SAR لازم است تعیین شود که آیا پیکسل متعلق به یک هدف خالص است و یا به یک هدف غیرمنفرد تعلق دارد. مشکل دیگر تجزیه‌های همدوس این است که آن‌ها تاثیر نویز اسپکل را در داده تک‌منظره^۱ نادیده می‌گیرند. برای حل این مشکل از فیلترها و متوسط‌گیری داده استفاده می‌شود. به علت همدوسی المان‌های ماتریس $[S]$ ، فیلترها بر مبنای آماره‌های مرتبه دو می‌باشد و این ملاحظات محققان را به استفاده از ماتریس همبستگی یا کواریانس سوق می‌دهد. بنابراین روش‌های تجزیه هدف ناهمدوس توسعه یافت که در بخش بعدی مورد بحث و بررسی قرار خواهد گرفت.

۲-۳-۲ تجزیه ناهمدوس

همان‌طور که قبلاً توضیح داده شد، ماتریس پراکنش جهت بررسی خصوصیات پراکنده‌سازهای

¹ single look

منفرد یا همبسته مورد استفاده قرار می‌گیرد، به طوری که نمی‌توان از این ماتریس به تنهایی جهت بررسی خصوصیات پراکنده‌سازهای غیرمنفرد استفاده نمود. جهت کاهش نویز اسپکل در پراکنده‌سازهای غیرمنفرد نمایش مرتبه دوم ماتریس پراکنش برای آنالیز این اهداف بکار برده می‌شود. در روش‌های تجزیه هدف ناهمدوس، ماتریس‌های کواریانس میانگین $\langle [C] \rangle$ و یا همبستگی میانگین $\langle [T] \rangle$ ، جهت استخراج پارامترهای میانگین برای تشخیص خصوصیات پراکنشی عارضه‌های هدف مختلف مورد استفاده قرار می‌گیرند (Cloude and Pottier, 1996). بر اساس روش‌های ناهمدوس، بررسی ماتریس‌های کواریانس و همبستگی به تنهایی امری پیچیده می‌باشد، به همین دلیل همانند روش همدوس این ماتریس‌ها به صورت ترکیبی از المان‌های پایه به ترتیب با ضرایب p_i و q_i نمایش داده می‌شوند (Pottier and Ferro-Famil, 2005).

$$[C] = \sum_{i=1}^k p_i [C]_i \quad (۱۸-۲)$$

$$[T] = \sum_{i=1}^k q_i [T]_i$$

بر اساس این روابط الگوریتم‌های تجزیه مختلفی ارائه شده است که در ادامه در سه دسته تجزیه بر مبنای ماتریس Kennaugh، تجزیه مدل مبنای ماتریس کواریانس یا همبستگی و تجزیه بر اساس آنالیز مقادیر ویژه ارائه خواهد شد.

پارامترهای حاصل از الگوریتم‌های تجزیه بر مبنای ماتریس Kennaugh

تجزیه Huynen

ایده اصلی تجزیه Huynen جداسازی داده ورودی به یک هدف متوسط منفرد و یک مولفه باقیمانده با نام "N-target" می‌باشد (Huynen, 1970). این تجزیه نوع خاصی از پارامترسازی اهداف غیرمنفرد را در نظر می‌گیرد. به منظور نمایش این نوع اهداف، ماتریس Kennaugh با رابطه (۱۹-۲) یا ماتریس همبستگی با رابطه (۲۰-۲) در نظر گرفته می‌شود.

$$[K] = \begin{bmatrix} A_0 + B_0 & C & H & F \\ C & A_0 + B & E & G \\ H & E & A_0 - B & D \\ F & G & D & -A_0 + B \end{bmatrix} \quad (۱۹-۲)$$

$$\langle [T_3] \rangle = \begin{bmatrix} 2\langle A_0 \rangle & \langle C \rangle - j\langle D \rangle & \langle H \rangle + j\langle G \rangle \\ \langle C \rangle + j\langle D \rangle & \langle B_0 \rangle + \langle B \rangle & \langle E \rangle + j\langle F \rangle \\ \langle H \rangle - j\langle G \rangle & \langle E \rangle - j\langle F \rangle & \langle B_0 \rangle - \langle B \rangle \end{bmatrix} \quad (۲۰-۲)$$

این الگوریتم با ۹ پارامتر مستقل تفسیر فیزیکی هدف را ارائه می‌دهد، درحالی‌که یک عارضه منفرد ثابت با پنج پارامتر مستقل توصیف می‌شود. بنابراین هدف اصلی تجزیه Huynen ارائه هدف به صورت یک هدف منفرد یا نقطه‌ای $[T_0]$ و یک هدف غیرمنفرد $[T_N]$ شامل چهار درجه آزادی باقیمانده می‌باشد. از این‌رو در تجزیه Huynen ماتریس همبستگی به صورت زیر است:

$$\langle [T_3] \rangle = [T_0] + \langle [T_N] \rangle \quad (۲۱-۲)$$

که در آن

$$[T_0] = \begin{bmatrix} 2\langle A_0 \rangle & \langle C \rangle - j\langle D \rangle & \langle H \rangle + j\langle G \rangle \\ \langle C \rangle + j\langle D \rangle & B_{0T} + B_T & E_T + jF_T \\ \langle H \rangle - j\langle G \rangle & E_T - jF_T & B_{0T} - B_T \end{bmatrix} \quad (۲۲-۲)$$

و

$$\langle [T_N] \rangle = \begin{bmatrix} 0 & 0 & 0 \\ 0 & B_{0N} + B_N & E_N + jF_N \\ 0 & E_N - jF_N & B_{0N} - B_N \end{bmatrix} \quad (۲۳-۲)$$

N-target تنها با پارامترهای (B_{0N}, B_N, E_N, F_N) تعریف شده و ارائه‌دهنده پارامترهای هدف کاملاً نامتقارن است. یکی از ویژگی‌های اصلی این تجزیه آن است که $\langle [T_N] \rangle$ تحت دوران سیستم مختصات آنتن در جهت خط دید رادار ثابت است یعنی roll-invariant است.

به طور کلی تئوری تجزیه هدف Huynen بر مبنای معادلات (۲۴-۲) می‌باشد (Pottier, 1993).

$$\begin{aligned} 2A_0(B_{0T} + B_T) &= C^2 + D^2 \\ 2A_0(B_{0T} - B_T) &= G^2 + H^2 \\ 2A_0E_T &= CH - DG \end{aligned} \quad (۲۴-۲)$$

$$2A_0 F_T = CG + DH$$

با توجه به ماهیت این تجزیه استفاده از آن برای آنالیز مناطق ساخت بشر معقول است. این مناطق یا مناطقی که تراکم بالایی از اهداف خالص دارند، با استفاده از این تجزیه مورد مطالعه قرار گرفته‌اند. تجزیه Huynen اهداف غیرمنفرد صحنه‌های طبیعی را به عنوان مولفه نويز در نظر می‌گیرد (Pottier and Ferro-Famil, 2005).

تجزیه Barnes

Barnes ثابت کرد که ساختار پیشنهاد شده توسط Huynen منحصر به فرد نیست و تجزیه‌های دیگری با ساختار مشابه می‌تواند ایجاد شود (Barnes, 1988). همان‌طور که ذکر شد در تجزیه Huynen، T_N از لحاظ دورانی ثابت است. به عبارت دیگر فضای برداری تولید شده با T_N به فضای برداری تولید شده با هدف خالص T_0 عمود است. در این صورت برای بردار دلخواه q که به فضای N-target تعلق دارد معادلات زیر ارائه شده است.

$$T_N q = 0 \quad (25-2)$$

$$T_N(\theta)q = 0 \rightarrow U(\theta)T_N U(\theta)^{-1}q = 0$$

$U(\theta)$ ماتریس دوران 3×3 است. با محاسبه بردارهای ویژه این ماتریس نهایتاً سه بردار هدف نرمال شده از معادله (۲۶-۲) بدست می‌آید.

$$k_{01} = \frac{1}{\sqrt{\langle 2A_0 \rangle}} \begin{bmatrix} 2\langle A_0 \rangle \\ \langle C \rangle + j\langle D \rangle \\ \langle H \rangle - j\langle G \rangle \end{bmatrix}$$

$$k_{02} = \frac{1}{\sqrt{2(\langle B_0 \rangle - \langle F \rangle)}} \begin{bmatrix} \langle C \rangle - \langle G \rangle + j\langle H \rangle - j\langle D \rangle \\ \langle B_0 \rangle + \langle B \rangle - \langle F \rangle + j\langle E \rangle \\ \langle E \rangle + j\langle B_0 \rangle - j\langle B \rangle - j\langle F \rangle \end{bmatrix} \quad (26-2)$$

$$k_{03} = \frac{1}{\sqrt{2(\langle B_0 \rangle + \langle F \rangle)}} \begin{bmatrix} \langle H \rangle + \langle D \rangle + j\langle C \rangle + j\langle G \rangle \\ \langle E \rangle + j\langle B_0 \rangle + j\langle B \rangle + j\langle F \rangle \\ \langle B_0 \rangle - \langle B \rangle + \langle F \rangle + j\langle E \rangle \end{bmatrix}$$

پارامترهای حاصل از الگوریتم‌های تجزیه بر مبنای مقادیر ویژه

تجزیه بر مبنای بردارهای ویژه به عنوان جایگزینی برای روش Huynen پیشنهاد شده است. بر اساس این روش، با آنالیز نمودن مقادیر ویژه ماتریس همبستگی، پارامترهای میانگین ماتریس پراکنش داده‌های موجود تخمین زده می‌شود. این روش بر اساس فرض توزیع آماری خاصی، نظیر توزیع گوسی داده‌ها پایه‌گذاری نشده است، روش آماری ارائه شده بر این فرض پایه‌گذاری شده است که همیشه یک بیشینه پراکنش میانگین غالب در هر پیکسل موجود می‌باشد که می‌توان با آنالیز کمی داده‌های پلاریمتری، پارامترهای این المان میانگین را استخراج نمود. در این روش ماتریس همبستگی $[T]$ به صورت معادله (۲-۲۷) تجزیه می‌شود (Cloude and Pottier, 1997):

$$\langle [T_3] \rangle = [U_3][\Sigma_3][U_3]^{-1}$$

$$= \frac{1}{2} \begin{bmatrix} \langle |S_{hh} + S_{vv}|^2 \rangle & \langle (S_{hh} + S_{vv})(S_{hh} + S_{vv})^* \rangle & 2\langle (S_{hh} + S_{vv})S_{hv}^* \rangle \\ \langle (S_{hh} - S_{vv})(S_{hh} + S_{vv})^* \rangle & \langle |S_{hh} - S_{vv}|^2 \rangle & 2\langle (S_{hh} - S_{vv})S_{hv}^* \rangle \\ 2\langle S_{hv}(S_{hh} + S_{vv})^* \rangle & 2\langle S_{hv}(S_{hh} - S_{vv})^* \rangle & 4\langle |S_{hv}|^2 \rangle \end{bmatrix} \quad (2-27)$$

به طوری که ماتریس قطری $[\Sigma_3]$ حاوی مقادیر ویژه $(\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq 0)$ و ماتریس $[U_3]$ شامل بردارهای ویژه ماتریس همبستگی می‌باشد.

$$[\Sigma_3] = \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_3 \end{bmatrix}, \quad [U_3] = [\underline{u}_1 \ \underline{u}_2 \ \underline{u}_3]^T \quad (2-28)$$

با پیدا کردن بردارهای ویژه ماتریس T_3 ، مجموعه‌ای از سه هدف مستقل بدست می‌آید، پس T_3 را می‌توان حاصل مجموع سه مکانیزم پراکندگی دانست. سهم هر مکانیزم با مقدار ویژه λ_i تعیین شده و نوع آن با بردار ویژه \underline{u}_i مرتبط است (Cloude, 1985). اگر فقط یک مقدار ویژه غیر صفر باشد ماتریس T_3 مربوط به یک هدف خالص است و با یک ماتریس پراکندگی مرتبط است. اگر تمام مقادیر ویژه برابر باشند، T_3 از سه مکانیزم پراکندگی متعامد با دامنه‌های مساوی تشکیل شده و هدف را "تصادفی" گویند و ساختار همبسته پلارایز شده به هیچ‌وجه وجود ندارد. در حالتی که T_3 مقادیر ویژه غیر صفر و نابرابر دارد، اهداف بخشی پلارایز یا غیرمنفرد غالب هستند.

تجزیه Cloude

اولین بار Cloude (1985) الگوریتم تجزیه‌ای بر اساس مقادیر ویژه برای تشخیص مکانیزم پراکندگی غالب با استخراج بزرگترین مقدار ویژه (λ_1) ارائه نمود. ماتریس همبستگی استخراج شده T_{01} که با رابطه (۲۹-۲) بیان می‌شود، دارای مرتبه یک است و یک ماتریس پراکندگی معادل S دارد.

$$T_{01} = \lambda_1 \underline{u}_1 \cdot \underline{u}_1^{*T} = \underline{k}_1 \cdot \underline{k}_1^{*T} \quad (29-2)$$

$$\underline{k}_1 = \sqrt{\lambda_1} \underline{u}_1 = \frac{e^{j\phi}}{\sqrt{2A_0}} \begin{bmatrix} 2A_0 \\ C + jD \\ H - jG \end{bmatrix} = e^{j\phi} \begin{bmatrix} \sqrt{2A_0} \\ \sqrt{B_0 + B} e^{+j \arctan(\frac{D}{C})} \\ \sqrt{B_0 - B} e^{-j \arctan(\frac{G}{H})} \end{bmatrix}$$

سه مولفه این بردار هدف معادل با سه جزء Huynen است. فاز مطلق هدف \emptyset بین $-\pi$ و π قرار دارد. این نحوه ارائه بردار هدف k_1 ترکیبی از سه مکانیزم ساده است: پراکنش سطحی، پراکنش ساختار دووجهی، و پراکنش حجمی، که با استفاده از سه مولفه بردار هدف مشخص می‌شوند؛ پراکنش سطحی: $A_0 \gg B_0 + B, B_0 - B$ ، پراکنش ساختار دووجهی: $B_0 + B \gg A_0, B_0 - B$ ، پراکنش حجمی: $B_0 - B \gg A_0, B_0 + B$.

تجزیه Holm

تجزیه Holm تفسیر هدف را به عنوان مجموعی از یک ماتریس پراکندگی S (ماتریس همبستگی مرتبه یک) به علاوه دو ترم نویز و باقیمانده فراهم می‌کند (Holm and Barnes, 1988). این تجزیه روش Huynen را با ترکیب آنالیزی از مقادیر ویژه و مدل نویز بهبود می‌بخشد (Lee and Pottier, 2009). با استفاده از رابطه (۳۰-۲)، ماتریس همبستگی به سه ماتریس تجزیه می‌شود که در آن T_1 وضعیت هدف خالص، T_2 وضعیت هدف غیرمنفرد و T_3 وضعیت هدف غیرمنفرد ناقطبیده را نشان می‌دهد. به عبارتی T_1 و T_2 به ترتیب نمایشی از میانگین هدف و واریانس هدف از میانگین آن را فراهم می‌کنند و T_3 معادل با یک ترم نویزی می‌باشد.

$$T = U_3 \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_3 \end{bmatrix} U_3^{-1} \quad (30-2)$$

$$= U_3 \begin{bmatrix} \lambda_1 - \lambda_2 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} U_3^{-1} + U_3 \begin{bmatrix} \lambda_2 - \lambda_3 & 0 & 0 \\ 0 & \lambda_2 - \lambda_3 & 0 \\ 0 & 0 & 0 \end{bmatrix} U_3^{-1} + U_3 \begin{bmatrix} \lambda_3 & 0 & 0 \\ 0 & \lambda_3 & 0 \\ 0 & 0 & \lambda_3 \end{bmatrix} U_3^{-1}$$

$$= T_1 + T_2 + T_3$$

تجزیه Cloude-Pottier

در الگوریتم تجزیه Cloude-Pottier که به الگوریتم $H/A/a$ نیز معروف است، مقادیر ویژه و بردارهای ویژه ماتریس همبستگی T_3 که از روابط (۲۷-۲) و (۲۸-۲) بدست آمد به عنوان پارامترهای اولیه تجزیه در نظر گرفته می‌شود (Cloude and Pottier, 1997). برای تفسیر فیزیکی و ساده‌سازی آنالیز اطلاعات فیزیکی موجود، پارامترهای فیزیکی ثانویه مانند انتروپی^۱ (H)، ناهمسانگردی^۲ (A) و زاویه آلفا (α) به صورت تابعی از مقادیر ویژه تعریف شده است (Lee and Pottier, 2009).

• انتروپی

انتروپی (H) به عنوان یک اندازه‌گیری از اتفاقی بودن فرآیند پراکندگی تفسیر می‌شود که از مقادیر ویژه ماتریس همبستگی هدف در حالت مونواساتیک طبق رابطه (۳۱-۲) محاسبه می‌شود. برای سطوح صاف H برابر صفر است که با افزایش زبری افزایش پیدا می‌کند.

$$H = - \sum_{i=1}^3 p_i \log_3 p_i \quad p_i = \frac{\lambda_i}{\sum_{j=1}^3 \lambda_j} = \frac{\lambda_i}{\lambda_1 + \lambda_2 + \lambda_3} \rightarrow p_1 + p_2 + p_3 = 1 \quad (31-2)$$

انتروپی در محدوده $[0, 1]$ قرار دارد و به عنوان درجه بی‌نظمی آماری هر نوع پراکنش مجزا نیز تفسیر شده است. از آنجا که مقادیر ویژه از لحاظ دورانی ثابت هستند، انتروپی نیز مستقل از دوران هدف حول خط دید رادار است. روابط زیر در مورد این پارامتر برقرار است (Pottier and Ferro, 2005).

$$H \rightarrow 0 \Rightarrow \quad \lambda_1 = SPAN \quad \lambda_2 = 0 \quad \lambda_3 = 0 \quad (32-2)$$

هنگامی که انتروپی کم است، ماتریس [T] مرتبه یک دارد، فرآیند پراکنش متناظر با یک هدف خالص است و بردار ویژه متناظر با بزرگترین مقدار ویژه تعیین‌کننده مکانیزم پراکندگی غالب است.

¹ entropy
² anisotropy

$$H \rightarrow 1 \Rightarrow \lambda_1 = \frac{SPAN}{3} \quad \lambda_2 = \frac{SPAN}{3} \quad \lambda_3 = \frac{SPAN}{3} \quad (33-2)$$

وقتی انتروپی زیاد است، مرتبه ماتریس [T] برابر ۳ و فرآیند پراکنش حاصل ترکیبی از سه هدف خالص است (اهداف غیرمنفرد). این حالت ترکیبی کاملاً تصادفی را از مکانیزم‌های پراکندگی با احتمالی یکسان نشان می‌دهد.

$$0 < H < 1 \Rightarrow \lambda_i \text{ سه مقدار ویژه مختلف} \quad (34-2)$$

در این حالت، مکانیزم پراکنش نهایی ترکیبی از سه هدف خالص ارائه شده بوسیله سه مقدار ویژه مختلف است، به عبارتی نشان‌دهنده سه هدف منفرد وزن‌دار می‌باشد و مکانیزم پراکندگی براساس مقادیر ویژه وزن‌دهی می‌شود.

هنگامی که انتروپی افزایش می‌یابد، میزان تصادفی بودن پراکنش افزایش می‌یابد و تعداد کلاس‌های قابل تشخیص از مشاهدات پلاریمتریک کاهش می‌یابد. در حالت $H=1$ اطلاعات پلاریزاسیون صفر شده و پراکنش هدف یک فرآیند نویزی تصادفی است.

انتروپی کم در اقیانوس‌ها (پراکندگی بوسیله سطح کمی زبر) و انتروپی زیاد در پارک‌ها رخ می‌دهد. معمولاً در مناطق شهری به علت وجود کلاس‌های مختلف مانند خیابان و ساختمان که در جهت خط دید رادار یا با زاویه‌ای نسبت به آن قرار دارند، ترکیبی از انتروپی کم و زیاد اتفاق می‌افتد. مناسب بودن انتروپی در تفکیک منطقه جنگلی از غیرجنگل، که به ترتیب دارای مقادیر بالا و پائین این پارامتر هستند، نشان داده شده است (Cloude and Pottier, 1996).

• ناهمسانگردی

اگرچه انتروپی توصیف‌گر مناسبی از اتفاقی بودن پراکندگی می‌باشد، تابعی منحصر به فرد از نسبت مقادیر ویژه نیست. از این‌رو، پارامتر ناهمسانگردی (A) تعریف شده است که مکمل انتروپی می‌باشد (Pottier and Lee, 1999).

$$A = \frac{\lambda_2 - \lambda_3}{\lambda_2 + \lambda_3} \quad (35-2)$$

A در محدوده [۰, ۱] قرار دارد و ارتباط بین مقادیر ویژه دوم و سوم را مشخص می‌کند، به عبارت دیگر اختلاف بین مکانیزم‌های پراکندگی دوم و سوم را ارائه می‌دهد. زمانی که A زیاد باشد نشان از حضور فقط یک فرآیند پراکندگی است اما زمانی که کم باشد دو فرآیند پراکندگی حضور دارند (Hellmann, 2001). از نقطه نظر عملی، عمدتاً وقتی که $H > 0.7$ بوده ناهمسانگردی به عنوان پارامتر تمیز بکار رفته است، به این علت که برای انتروپی‌های کمتر، مقادیر ویژه دوم و سوم به شدت تحت تاثیر نویز قرار دارند، در نتیجه A نیز بسیار نویزی می‌باشد.

همان‌طور که بیان شد، هنگامی که انتروپی افزایش می‌یابد، تعداد کلاس‌های قابل تشخیص از مشاهدات پلاریمتریک کاهش می‌یابد. بنابراین A می‌تواند به عنوان پارامتر مفیدی برای بهبود توانایی تشخیص انواع مختلف پراکندگی هنگامی که انتروپی افزایش یافته و به مقدار زیادی می‌رسد، بکار رود (Lee and Pottier, 2009). انتروپی زیاد و A کم مربوط به پراکنش تصادفی و انتروپی و A زیاد مربوط به حضور دو مکانیزم پراکندگی با احتمال یکسان است.

پارامترهای درجه پلاریزاسیون و ناهمسانگردی موج معادل هم هستند و اطلاعات فیزیکی مشابهی فراهم می‌کنند.

• پارامترهای آلفا، بتا، دلتا، گاما و لامبدا

این پارامترها با استفاده از بردارهای ویژه ماتریس همبستگی بدست می‌آید، هر بردار ویژه \underline{u} را می‌توان با پنج زاویه بیان کرد.

$$\underline{u} = \begin{bmatrix} \cos \alpha e^{j\emptyset} & \sin \alpha \cos \beta e^{j(\delta+\emptyset)} & \sin \alpha \sin \beta e^{j(\gamma+\emptyset)} \end{bmatrix}^T \quad (۳۶-۲)$$

$$U_3 = \begin{bmatrix} \cos \alpha_1 e^{j\emptyset_1} & \cos \alpha_2 e^{j\emptyset_2} & \cos \alpha_3 e^{j\emptyset_3} \\ \sin \alpha_1 \cos \beta_1 e^{j(\delta_1+\emptyset_1)} & \sin \alpha_2 \cos \beta_2 e^{j(\delta_2+\emptyset_2)} & \sin \alpha_3 \cos \beta_3 e^{j(\delta_3+\emptyset_3)} \\ \sin \alpha_1 \sin \beta_1 e^{j(\gamma_1+\emptyset_1)} & \sin \alpha_2 \sin \beta_2 e^{j(\gamma_2+\emptyset_2)} & \sin \alpha_3 \sin \beta_3 e^{j(\gamma_3+\emptyset_3)} \end{bmatrix}$$

در رابطه فوق β به عنوان زاویه دوران متناظر با بردار ویژه \underline{u} در صفحه عمود بر صفحه پراکندگی تفسیر می‌شود. ستون‌های ماتریس U_3 دو به دو بر هم عمودند، بنابراین $(\alpha_1, \alpha_2, \alpha_3)$ ، $(\beta_1, \beta_2, \beta_3)$ ، $(\delta_1, \delta_2, \delta_3)$ و $(\gamma_1, \gamma_2, \gamma_3)$ مستقل نیستند. $(\emptyset_1, \emptyset_2, \emptyset_3)$ معادل با فاز مطلق هدف هستند و به عنوان پارامترهای مستقل در نظر گرفته می‌شوند. پارامترهای آلفا، بتا، دلتا، گاما، لامبدا و به عبارتی

متوسط وزن دار این مقادیر از رابطه (۳۷-۲) بدست می‌آید.

$$\bar{\alpha} = \sum_{k=1}^3 p_k \alpha_k \quad \bar{\beta} = \sum_{k=1}^3 p_k \beta_k \quad \bar{\delta} = \sum_{k=1}^3 p_k \delta_k \quad \bar{\gamma} = \sum_{k=1}^3 p_k \gamma_k \quad \bar{\lambda} = \sum_{k=1}^3 p_k \lambda_k \quad (37-2)$$

با استفاده از میانگین پارامترهای مکانیزم پراکندگی غالب که از ماتریس همبستگی بدست می‌آید، می‌توان بردار هدف یکه متوسط \underline{u}_0 و بردار هدف متوسط \underline{k}_0 را به صورت رابطه (۳۸-۲) نشان داد.

$$\underline{u}_0 = e^{j\phi} [\cos \bar{\alpha} \quad \sin \bar{\alpha} \cos \bar{\beta} e^{j\bar{\delta}} \quad \sin \bar{\alpha} \sin \bar{\beta} e^{j\bar{\gamma}}]^T \quad (38-2)$$


$$\underline{k}_0 = \sqrt{\bar{\lambda}} \underline{u}_0 = \sqrt{\bar{\lambda}} e^{j\phi} [\cos \bar{\alpha} \quad \sin \bar{\alpha} \cos \bar{\beta} e^{j\bar{\delta}} \quad \sin \bar{\alpha} \sin \bar{\beta} e^{j\bar{\gamma}}]^T$$

بنابراین میانگین هدف بازسازی شده با پنج پارامتر مستقل $\bar{\alpha}$ ، $\bar{\beta}$ ، $\bar{\delta}$ ، $\bar{\gamma}$ و $\bar{\lambda}$ توصیف می‌شود. از آنجا که این هدف پنج درجه آزادی دارد، یک هدف منفرد در نظر گرفته می‌شود.

همبستگی بین $\bar{\beta}$ (به عنوان پارامتر توجیه هدف) و پارامترهای پلاریمتریک مختلف توسط Mansouri و همکاران (2010) بررسی شده است. نتایج تحقیق آن‌ها نشان داد که نسبت پلاریزاسیون HV به VV بالاترین همبستگی را با $\bar{\beta}$ دارد، اما نسبت پلاریزاسیون RL به RR کمترین همبستگی را با $\bar{\beta}$ دارد و می‌تواند به عنوان پارامتری مستقل از توجیه هدف در نظر گرفته شود.

سه پارامتر $\bar{\beta}$ ، $\bar{\delta}$ و $\bar{\gamma}$ از نظر دورانی متغیر هستند و برای تعریف زاویه جهت پلاریزاسیون هدف استفاده شده‌اند. زاویه $\bar{\alpha}$ از لحاظ دوران تغییرناپذیر است، به این معنی که از زاویه توجیه هدف قابل جداسازی است. در نتیجه می‌توان مکانیزم‌های پراکندگی را به صورت مستقل از توجیه فیزیکی آن‌ها در فضا تعریف کرد (Lee et al., 2000). بنابراین پارامتر اصلی برای تشخیص مکانیزم پراکندگی غالب $\bar{\alpha}$ می‌باشد.

زاویه آلفا نوع فرآیند پراکندگی اتفاق افتاده را بیان می‌کند و به عنوان یک درجه آزادی داخلی از هدف ظاهر می‌شود لذا از آن برای توصیف نوع مکانیزم پراکندگی استفاده می‌شود. آلفا زاویه‌ای پیوسته در محدوده $0^\circ \leq \bar{\alpha} \leq 90^\circ$ می‌باشد و برای نمایش تغییرات وسیع از پراکنده‌گرهای مختلف استفاده می‌شود که در شکل ۳-۲ نشان داده شده است (Lee and Pottier, 2009).



شکل ۲-۳. تفسیر زاویه آلفا (Hellmann, 2001)

$\bar{\alpha} = 0^\circ$ مربوط به سطح ایزوتروپیک و مناطقی با تک انعکاس است مانند زمین‌های بدون پوشش گیاهی، اما با افزایش $\bar{\alpha}$ سطح از حالت ایزوتروپیک خارج می‌شود ($S_{hh} \neq S_{vv}$). در $\bar{\alpha} = 45^\circ$ برابر با یک دوقطبی^۱ است مانند جنگل‌ها و اگر $\bar{\alpha} > 45^\circ$ باشد یک دوسطحی ناهمسانگرد بدست می‌آید که $S_{hh} \neq S_{vv}$ و اختلاف فاز برابر 180° درجه می‌شود. معمولاً جایی که $\bar{\alpha} = 90^\circ$ است مناطق شهری و عوارض ساخت دست بشر را نشان می‌دهد. به طور کلی در مناطق شهری و پارک‌ها مقادیر متوسط و زیاد این پارامتر ارائه شده است ($45^\circ \leq \bar{\alpha} \leq 90^\circ$)، و در اقیانوس‌ها مقدار کم $\bar{\alpha}$ رخ می‌دهد که نشان‌دهنده پراکنش غالب سطحی می‌باشد (Lee and Pottier, 2009).

• ترکیب انتروپی و ناهمسانگردی

به منظور افزایش توانایی تشخیص انواع مختلف فرآیندهای پراکندگی، استفاده از ترکیب اطلاعات انتروپی (H) و ناهمسانگردی (A) پیشنهاد شده است (Lee and Pottier, 2009). $(1-H)(1-A)$ مربوط به حضور یک فرآیند پراکندگی غالب، $H(1-A)$ توصیف کننده یک فرآیند پراکندگی تصادفی، HA مرتبط با حضور دو مکانیزم پراکندگی با احتمال مشابه و $(1-H)A$ مربوط به حضور دو مکانیزم پراکندگی یکی با احتمال زیاد و دیگری با احتمال متوسط می‌باشد.

• SERD و DERD

پارامترهای SERD و DERD توسط Allain و همکاران (Allain et al., 2004) بیان شدند که از

^۱ dipole

ماتریس همبستگی با فرض تقارن انعکاسی^۱ حاصل می‌شوند (Lee and Pottier, 2009). نحوه محاسبه این دو کمیت در پیوست (الف) آورده شده است.

اختلاف نسبی مقادیر ویژه تک انعکاسی^۲ (SERD) و اختلاف نسبی مقادیر ویژه دو انعکاسی^۳ (DERD) به مشخصات محیط طبیعی حساس هستند و برای تبدیل کمی پارامترهای زیستی و ژئوفیزیکی استفاده می‌شوند. SERD پارامتری مهم برای محیط با انتروپی زیاد، به منظور تعیین ماهیت و اهمیت مکانیزم‌های پراکندگی مختلف می‌باشد. این پارامتر به زبری سطح بسیار حساس است.

Hajnsek و همکاران (2003) مقایسه‌ای بین پارامتر DERD و ناهمسانگردی (A) که معمولاً به عنوان توصیف‌گری از زبری سطح بکار می‌رود، انجام دادند. آن‌ها نشان دادند که پارامتر DERD برای زبری کم مشابه با پارامتر A می‌باشد، اما در فرکانس‌های بالا رفتار متفاوتی ارائه می‌دهد. این پارامترها به نسبت زبری سطح به فرکانس ($k\sigma$) بسیار حساس هستند، درحالی‌که وابستگی آن‌ها به ثابت دی الکتریک کمتر قابل توجه است. همچنین نشان داده شد که یک مقدار A متناظر با دو مقدار مختلف $k\sigma$ است، در نتیجه پارامتر ناهمسانگردی در استخراج زبری سطح با ابهام مواجه می‌شود، درحالی‌که DERD این گونه نیست. تفاوت دیگر این دو آن است که محدوده دینامیکی DERD (بین -۱ و ۱) بزرگتر از A (بین ۰ و ۱) است. بنابراین پارامتر DERD در مقایسه با A توصیف‌گر بهتری از زبری سطح می‌باشد.

• عدم تقارن پلاریزاسیون^۴

این پارامتر توسط Ainsworth و همکاران (2002) معرفی شد. همان‌طور که قبلاً بیان شد، مقادیر ویژه ماتریس همبستگی اطلاعاتی راجع به مکانیزم‌های پراکندگی مختلف ارائه می‌کنند و تصویر حاصل از مجموع سه مقدار ویژه، تمام اطلاعات مربوط به توان کل را دارد، اما هیچ‌گونه اطلاعاتی را در مورد میزان توان توزیع شده در بین کانال‌های مختلف پلاریمتریک نمی‌دهد.

¹ reflection symmetry

² single-bounce eigenvalues relative difference

³ double-bounce eigenvalues relative difference

⁴ polarization asymmetry

با توجه به تئوری تجزیه Holm، با جداسازی ماتریس همبستگی T_3 به ترم‌های قطبیده و ناقطبیده داریم:

$$T_3 = U_3 \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_3 \end{bmatrix} U_3^{-1} \quad (39-2)$$

$$= U_3 \begin{bmatrix} \lambda_1 - \lambda_3 & 0 & 0 \\ 0 & \lambda_2 - \lambda_3 & 0 \\ 0 & 0 & 0 \end{bmatrix} U_3^{-1} + U_3 \begin{bmatrix} \lambda_3 & 0 & 0 \\ 0 & \lambda_3 & 0 \\ 0 & 0 & \lambda_3 \end{bmatrix} U_3^{-1}$$

ترم اول در رابطه (۳۹-۲) حداکثر دو مقدار ویژه غیر صفر دارد، بنابراین بیش از دو مکانیزم پراکندگی مجزا ندارد. مقدار ویژه سوم مربوط به بازگشت ناقطبیده است و نیازی به وارد کردن آن در آنالیز پلاریمتریک نمی‌باشد. عدم تقارن پلاریزاسیون (PA)، معادل با ناهمسانگردی پلاریمتریک (A)، به صورت نسبت اختلاف و مجموع دو مقدار ویژه بازگشت قطبیده با رابطه (۴۰-۲) تعریف می‌شود.

$$PA = \frac{(\lambda_1 - \lambda_3) - (\lambda_2 - \lambda_3)}{(\lambda_1 - \lambda_3) + (\lambda_2 - \lambda_3)} = \frac{\lambda_1 - \lambda_2}{\lambda_1 + \lambda_2 - 2\lambda_3} = \frac{\lambda_1 - \lambda_2}{Span - 3\lambda_3} \quad 0 \leq PA \leq 1 \quad (40-2)$$

PA قدرت نسبی دو مکانیزم پراکندگی را اندازه‌گیری می‌کند (Lee and Pottier, 2009).

• شاخص گیاهی رادار^۱ و ارتفاع پایه^۲

شاخص گیاهی رادار (RVI) توسط Van Zyl و همکاران (1987) براساس آنالیز مقادیر ویژه، به عنوان برآوردی از زیست‌توده^۳ از داده PolSAR، معرفی شد. این شاخص برای آنالیز پراکندگی مناطق گیاهی استفاده شده است. روش دیگری برای اندازه‌گیری درجه تصادفی در پراکندگی استفاده از ارتفاع پایه (PH) در امضای پلاریزاسیون^۴ است که از اندازه‌گیری نسبت حداقل مقدار ویژه به حداکثر آن بدست می‌آید (Durden et al., 1990). این دو پارامتر از روابط زیر محاسبه می‌شوند.

$$RVI = \frac{4\lambda_3}{\lambda_1 + \lambda_2 + \lambda_3} \quad (41-2)$$

¹ Radar Vegetation Index

² Pedestal Height

³ biomass

⁴ polarization signature

$$PH = \frac{\min(\lambda_1, \lambda_2, \lambda_3)}{\max(\lambda_1, \lambda_2, \lambda_3)} = \frac{\lambda_3}{\lambda_1}, \lambda_3 \leq \lambda_2 \leq \lambda_1 \quad 0 \leq PH \leq 1 \quad (۴۲-۲)$$

- پارامتر تصادفی هدف^۱

پارامتر تصادفی هدف (A_luen) توسط Luneburg (2001) ارائه شد و با رابطه (۴۳-۲) بیان می‌شود.

$$A_{luen} = \sqrt{\frac{3}{2} \sqrt{\frac{\lambda_2^2 + \lambda_3^2}{\lambda_1^2 + \lambda_2^2 + \lambda_3^2}}} \quad 0 \leq P_R \leq 1 \quad (۴۳-۲)$$

این پارامتر برای یک هدف قطعی^۲ با $\lambda_2 \approx \lambda_3 \approx 0$ و برای یک هدف کاملاً تصادفی با $\lambda_1 \approx \lambda_2 \approx \lambda_3 \approx 0$ می‌باشد. A_luen به انتروپی بسیار نزدیک است و اطلاعات مشابهی را فراهم می‌کند (Lee and Pottier, 2009).

- انتروپی شانون^۳

انتروپی شانون (SE) توسط Morio و همکاران (2007) به صورت مجموعی از SE_I و SE_P ارائه شد، SE_I مربوط به شدت است که وابسته به توان کل می‌باشد و SE_P وابسته به درجه پلاریزاسیون Barakat (P_T) است. انتروپی شانون راهی برای اندازه‌گیری بی‌نظمی آماری منطقه هدف رادار است (Refregier and Morio, 2006) و در ادامه نحوه محاسبه آن آمده است.

$$SE = \log(\pi^3 e^3 |T_3|) = SE_I + SE_P$$

$$P_T = \sqrt{1 - 27 \frac{|T_3|}{Tr(T_3)^3}} \quad (۴۴-۲)$$

$$SE_I = 3 \log\left(\frac{\pi e Tr(T_3)}{3}\right)$$

$$SE_P = \log(1 - P_T^2) = \log\left(27 \frac{|T_3|}{Tr(T_3)^3}\right)$$

¹ target randomness parameter

² deterministic

³ Shannon Entropy

تجزیه Van Zyl

Van Zyl (1989) با مدل کردن پاسخ پلاریمتریکی عارضه‌های مختلف، الگوریتمی براساس مکانیزم‌های پراکنشی پایه شامل پراکنش زوج، پراکنش فرد و پراکنش پراکنده^۱ یا حجمی با استفاده از ماتریس مولر ارائه کرد. ماتریس مولر را در حالت کلی می‌توان به صورت زیر بیان کرد:

$$[F] = \begin{bmatrix} A + B_0 & B & 0 & 0 \\ B & A - B_0 & 0 & 0 \\ 0 & 0 & C + B_0 & D \\ 0 & 0 & -D & C - B_0 \end{bmatrix} \quad (۴۵-۲)$$

که در آن

$$A = \frac{1}{2} \langle |S_{hh}|^2 + |S_{vv}|^2 \rangle$$

$$B = \frac{1}{2} \langle |S_{hh}|^2 - |S_{vv}|^2 \rangle \quad (۴۶-۲)$$


$$B_0 = \langle |S_{hv}|^2 \rangle$$

$$C = \langle \Re(S_{hh}^* S_{vv}) \rangle$$

$$D = \langle \Im(S_{hh}^* S_{vv}) \rangle$$

که \Re و \Im نشان‌دهنده قسمت‌های حقیقی و موهومی،^{*} نشانگر مزدوج مختلط و $\langle \rangle$ مجموع متوسط است. از لحاظ تئوری در کلاس پراکنش فرد، زاویه فاز $\langle (S_{hh}^* S_{vv}) \rangle$ در حالت کلی نزدیک به صفر است و مقدار C مثبت می‌باشد. در کلاس پراکنش زوج، این زاویه نزدیک ۱۸۰ درجه و C منفی است. در کلاس پراکنش پراکنده، بازگشت‌های co-pol تقریباً ناهمبسته هستند، بنابراین مقدار مورد انتظار C نزدیک به صفر خواهد بود. لازم به ذکر است این پراکنش در مناطقی اتفاق می‌افتد که چندین پراکنش حضور داشته باشند مانند جنگل و سطوح بسیار زبر (Van Zyl, 1989).

^۱ diffuse



شکل ۲-۴. مکانیزم پراکنش زوج (تصویر راست)، پراکنش پراکنده (تصویر وسط)، پراکنش فرد (تصویر چپ) (Van Zyl, 1989)

در سال ۱۹۹۲ این الگوریتم با استفاده از توصیفی کلی از ماتریس کواریانس C_3 برای زمین طبیعی متقارن در حالت مونواستاتیک معرفی شد (Van Zyl, 1992). فرض تقارن انعکاسی که در یک محیط طبیعی، مانند خاک و جنگل، برقرار باشد همبستگی بین کانال‌های co-pol و cross-pol صفر در نظر گرفته می‌شود (Nghiem et al., 1992). در رابطه (۲-۴۷) ماتریس کواریانس متوسط مربوطه ارائه شده است.

$$C_3 = \begin{bmatrix} \langle |S_{HH}|^2 \rangle & 0 & \langle S_{HH}S_{VV}^* \rangle \\ 0 & \langle 2|S_{HV}|^2 \rangle & 0 \\ \langle S_{VV}S_{HH}^* \rangle & 0 & \langle |S_{VV}|^2 \rangle \end{bmatrix} = \alpha \begin{bmatrix} 1 & 0 & \rho \\ 0 & \eta & 0 \\ \rho^* & 0 & \mu \end{bmatrix} \quad (۲-۴۷)$$

$$\alpha = \langle S_{HH}S_{HH}^* \rangle \quad \rho = \langle S_{HH}S_{VV}^* \rangle / \langle S_{HH}S_{HH}^* \rangle$$

$$\eta = 2\langle S_{HV}S_{HV}^* \rangle / \langle S_{HH}S_{HH}^* \rangle \quad \mu = \langle S_{VV}S_{VV}^* \rangle / \langle S_{HH}S_{HH}^* \rangle$$

پارامترهای α ، ρ ، η و μ به اندازه، شکل، ویژگی‌های الکتریکی و توزیع زاویه‌ای آماری پراکنده‌سازها وابسته است. ماتریس کواریانس را در این الگوریتم می‌توان با رابطه (۲-۴۸) نیز نمایش داد (Van Zyl, 1992).

$$C_3 = \sum_{i=1}^3 \lambda_i \underline{u}_i \underline{u}_i^{*T} = \Lambda_1 \begin{bmatrix} |\alpha|^2 & 0 & \alpha \\ 0 & 0 & 0 \\ \alpha^* & 0 & 1 \end{bmatrix} + \Lambda_2 \begin{bmatrix} |\beta|^2 & 0 & \beta \\ 0 & 0 & 0 \\ \beta^* & 0 & 1 \end{bmatrix} + \Lambda_3 \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} \quad (۲-۴۸)$$

که در آن

$$\Delta = (1 - \mu)^2 + 4|\rho|^2, \quad \alpha = \frac{2\rho}{\mu - 1 + \sqrt{\Delta}}, \quad \beta = \frac{2\rho}{\mu - 1 - \sqrt{\Delta}} \quad (۲-۴۹)$$

$$\Lambda_1 = \lambda_1 \left[\frac{(\mu - 1 + \sqrt{\Delta})^2}{(\mu - 1 + \sqrt{\Delta})^2 + 4|\rho|^2} \right], \quad \Lambda_2 = \lambda_2 \left[\frac{(\mu - 1 + \sqrt{\Delta})^2}{(\mu - 1 + \sqrt{\Delta})^2 + 4|\rho|^2} \right], \quad \Lambda_3 = \lambda_3$$

در تجزیه Van Zyl دو بردار ویژه اول نماینده تعداد بازتاب‌های فرد و زوج می‌باشد. رابطه (۲-۴۸)

که از آنالیز مقادیر ویژه ماتریس کواریانس بدست می‌آید نقطه شروع تئوری‌های تجزیه مدل مبنا می‌باشد (Lee and Pottier, 2009).

پارامترهای حاصل از الگوریتم‌های تجزیه مدل مبنا

تجزیه سه مولفه‌ای Freeman- Durden

Freeman و همکاران (1998) روشی بر مبنای فیزیک پراکنش رادار ارائه کرده‌اند که کمتر محدود به صرفاً مدل‌های ریاضی است. این روش برای تعیین مکانیزم پراکندگی غالب در داده پلاریمتریک SAR می‌تواند استفاده شود. پارامترهای این تجزیه به عنوان توان پراکنده شده بوسیله سه مکانیزم فیزیکی سطحی، دو انعکاسی و حجمی توصیف می‌شود. بر اساس این مدل، توان کل به صورت زیر بیان می‌شود.

(۵۰-۲)

$$Span = |S_{hh}|^2 + |S_{vv}|^2 + 2|S_{hv}|^2 = P_s + P_d + P_v$$

این سه مولفه با استفاده از المان‌های ماتریس کواریانس محاسبه می‌شوند. در این فرآیند، ابتدا مجموعه‌ای از پارامترهای واسطه یعنی f_s ، f_d ، f_v و α و β از روابط زیر معرفی می‌شوند.

$$P_s = f_s(1 + |\beta|^2)$$

$$P_d = f_d(1 + |\alpha|^2) \quad (۵۱-۲)$$

$$P_v = \frac{8}{3}f_v$$

سپس این پارامترها به المان‌های ماتریس کواریانس ارتباط داده می‌شود.

$$\langle |S_{HH}|^2 \rangle = f_s|\beta|^2 + f_d|\alpha|^2 + f_v$$

$$\langle |S_{VV}|^2 \rangle = f_s + f_d + f_v$$

$$\langle S_{HH}S_{VV}^* \rangle = f_s\beta + f_d\alpha + \frac{f_v}{3} \quad (۵۲-۲)$$

$$\langle |S_{HV}|^2 \rangle = \frac{f_v}{3}$$

لازم به ذکر است که به علت فرض تقارن انعکاسی یعنی $\langle S_{HH}S_{HV}^* \rangle = \langle S_{HV}S_{VV}^* \rangle = 0$ سایر عناصر ماتریس کواریانس حذف شده‌اند. ۴ معادله با ۵ مجهول وجود دارد که یکی از مجهولات می‌تواند ثابت باشد. با استفاده از روش Van Zyl (1989) بر اساس علامت بخش حقیقی $\langle S_{HH}S_{VV}^* \rangle$

پراکنش سطحی یا دو انعکاسی به عنوان پراکنش غالب در نظر گرفته می‌شود. اگر $Re\{S_{HH}S_{VV}^*\} \geq 0$ ، پراکنش سطحی غالب است و α ثابت و برابر با ۱- می‌باشد. اگر $Re\{S_{HH}S_{VV}^*\} \leq 0$ ، پراکنش دو انعکاسی غالب است و β ثابت و برابر با ۱+ می‌باشد.

با وجود توانایی این تجزیه در ارائه ویژگی‌های مناسب برای تفکیک بین انواع مختلف پوشش‌های زمینی دو فرض محدودکننده در این روش وجود دارد؛ اول فرض تقارن انعکاسی و دوم آنکه مدل پراکندگی سه‌مولفه‌ای همواره قابل اجرا نیست و محدود به برخی کاربردهایی است که در ارتباط با پراکنش از سطح زمین و جنگل می‌باشند. برای مثال اگر پراکنش سطحی با انتروپی غیرصفر در نظر گرفته شود، این روش نامعتبر است (Cloude and Pottier, 1996).

به طور کلی جنگل‌ها پراکنش حجمی قوی دارند. اگرچه به علت ساختار پوشش گیاهی متفاوت همچنین شکل مختلف برگ‌ها، پراکنش حجمی در میان درختان گوناگون متفاوت است. این موجب می‌شود که پراکنش پوشش گیاهی به عنوان پارامتری مفید برای تهیه نقشه جنگل استفاده شود (Maghsoudi, 2012).

تجزیه چهار مولفه‌ای Yamaguchi

Yamaguchi و همکاران (2005) بر اساس مدل پراکندگی سه مولفه‌ای Freeman، مدلی چهار مولفه‌ای با معرفی یک ترم اضافی برای حالت‌های انعکاس غیر متقارن یعنی $\langle S_{HV}S_{VV}^* \rangle \neq 0$ و $\langle S_{HH}S_{HV}^* \rangle \neq 0$ پیشنهاد کردند. در این روش که به منظور رویارویی با ساختارهای پیچیده هندسی در پراکنش ارائه شده است، مولفه چهارم معادل با توان پراکنش helix می‌باشد. این ترم غالباً در مناطق ناهمگن (سازه‌های ساخت بشر در مناطق شهری پیچیده) ظاهر می‌شود در حالی که تقریباً در هیچ‌یک از پراکنش‌های غیرمنفرد طبیعی وجود ندارد. مفهوم این مکانیزم برای اولین بار توسط تئوری تجزیه هدف همدوس Krogager ارائه شده است (Krogager and Freeman, 1994). یک هدف helix پلاریزاسیون دایره‌ای دست چپی یا راستی برای تمام پلاریزاسیون‌های خطی فرودی تولید می‌کند. ماتریس‌های پراکندگی و کواریانس مربوطه در رابطه (۵۳-۲) آمده است.

$$S_{LH} = \frac{1}{2} \begin{bmatrix} 1 & j \\ j & -1 \end{bmatrix}, S_{RH} = \frac{1}{2} \begin{bmatrix} 1 & -j \\ -j & -1 \end{bmatrix} \quad (53-2)$$

$$C_{3LH} = \frac{f_C}{4} \begin{bmatrix} 1 & -j\sqrt{2} & -1 \\ j\sqrt{2} & 2 & -j\sqrt{2} \\ -1 & j\sqrt{2} & 1 \end{bmatrix}, C_{3RH} = \frac{f_C}{4} \begin{bmatrix} 1 & j\sqrt{2} & -1 \\ -j\sqrt{2} & 2 & j\sqrt{2} \\ -1 & -j\sqrt{2} & 1 \end{bmatrix}$$

f_C مربوط به مولفه پراکندگی helix است. در این تجزیه با فرض اینکه مولفه‌های پراکنش حجمی،

دو انعکاسی، سطحی و helix ناهمبسته هستند، مدل کلی به صورت زیر ارائه می‌شود.

$$C_3 = C_{3S} + C_{3D} + C_{3LH/RH} + \langle C_{3V} \rangle_\theta$$

$$= \begin{bmatrix} f_S|\beta|^2 + f_D|\alpha|^2 + \frac{f_C}{4} & \pm j \frac{\sqrt{2}f_C}{4} & f_S\beta + f_D\alpha - \frac{f_C}{4} \\ \mp j \frac{\sqrt{2}f_C}{4} & \frac{f_C}{2} & \pm j \frac{\sqrt{2}f_C}{4} \\ f_S\beta^* + f_D\alpha^* - \frac{f_C}{4} & \mp j \frac{\sqrt{2}f_C}{4} & f_S + f_D + \frac{f_C}{4} \end{bmatrix} + f_V \begin{bmatrix} a & 0 & d \\ 0 & b & 0 \\ d & 0 & c \end{bmatrix} \quad (۵۴-۲)$$

این مدل ۵ معادله و ۶ مجهول $\alpha, \beta, f_S, f_D, f_C, f_V$ دارد و پارامترهای a, b, c و d ثابت می‌باشند.

سهم هر مکانیزم پراکندگی در Span با معادله (۵۵-۲) تخمین زده می‌شود.

$$Span = |S_{hh}|^2 + |S_{vv}|^2 + 2|S_{hv}|^2 = P_S + P_D + P_C + P_V \quad (۵۵-۲)$$

$$P_S = f_S(1 + |\beta|^2), \quad P_D = f_D(1 + |\alpha|^2), \quad P_C = f_C, \quad P_V = f_V$$

تجزیه Touzi

در مقایسه با تجزیه $H/A/\alpha$ ، که زاویه α را برای توصیف نوع پراکندگی هدف استفاده می‌کند،

تجزیه Touzi نوع پراکنش را با پارامترهای شدت α_s و فاز ϕ_s پراکنش متقارن، مارپیچی بودن^۱ هدف

(τ_s)، و زاویه توجیه (ψ_s) مشخص می‌کند (Touzi, 2007). Touzi و همکاران (2009) نشان دادند

که استفاده از پارامترهای α_s و τ_s می‌تواند منجر به طبقه‌بندی مناسبی از تالاب^۲ شود. همچنین

کارایی این پارامترها برای تهیه نقشه جنگل بررسی شده است (Maghsoudi, 2012).

^۱ helicity

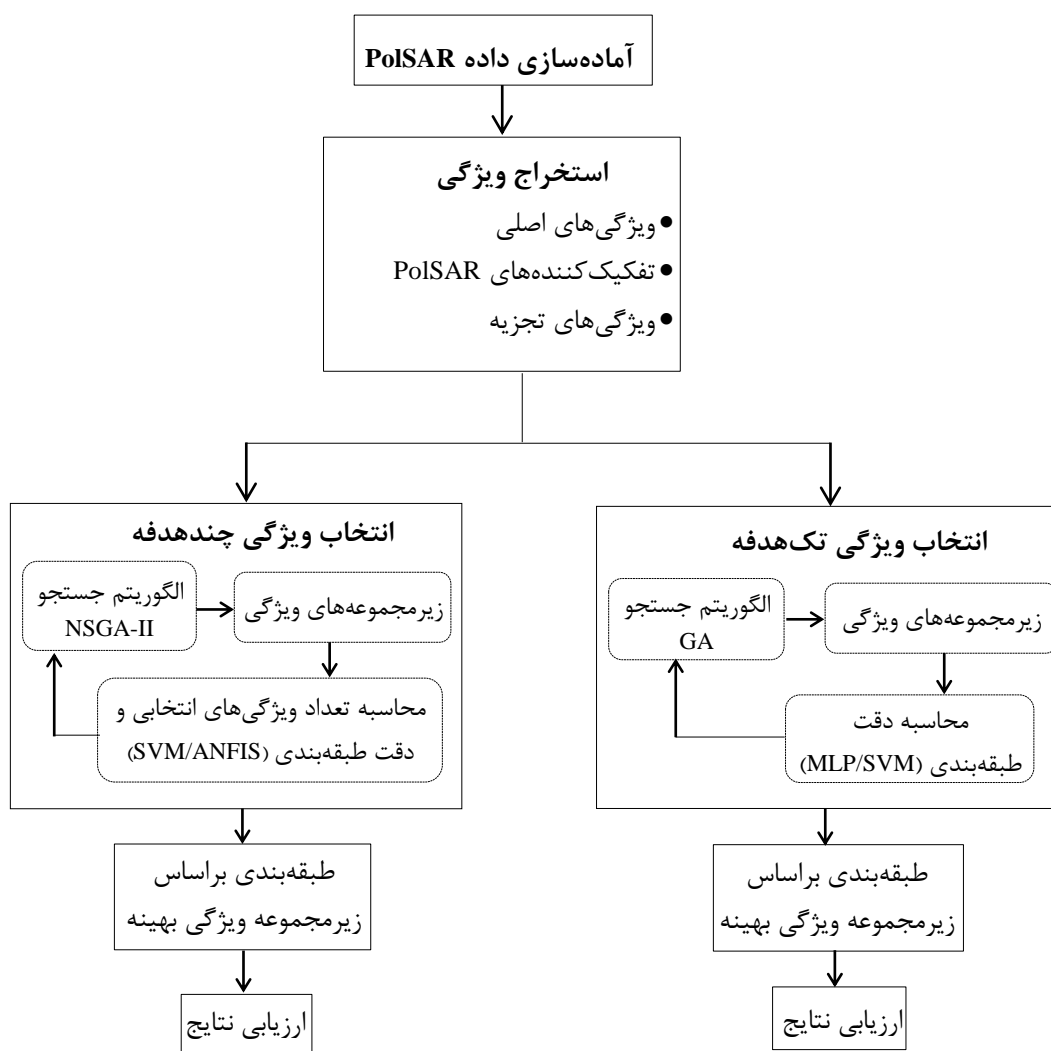
^۲ wetland

فصل سوم: روش‌های پیشنهادی در تعیین ویژگی‌های بهینه PolSAR

۱-۳ مقدمه

طرح کلی روش‌های پیشنهاد شده در این تحقیق، به منظور تعیین ویژگی‌های بهینه تصاویر پلاریمتری در طبقه‌بندی پوشش زمینی، در شکل ۱-۳ نشان داده شده است. مراحل آماده‌سازی داده پلاریمتری در فصل چهارم شرح داده خواهد شد. بعد از استخراج ویژگی‌های PolSAR در قالب سه گروه ویژگی‌های اصلی، تفکیک‌کننده‌های PolSAR و ویژگی‌های تجزیه که شرح آن در فصل دوم ارائه شد، انتخاب بهترین ویژگی‌های پلاریمتری را در قالب روش‌های بهینه‌سازی تک‌هدفه و چندهدفه خواهیم داشت که در این فصل مورد بررسی قرار می‌گیرد. در روش‌های تک‌هدفه GAMLP و GASVM (بخش ۲-۳)، الگوریتم ژنتیک به عنوان ابزار جستجو، و به ترتیب دقت طبقه‌بندی با طبقه‌بندی‌کننده‌های MLP و SVM به عنوان تابع هدف در نظر گرفته می‌شود. در روش‌های چندهدفه MOGA-SVM و MOGA-ANFIS (بخش ۳-۳)، در مرحله جستجو از الگوریتم ژنتیک با مرتب‌سازی نامغلوب^۱ (NSGA-II) و در مرحله ارزیابی از تعداد ویژگی‌های انتخابی و دقت کلی طبقه‌بندی با SVM و یا ANFIS به عنوان توابع هدف استفاده می‌شود. در این فصل تئوری روش‌های پیشنهادی مورد بررسی قرار خواهد گرفت.

^۱ Non-Dominated Sorting Genetic Algorithm-II

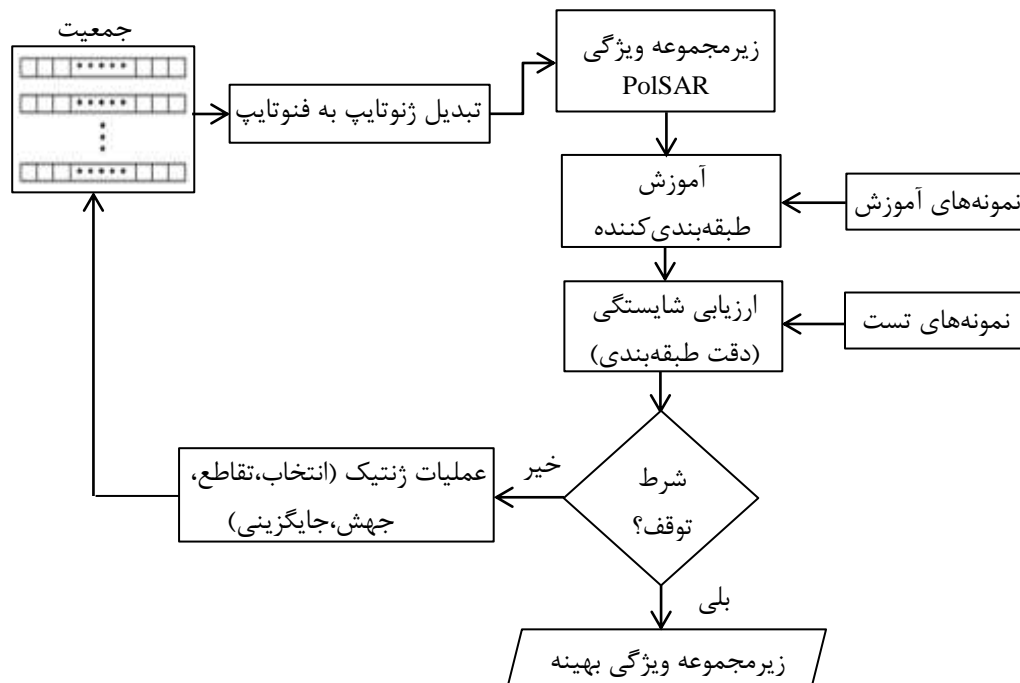


شکل ۳-۱. طرح کلی روش پیشنهاد شده در این تحقیق به منظور بهبود طبقه‌بندی پوشش زمین تصاویر PolSAR

۳-۲ انتخاب ویژگی تک‌هدفه

در روش تک‌هدفه که فلوچارت آن در شکل ۳-۲ نشان داده شده است، براساس الگوریتم ترکیبی و تکراری از GA و دو طبقه‌بندی‌کننده MLP و یا SVM انتخاب ویژگی‌های پلاریمتری انجام می‌شود. GA به عنوان ابزار جستجو در فضای زیرمجموعه‌های ویژگی و دقت طبقه‌بندی به عنوان تابع ارزیابی زیرمجموعه ویژگی‌ها بکار گرفته می‌شود. به این ترتیب که در هر بار تکرار الگوریتم طبقه‌بندی‌کننده با استفاده از داده آموزشی و ویژگی‌های انتخابی آموزش می‌بیند. براساس تابع شایستگی که در این تحقیق دقت طبقه‌بندی داده تست در نظر گرفته شده است، عملیات انتخاب

ویژگی با الگوریتم ژنتیک ادامه یافته تا زمانی که معیار خاتمه الگوریتم فراهم شود. در این مرحله زیرمجموعه ویژگی بهینه به منظور طبقه‌بندی نهایی حاصل می‌گردد.



شکل ۳-۲. فلوچارت الگوریتم انتخاب ویژگی تک‌هدفه

۳-۲-۱ روش جستجو: الگوریتم ژنتیک (GA)

الگوریتم ژنتیک (GA) که توسط Holland در سال ۱۹۷۵ میلادی ابداع شد، یک روش جستجوی تصادفی براساس اصول تکاملی طبیعی می‌باشد. از جمله مزایای الگوریتم ژنتیک آن است که به اطلاعات زیادی درباره تابع برای بهینه‌سازی نیاز ندارد و قابل اجرا حتی در فضای جستجوی بسیار بزرگ می‌باشد (Atkinson and Tatnall, 1997). در GA ابتدا مجموعه‌ای از راه‌حل‌های اولیه (جمعیت) به طور تصادفی از میان فضای راه‌حل‌ها انتخاب می‌گردد. هر عضو از جمعیت کروموزوم نامیده می‌شود و هر کروموزوم نیز از تعدادی ژن که معادل متغیرهای یک راه حل می‌باشد تشکیل شده است. در این مطالعه هر ژن معادل با یکی از ویژگی‌های استخراج شده از تصویر پلاریمتری می‌باشد و دارای دو مقدار صفر و یک است که یک به معنی انتخاب شدن ویژگی مربوطه می‌باشد. پس از بدست آوردن مقدار شایستگی هر یک از کروموزوم‌ها با استفاده از تابع هدف مورد نظر، عملیات

انتخاب، تقاطع^۱ و جهش^۲ در هر نسل روی کروموزوم‌ها عمل می‌کنند و جمعیت جدید را از جمعیت فعلی بوجود می‌آورند. عمل انتخاب مشخص می‌کند که کدامیک از اعضای نسل حاضر می‌توانند به عنوان والد^۳ در تولید نسل آینده شرکت کنند. این عمل طبق اصل بقای اصلح صورت می‌گیرد که برطبق آن عضو شایسته‌تر احتمال بقای بیشتری دارد. معمولاً انتخاب اعضا برای تولید نسل بعد با احتمالی متناسب با میزان شایستگی آن‌ها صورت می‌گیرد.

پس از انتخاب کروموزوم‌های والد، با امید به تولید نسلی بهتر از نسل فعلی، عملگرهای تقاطع و جهش بر روی آن‌ها اعمال می‌شود. از جمله مهم‌ترین روش‌های تقاطع می‌توان به تقاطع تک نقطه‌ای^۴، چند نقطه‌ای و یکنواخت^۵ (ماسک) اشاره کرد. در روش تک نقطه‌ای پس از انتخاب کروموزوم‌های والد، دو کروموزوم از محلی که به طور تصادفی انتخاب می‌شود، دو قطعه می‌شوند و قطعات جدا شده هر یک با دیگری ترکیب شده تا کروموزوم‌های فرزند تولید شوند. به همین ترتیب می‌توانیم عملگر تقاطع چند نقطه‌ای را تعریف کنیم. روش ماسک به دلیل پخش کامل ژن‌ها در نسل جدید معمولاً عملکرد بهتری دارد. در این روش ماسکی با اندازه کروموزوم انتخاب و مقادیر هر المان آن به صورت تصادفی با صفر و یک پر می‌گردد، سپس نسل جدید با استفاده از روابط (۱-۳) و (۲-۳) بدست می‌آید.

$$offspring1 = M \times P1 + (1 - M) \times P2 \quad (1-3)$$

$$offspring2 = M \times P2 + (1 - M) \times P1 \quad (2-3)$$

در این روابط M ماسک و $P1$ و $P2$ دو کروموزوم انتخاب شده برای عمل تقاطع هستند.

اگر اطلاعات کد شده مورد نیاز برای حل یک مسئله مشخص درون جمعیت وجود نداشته باشد، با استفاده از عملگر تقاطع به هر میزان ژن‌ها با همدیگر ترکیب شوند، به پاسخ رضایت بخشی نخواهیم رسید. عملگر جهش ضمن تولید خود بخودی کروموزوم‌های جدید با تغییر مقدار برخی از ژن‌ها، باعث

¹ crossover

² mutation

³ parent

⁴ single-point crossover

⁵ uniform

جلوگیری از همگرا شدن و متوقف شدن الگوریتم در اکستریم‌های محلی می‌شود. لازم به ذکر است که عمل تقاطع و جهش با در نظر گرفتن یک عدد احتمال که به آن نسبت تقاطع و نسبت جهش گفته می‌شود، صورت می‌گیرد. معمولاً نسبت جهش در سطح پایینی نگاه داشته می‌شود تا کروموزوم‌های خوب بدست آمده از عمل تقاطع، از بین نروند. فرآیند انتخاب، تقاطع و جهش ادامه یافته تا زمانی که معیار خاتمه الگوریتم ژنتیک فراهم شود.


۳-۲-۲ تابع هدف

در GA شایستگی و عملکرد هر عضو جمعیت در حل مسئله توسط تابع هدف ارزیابی می‌شود. در روش‌های بهینه‌سازی تک‌هدفه، دقت کلی طبقه‌بندی با شبکه‌های عصبی پرسپترون چند لایه و ماشین‌های بردار پشتیبان به عنوان تابع هدف در نظر گرفته شده است.

۳-۲-۲-۱ شبکه‌های عصبی مصنوعی

شبکه‌های عصبی مصنوعی از پتانسیل بالایی جهت ایجاد نگاشتی غیرخطی از ورودی‌ها به خروجی‌ها برخوردار هستند. از این رو، تاکنون در بسیاری از شاخه‌های علوم و مهندسی به کار گرفته شده‌اند. شبکه پرسپترون چند لایه (MLP) از متداول‌ترین و پرکاربردترین انواع شبکه عصبی است که از اتصال بین واحدهای پردازشی با نام نرون (گره) تشکیل شده است. مهم‌ترین وظیفه منتسب به یک نرون، دریافت اطلاعات از نرون‌های همسایه به عنوان ورودی، انتساب پارامتر وزن به هر یک از ورودی‌ها، تاثیر بر ورودی‌های موجود توسط تابع عملکرد داخلی نرون جهت محاسبه پاسخ نرون به داده‌های ورودی و نهایتاً ارسال پاسخ محاسبه شده به سایر نرون‌های شبکه به عنوان ورودی جدید می‌باشد (Frohlich *et al.*, 2003). شبکه MLP حداقل شامل سه لایه ورودی، میانی (پنهان) و خروجی می‌باشد. روش قانونمندی برای تعیین تعداد لایه‌ها و نرون‌های هر لایه وجود ندارد و فاکتورهای زیادی در این زمینه تاثیرگذار هستند. از جمله این فاکتورها می‌توان به پیچیدگی مسئله طبقه‌بندی، تعداد ورودی‌ها و خروجی‌ها، نوع روش آموزش، تابع فعالسازی مورد استفاده، و همچنین سطح نویز موجود در داده‌های آموزشی اشاره کرد. همان‌طور که در شکل ۳-۳ نشان داده شده است، در لایه ورودی نرون‌های ۱ تا n مربوط به n ویژگی ورودی (ویژگی‌های انتخابی) می‌باشند. لایه

خروجی دارای یک نرون است که برچسب کلاس هر پیکسل را مشخص می‌کند و لایه میانی به عنوان واسطه لایه ورودی و خروجی عمل می‌کند.




شکل ۳-۳. ساختار شبکه عصبی با یک لایه میانی

با در نظر گرفتن بردار $W_i = [\Omega_{i1}, \Omega_{i2}, \dots, \Omega_{in}]^T$ در مورد یک شبکه عصبی با چند لایه میانی عملکرد نرون i ام از را می‌توان به صورت رابطه (۳-۳) نشان داد:

$$S_j = \sum_{i=1}^n X_i \Omega_{ij} + B_j, \quad Z_j = \phi_j(S_j) \quad (3-3)$$

که در آن i شاخص نرون لایه قبل، j شاخص نرون لایه مورد نظر، n تعداد نرون‌های لایه قبل، X_i خروجی نرون i ام لایه قبل، Ω_{ij} وزن اتصال‌دهنده نرون i ام لایه قبل به نرون j ام لایه فعلی، B_j مقدار بایاس، Z_j ورودی نرون j ام لایه فعلی، ϕ_j تابع فعالسازی نرون j ام و Z_j خروجی نرون j ام است.

توابع فعالسازی مختلفی وجود دارد که از مهم‌ترین آن‌ها می‌توان به توابع خطی، سیگموئید (لگاریتمی)، سیگموئید (تانژانت هایپربولیک) و تابع آستانه اشاره کرد. این توابع در شکل ۳-۴ نشان داده شده است.



$$f(x) = \begin{cases} 1 & x \geq 0 \\ 0 & x < 0 \end{cases} \quad f(x) = \frac{2}{(1 + \exp(-2x))} - 1 \quad f(x) = \frac{1}{1 + \exp(-x)} \quad f(x) = x$$

شکل ۳-۴. توابع فعالسازی به ترتیب از راست به چپ: خطی، سیگموئید (لگاریتمی)، سیگموئید (تانژانت هایپربولیک)، تابع آستانه

برای آموزش این شبکه‌ها فرض کنید مدل به صورت $F(x, w)$ باشد که در آن x بردار ورودی و w بردار پارامترهای شبکه عصبی است. اگر N داده آموزشی به صورت $(x_i, y_i), i = 1, 2, \dots, N$ وجود داشته باشد، آنگاه خطای شبکه عصبی برای هر داده آموزشی به صورت رابطه (۳-۴) تعریف می‌شود:

$$e_i = y_i - F(x_i, w) \quad (۳-۴)$$

هدف یافتن بردار w است به نحوی که تابع $E = 1/2 \sum_{i=1}^N e_i^2$ را حداقل کند. یکی از روش‌های رایج آموزش شبکه، روش پس انتشار خطا^۱ است. در این روش آموزش شبکه در سه مرحله صورت می‌گیرد؛ مرحله اول، ارائه داده‌های آموزشی به شبکه در لایه ورودی و خروجی، مرحله دوم، محاسبه خطای شبکه، برگشت و انتشار خطا در شبکه به طور معکوس از خروجی به ورودی و مرحله سوم، تصحیح وزن‌ها در جهت کاهش خطا می‌باشد.

مرحله آموزش یک پروسه تکرارشونده است، تصحیحات مربوط به پارامترهای وزن منتسب به هر نرون محاسبه و به مقادیر پیشین اضافه می‌گردند. رابطه (۳-۵) چگونگی این محاسبات را نشان می‌دهد.

$$\begin{cases} \Delta w_{i,j}^{k-1,k} = -\eta(t) \frac{\partial E}{\partial w_{i,j}^{k-1,k}} \\ \Delta w_{i,j}(t+1) = -\Delta w_{i,j} + \alpha \Delta w_{i,j}(t) \end{cases} \quad (۳-۵)$$

$w_{i,j}$ وزن منتسب به پاسخ نرون j ام است که به عنوان ورودی به نرون i ام در لایه بعد ارسال می‌گردد. η یک ثابت عددی است که روند و مقدار تصحیحات اعمال شده به وزن‌ها را کنترل می‌کند و نرخ آموزش^۲ نامیده می‌شود. α که پارامتر اینرسی^۳ نام دارد، مقادیر بین صفر و یک را اتخاذ می‌کند و در نقش پایدارسازی روند آموزش اقدام می‌نماید، بدین ترتیب که میزان تصحیحات در هر مرحله متاثر از مرحله قبل می‌باشد. t بیانگر تعداد تکرار انجام شده در مرحله آموزش است.

بعد از مرحله آموزش، شبکه عصبی با استفاده از داده‌های آزمایشی مورد آزمون قرار می‌گیرد. اگر

^۱ Error Back propagation

^۲ learning rate

^۳ momentum parameter

خطای داده‌های آزمایشی پس از آموزش کمتر از مقدار دلخواهی باشد، آموزش شبکه مناسب بوده است و می‌توان از آن برای پیش‌بینی استفاده کرد.

از جمله معایب شبکه‌های عصبی آن است که در این شبکه‌ها تعداد داده‌های آموزشی مورد نیاز، وابستگی زیادی به پیچیدگی مسئله دارند. با پیچیده‌تر شدن مسئله، پارامترهای موجود در مدل و در نتیجه تعداد داده‌های لازم جهت آموزش شبکه افزایش می‌یابد و در صورت کافی نبودن تعداد داده‌ها ممکن است مدل در اکستریم‌های محلی گرفتار شود و یا موجب برازش بیش از حد گردد. بدین ترتیب قابلیت پیش‌بینی مدل به شدت کاهش پیدا خواهد کرد. علاوه بر این فرایند آموزش توأم با تکرار در این شبکه‌ها، بسیار زمانبر و پرهزینه می‌باشد. نکته مهم دیگر در مورد این شبکه‌ها آن است که، مرزهای تصمیم که داده‌ها را به کلاس‌های مجزا تفکیک می‌کنند، ممکن است بسیار پیچیده یا در اصل خارج از توان بازنمایی شبکه باشند. یک طبقه‌بندی‌کننده که تنها قادر به یادگیری مرزهای خطی است، نمی‌تواند مرزهای پیچیده غیرخطی را آموزش ببیند.

۲-۲-۲-۳ ماشین‌های بردار پشتیبان


ماشین‌های بردار پشتیبان (SVM)، یکی از جدیدترین و قدرتمندترین طبقه‌بندی‌کننده‌ها در سنجش از دور محسوب می‌شوند. روش‌های کلاسیک یادگیری، جهت حداقل کردن خطا بر روی مجموعه داده‌های آموزش یعنی حداقل‌سازی خطای تجربی^۱ طراحی شده‌اند (Vapnik, 1995). متداول‌ترین نمونه از این روش‌ها، شبکه‌های عصبی مصنوعی می‌باشند. برخلاف این روش‌ها، ماشین‌های بردار پشتیبان مبتنی بر حداقل کردن خطای ساختاری هستند. به عبارت ساده‌تر ساختار سیستم مانند شبکه‌های عصبی از ابتدا مشخص نمی‌باشد و در طول فرآیند آموزش علاوه بر حداقل‌سازی خطای تجربی، خطای ساختاری نیز حداقل شده و بهینه‌ترین ساختار سیستم نیز تعیین می‌گردد. این ماشین‌ها دارای قدرت بالاتری نسبت به بقیه روش‌های یادگیری کلاسیک برای داده‌های غیرآموزشی (داده‌های تست) می‌باشند. همچنین به طور موثری قادر به غلبه بر مشکلاتی مانند برازش

¹ empirical risk minimization

بیش از حد و مسائلی چون بهینه محلی که معمولاً در یادگیری شبکه عصبی مشاهده می‌شود، می‌باشند.

• طبقه‌بندی خطی با حاشیه سخت^۱

ایده اصلی SVM یافتن فوق صفحه بهینه برای جدا کردن دو کلاس با بیشترین حاشیه جداسازی می‌باشد. به عبارت دیگر در استفاده از روش‌هایی مانند شبکه عصبی، در فضای n بعدی، هدف یافتن فوق صفحه $n-1$ بعدی است که بتواند نقاط موجود در این فضا را از هم تفکیک کند. در این صورت همان‌گونه که در شکل ۳-۵ نیز مشاهده می‌شود، مسئله می‌تواند چندین جواب داشته باشد. اما در SVM علاوه بر هدف فوق، خواستار بدست آوردن جوابی هستیم که حداکثر حاشیه را بین دو کلاس ایجاد کند. در این حالت، به فوق صفحه ایجاد شده، فوق صفحه حداکثر حاشیه^۲ گفته می‌شود.




شکل ۳-۵. خط‌های تفکیک‌کننده دو کلاس

در حالت کلی SVM برای طبقه‌بندی دو کلاسی طراحی شده است. در این حالت فرض کنید یک مجموعه داده آموزشی به صورت $D = \{(x_1, y_1), \dots, (x_l, y_l)\}, x_i \in R^n, y_i \in \{+1, -1\}$ داریم، که در آن x_i نشان‌دهنده بردار ویژگی نمونه i ام است و y_i کلاس نمونه i ام را نشان می‌دهد. می‌خواهیم فوق صفحه جداکننده‌ای به صورت $H: w^T x + b = 0$ مشخص کنیم که بین دو کلاس $+1$ و -1 بزرگترین حاشیه را بوجود آورد. در این رابطه w برداری عمود بر فوق صفحه و b ضریب بایاس است.

¹ hard margin

² maximum margin hyperplane

این صفحه جداکننده بهینه، دو کلاس را به نحوی از هم جدا می‌کند که با نزدیکترین نقاط از هر کلاس که به آن‌ها بردارهای پشتیبان گفته می‌شود، بیشترین فاصله را داشته باشد. این کار نه تنها یک جواب منحصر به فرد برای انتخاب صفحه جداکننده بوجود می‌آورد بلکه با بیشینه کردن حاشیه بین دو کلاس عملکرد بهتری را در تفکیک داده‌های تست از خود نشان می‌دهد. به عبارت دیگر تفکیک‌کننده طراحی شده از قابلیت تعمیم‌دهی بهتری برخوردار خواهد بود. می‌توان نشان داد که فوق صفحه‌هایی که حداکثر حاشیه را ایجاد می‌کنند، به صورت موازی با جداکننده بهینه قرار می‌گیرند و بوسیله دو معادله $w^T x + b = +1$ و $w^T x + b = -1$ قابل بیان می‌باشند. فوق صفحه بهینه برای حالت دو کلاس کاملاً جدا در شکل ۶-۳ نشان داده شده است.



شکل ۶-۳. تفکیک‌کننده بهینه برای دو کلاس کاملاً جدا (Burges, 1998)

اگر نمونه‌های آموزشی بوسیله یک خط قابل جداسازی باشند، فوق صفحه‌ها به گونه‌ای قرار می‌گیرند که هیچ نمونه‌ای بین آن‌ها قرار نداشته باشد و حداکثر فاصله را داشته باشند. با توجه به اینکه فاصله بین دو فوق صفحه $2/\|w\|$ است، هدف کمینه کردن $\|w\|$ می‌باشد. برای اینکه هیچ نمونه‌ای بین دو فوق صفحه قرار نگیرد، باید حداقل یکی از شرایط $w^T x_i + b \geq +1$ یا $w^T x_i + b \leq -1$ برقرار باشد. این شرط را می‌توان به کمک رابطه (۶-۳) نیز بیان نمود.

(۶-۳)

$$y_i(w^T x_i + b) \geq 1$$


نهایتاً با استفاده از توابع لاگرانژ، تابع تصمیم بهینه از رابطه (۷-۳) بدست خواهد آمد که در آن α_i

ضرایب لاگرانژ می‌باشد.

$$f(x_i) = \text{sign} \left\{ \sum_{i=1}^l \alpha_i y_i (x_i^T \cdot x) + b \right\} \quad (۷-۳)$$

• طبقه‌بندی خطی با حاشیه نرم^۱

یکی از راه‌های برخورد با حالتی که کلاس‌ها همپوشانی دارند آن است که اجازه داده شود بعضی نقاط در داخل حاشیه یا سمت اشتباه مرز تصمیم‌گیری قرار گیرند (شکل ۷-۳).



شکل ۷-۳. تفکیک‌کننده بهینه برای دو کلاس دارای همپوشانی (Burgess, 1998)

در این حالت، هدف اصلی SVM حل یک مسئله بهینه‌سازی جهت ماکزیمم کردن حاشیه در عین مینیمم کردن تعداد نمونه‌های آموزشی قرار گرفته درون حاشیه است. با تعریف ξ_i به عنوان پارامتر تخطی و C به عنوان پارامتر جریمه^۲، بیان ریاضی مسئله به صورت رابطه (۸-۳) خواهد بود.

$$\text{Min } \Phi(w, \xi_i) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l \xi_i; i = 1, 2, \dots, l \quad (۸-۳)$$

$$\text{Subject To: } y_i(w^T x_i + b) \geq 1 - \xi_i; \xi_i \geq 0; i = 1, 2, \dots, l$$

^۱ soft margin

^۲ penalty

• طبقه‌بندی غیرخطی

برای داده غیر قابل تفکیک به صورت خطی، SVM از طریق تابع کرنل فضای ورودی را به یک فضای ویژگی با ابعاد بالاتر که در آن یک فوق صفحه خطی یافت می‌شود، نگاشت می‌کند (Frohlich et al., 2003). از طرفی ماشین بردار پشتیبان تضمین می‌کند که مسائل غیرخطی وقتی به فضاهای بالاتر نگاشت داده می‌شوند، پیچیدگی محاسباتی بالا نرود و همچنین با معرفی تابع کرنل و عملگر ضرب نقطه‌ای از پدیده curse of dimensionality جلوگیری می‌کند.

برای نگاشت فضای ورودی، فرض کنید x برداری در فضای ورودی m بعدی باشد و با استفاده از توابع پایه $\varphi_j(x), j = 1, \dots, M$ به فضای ویژگی جدید M بعدی انتقال داده شده باشد. در این صورت هر بردار m بعدی ورودی $x_i, i = 1, \dots, l$ به بردار ویژگی جدیدی به صورت $\varphi(x_i) = [\varphi_1(x_i), \varphi_2(x_i), \dots, \varphi_M(x_i)]^T$ تبدیل می‌شود به طوری که، $k(x, x_i) \equiv \varphi(x)^T \varphi(x_i)$ تابع کرنل می‌باشد. تابع تصمیم‌گیری یک SVM بر پایه کرنل از رابطه (۹-۳) بدست می‌آید.

$$f(x_i) = \text{sign} \left\{ \sum_{i=1}^l \alpha_i y_i k(x, x_i) + b \right\} \quad (9-3)$$

سه تابع کرنل که به طور متداول در SVM بکار برده می‌شود تابع چندجمله‌ای درجه d ، تابع پایه شعاعی (RBF) یا گوسین و تابع سیگموئید می‌باشند که به ترتیب در رابطه (۱۰-۳) تا (۱۲-۳) ارائه شده‌اند.

$$k(x, x_i) = (1 + x^T \cdot x_i)^d \quad (10-3)$$

$$k(x, x_i) = \exp\{-\gamma \times |x - x_i|^2\} \quad (11-3)$$

$$k(x, x_i) = \tanh(1 + x^T \cdot x_i) \quad (12-3)$$

کارایی SVM به نوع تابع کرنل، پارامترهای کرنل، و پارامتر جریمه C وابسته است. یکی از ضعف‌های SVM این است که تنظیم پارامترهای آن قاعده خاصی ندارد و در بسیاری از موارد با سعی و خطا انجام می‌شود. توابع کرنل و پارامترهای آن در دقت طبقه‌بندی عوارض با استفاده از طبقه‌بندی‌کننده SVM بسیار تاثیرگذار می‌باشد (Yang et al., 2007). از طرفی انتخاب زیرمجموعه

ویژگی بر روی پارامترهای SVM مناسب تاثیر می‌گذارد و برعکس. به عبارت دیگر، کارایی و دقت طبقه‌بندی‌کننده SVM تحت تاثیر پارامترهای آن و زیرمجموعه ویژگی ورودی است. تاکنون روش‌هایی نیز برای تعیین پارامترهای SVM ارائه شده است. جستجوی شبکه‌ای^۱ از رایج‌ترین روش‌های تعیین این پارامترها محسوب می‌شود (Hsu et al., 2003). این روش با وجود سادگی، زمانبر است و یک روش جستجوی محلی محسوب می‌شود.

کرنل گوسین یکی از رایج‌ترین و جامع‌ترین توابع کرنل می‌باشد که تنها یک پارامتر γ دارد. معمولاً برای تعیین C و γ در روش جستجوی شبکه‌ای ابتدا بازه‌ای از اعداد مانند $C \in \{2^{-7}, 2^{-6}, \dots, 2^7\}$ ؛ $\gamma \in \{2^{-7}, 2^{-6}, \dots, 2^7\}$ در نظر گرفته می‌شود. در این روش هر ترکیب از پارامترها با استفاده از روش اعتبارسنجی k-fold cross validation بررسی و پارامترها با بهترین دقت برگزیده می‌شوند. در این تحقیق، به علت هزینه محاسباتی بالای این روش، تعیین بهترین پارامترهای SVM همزمان با فرآیند انتخاب ویژگی و با استفاده از GA انجام شده است.

برای استفاده از SVM در حالت چندکلاسه دو استراتژی یک در برابر بقیه^۲ (OAA) و یک در برابر یک^۳ (OAO) وجود دارد. در روش یک در برابر یک، برای هر زوج کلاس ممکن از یک SVM باینری استفاده می‌شود، بنابراین برای C کلاس، $C(C-1)/2$ طبقه‌بندی‌کننده باینری داریم. در روش یک در برابر بقیه هر ماشین بردار پشتیبان داده‌های یک کلاس را از داده‌های کلاس‌های دیگر جدا می‌کند. در این روش برای C کلاس، C طبقه‌بندی‌کننده باینری خواهیم داشت. در هر دو روش برچسب نهایی داده از طریق روش رای‌گیری حداکثر تعیین می‌شود. نشان داده شده است که OAO معمولاً عملکرد بهتری دارد (Hsu and Lin, 2002).

۳-۳ انتخاب ویژگی چندهدفه

تاکنون، روش‌های متعددی برای حل مسائل بهینه‌سازی چندهدفه معرفی شده‌اند که از میان

^۱ grid search

^۲ one against all

^۳ one against one

آن‌ها، روش‌های بهینه‌سازی تکاملی جایگاه ویژه‌ای دارند، زیرا برخلاف روش‌های کلاسیک که اغلب مسئله چندهدفه را به مسئله یک هدفه تقلیل می‌دهند، مسائل چندهدفه را به همان شکل که هستند، مورد حل قرار می‌دهند و از تبدیلات هندسی و مشابه آن استفاده نمی‌کنند. بهینه‌سازی چندهدفه تکاملی^۱ (EMO) یکی از فعال‌ترین زمینه‌های تحقیقاتی در حوزه محاسبات تکاملی محسوب می‌شود. اولین بار Emmanouilidis و همکاران (2000) استفاده از الگوریتم‌های ژنتیک چندهدفه^۲ (MOGA) را برای انتخاب ویژگی پیشنهاد کردند. از یکبار اجرای الگوریتم ژنتیک تک‌هدفه^۳ (SOGA) تنها یک راه‌حل بدست می‌آید، درحالی‌که از یکبار اجرای MOGA تعدادی راه‌حل حاصل می‌شود که هیچ‌یک بر دیگری برتری و غلبه ندارد (راه‌حل‌های نامغلوب). در این بخش، ابتدا مقایسه‌ای بین تک راه‌حل SOGA و مجموعه راه‌حل‌های نامغلوب MOGA انجام می‌شود و سپس به شرح روش پیشنهادی استفاده از MOGA در انتخاب ویژگی‌های PolSAR پرداخته خواهد شد.

ارتباط بین تک راه‌حل SOGA و مجموعه راه‌حل‌های نامغلوب MOGA را می‌توان مطابق شکل ۸-۳ به چهار حالت دسته‌بندی کرد (Ishibuchi *et al.*, 2006).

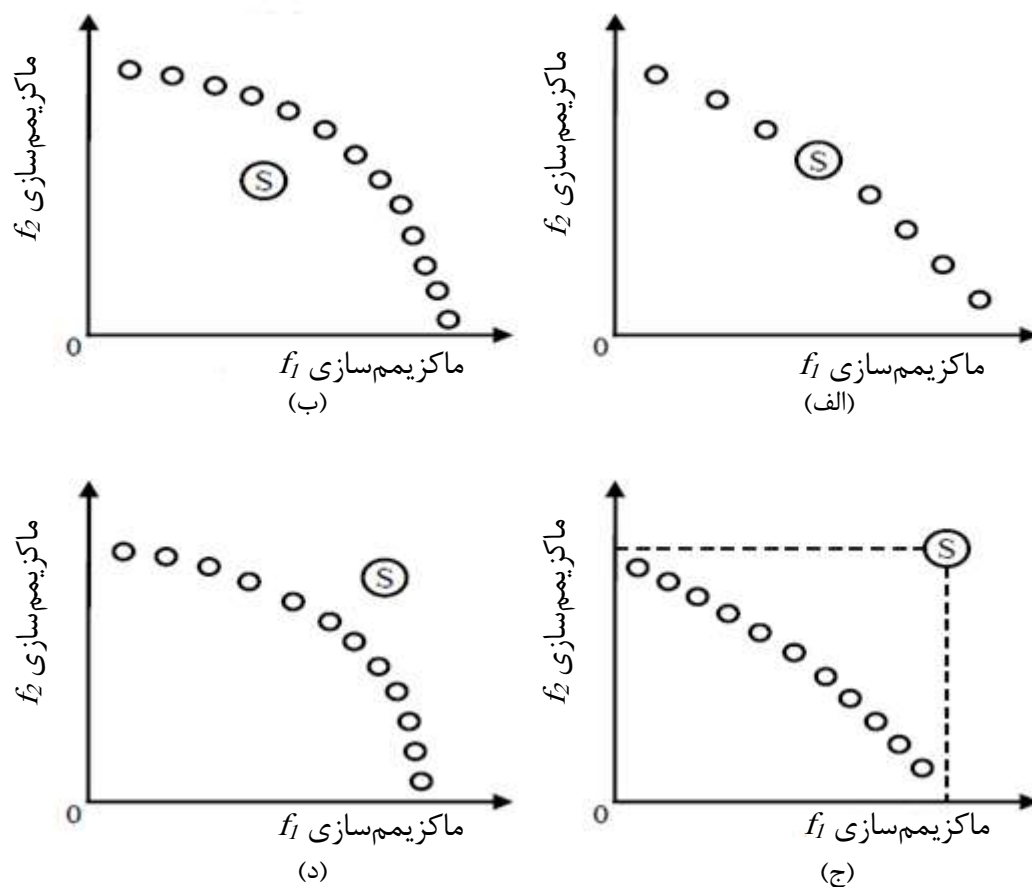
در شکل ۸-۳ (الف)، راه‌حل S راه‌حلی نامغلوب در مجموعه راه‌حل MOGA است. در صورتی که وارد کردن S تا حدی کیفیت مجموعه راه‌حل MOGA را بهبود دهد، نمی‌توان اظهار داشت که SOGA عملکرد بهتری دارد. از آنجایی که راه‌حل S بر هیچ راه‌حلی از راه‌حل‌های MOGA غلبه نمی‌کند، بنابراین در شکل ۸-۳ (الف) MOGA عملکرد بهتری از SOGA دارد.

¹ evolutionary multi-objective optimization

² multi-objective genetic algorithm

³ single-objective genetic algorithm

(S) : SOGA O : MOGA

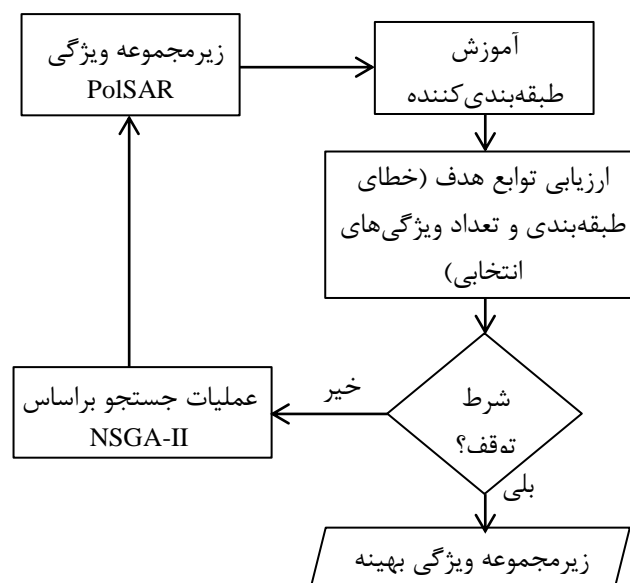


شکل ۳-۸. چهار حالت ارتباط بین تک راه حل SOGA و مجموعه راه حل‌های نامغلوب MOGA (Emmanouilidis et al., 2000)

در شکل ۳-۸ (ب)، راه حل S از SOGA توسط برخی راه حل‌ها در مجموعه راه حل MOGA مغلوب شده است. در این حالت MOGA عملکرد بهتری از SOGA دارد از آنجایی که با در نظر گرفتن راه حل S کیفیت مجموعه راه حل MOGA بهبود داده نمی‌شود. در شکل ۳-۸ (ج) SOGA عملکرد بهتری از MOGA دارد از آنجایی که راه حل S بر همه راه حل‌ها در مجموعه راه حل MOGA غلبه دارد ولی این حالت به ندرت اتفاق می‌افتد. در شکل ۳-۸ (د) تشخیص اینکه کدام راه حل بهتر می‌باشد، سخت‌تر است چرا که راه حل S نسبت به برخی از راه حل‌های MOGA غلبه دارد، بنابراین MOGA ممکن است بهتر از SOGA ارزیابی شود.

در این پایان‌نامه روش‌های انتخاب ویژگی چندهدفه MOGA-SVM و MOGA-ANFIS به

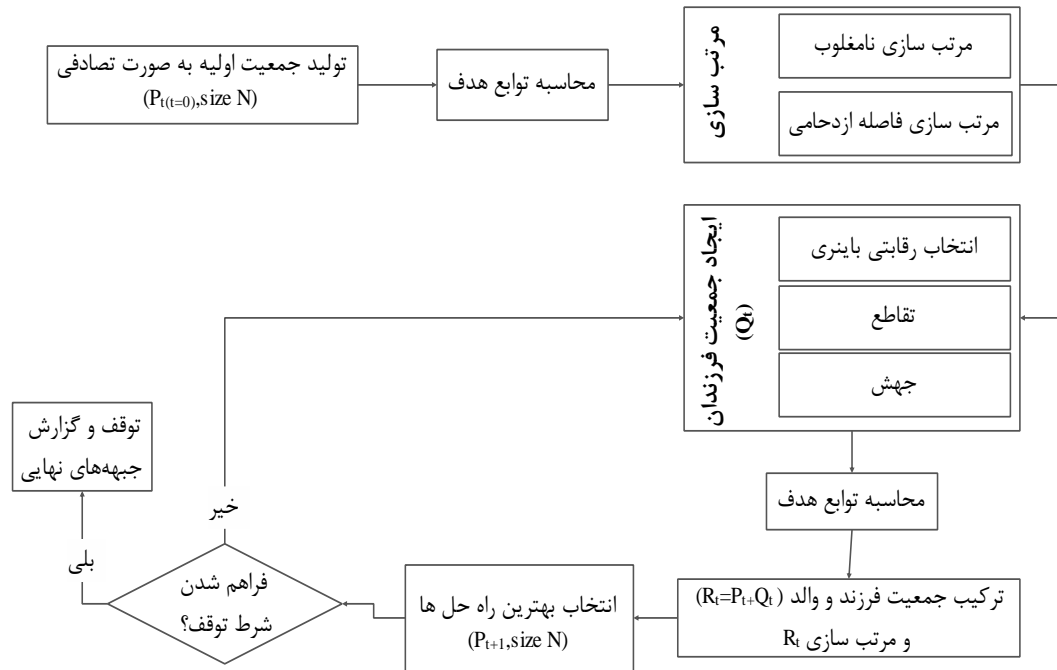
منظور کمینه‌سازی تعداد ویژگی‌های PolSAR انتخابی و خطای طبقه‌بندی ارائه شده است. تفاوت این روش‌ها با روش‌های تک‌هدفه همان‌طور که در شکل ۳-۹ مشاهده می‌شود، آن است که در مرحله جستجو به جای GA از الگوریتم بهینه‌سازی چندهدفه NSGA-II استفاده شده و تعداد ویژگی‌های انتخابی و خطای کلی طبقه‌بندی با SVM و یا ANFIS به عنوان توابع هدف در نظر گرفته می‌شود.




شکل ۳-۹. فلوچارت الگوریتم انتخاب ویژگی چندهدفه

۳-۳-۱ روش جستجو: الگوریتم ژنتیک با مرتب‌سازی نامغلوب ۲ (NSGA-II)

الگوریتم ژنتیک با مرتب‌سازی نامغلوب ۲ (NSGA-II) که توسط Deb و همکارانش در سال ۲۰۰۲ معرفی گردید یکی از پرکاربردترین و قدرتمندترین الگوریتم‌های موجود برای حل مسائل بهینه‌سازی چندهدفه می‌باشد و کارایی آن در حل مسائل مختلف، به اثبات رسیده است. فلوچارت و طرح کلی این الگوریتم به ترتیب در شکل ۳-۱۰ و شکل ۳-۱۱ ارائه شده است.



شکل ۳-۱۰. فلوچارت الگوریتم NSGA-II



شکل ۳-۱۱. طرح کلی الگوریتم NSGA-II، P_t جمعیت اولیه، Q_t جمعیت فرزندان در نسل t و F_i نشان‌دهنده Front است (Deb et al., 2006).

یکی از مفاهیم پایه در مسائل چندهدفه، رابطه غلبه^۱ می‌باشد. بر طبق این رابطه، راه حل J_1 بر راه حل J_2 غلبه دارد اگر و فقط اگر دو شرط زیر همزمان برقرار باشد:

- J_1 در هیچ یک از توابع هدف بدتر از J_2 نباشد.
- J_1 حداقل در یک تابع هدف اکیدا بهتر از J_2 باشد.

در الگوریتم NSGA-II ابتدا جمعیت اولیه به صورت تصادفی تشکیل می‌شود و مقادیر توابع هدف یعنی تعداد ویژگی‌های انتخابی و دقت کلی طبقه‌بندی، برای هر راه حل محاسبه می‌گردد. سپس اعضای جمعیت در داخل جبهه‌هایی^۲ قرار می‌گیرند به گونه‌ای که هر جبهه شامل مجموعه‌ای از راه حل‌ها می‌باشد که هیچ کدام بر یکدیگر غلبه نمی‌کنند. به عبارت دیگر اعضای موجود در جبهه اول (F_1)، یک مجموعه کاملاً نامغلوب از نظر توابع هدف توسط دیگر اعضای جمعیت فعلی می‌باشند. اعضای موجود در F_2 نیز بر همین مبنا تنها توسط اعضای F_1 مغلوب شده و این روند به همین صورت در جبهه‌های دیگر ادامه یافته تا به تمام اعضای موجود در هر جبهه، یک رتبه بر مبنای شماره آن اختصاص داده شود. سپس برای هر عضو در هر جبهه معیار فاصله ازدحامی^۳ محاسبه می‌شود، به این صورت که ابتدا برای هر تابع هدف نتایج مرتب می‌شود. به نقاطی که ماکزیمم و مینیمم مقدار این تابع هدف را دارند، مقدار فاصله بینهایت اختصاص می‌یابد. فاصله ازدحامی برای سایر اعضای جمعیت در هر جبهه طبق روابط (۱۳-۳) تا (۱۵-۳) محاسبه می‌شود.

$$cd_1^i = |f_1^{i+1} - f_1^{i-1}| / (f_1^{max} - f_1^{min}) \quad (13-3)$$

$$cd_2^i = |f_2^{i+1} - f_2^{i-1}| / (f_2^{max} - f_2^{min}) \quad (14-3)$$

$$cd(i) = cd_1^i + cd_2^i \quad (15-3)$$

که در آن $cd(i)$ ، فاصله ازدحامی عضو i ام بر روی جبهه F ، f_1^i و f_2^i به ترتیب مقادیر تابع هدف اول و دوم در i امین عضو در جبهه F و f^{max} ، f^{min} به ترتیب کمترین و بیشترین مقدار تابع هدف

¹ Dominance Relation

² front

³ crowding distance


در جبهه F است. در ادامه با استفاده از روش انتخاب رقابتی باینری^۱ دو راه‌حل به تصادف از میان جمعیت برگزیده شده و میان این دو جواب مقایسه‌ای انجام می‌شود و هر کدام که بهتر باشد، نهایتاً انتخاب می‌شود. معیارهای انتخاب در الگوریتم NSGA-II در درجه اول، رتبه جواب و در درجه دوم مربوط به فاصله ازدحامی جواب است. هرچه رتبه جواب کمتر باشد و دارای فاصله ازدحامی بیشتری باشد، مطلوب‌تر است.

با تکرار عملگر انتخاب باینری بر روی جمعیت هر نسل، مجموعه‌ای از افراد آن نسل برای شرکت در تقاطع و جهش انتخاب می‌شوند و جمعیتی از فرزندان ایجاد می‌شود. در ادامه، این جمعیت با جمعیت اصلی ادغام می‌شود. اعضای جمعیت جدید، ابتدا براساس رتبه و به صورت صعودی مرتب می‌شوند و سپس اعضای از جمعیت که دارای رتبه یکسانی هستند، براساس فاصله ازدحامی و به صورت نزولی مرتب می‌شوند. حال اعضای جمعیت در درجه اول براساس رتبه، و در درجه دوم براساس فاصله ازدحامی مرتب‌سازی شده‌اند. برابر با تعداد افراد جمعیت اصلی، اعضای از بالای فهرست مرتب شده انتخاب می‌شوند و بقیه اعضای جمعیت کنار گذاشته می‌شوند. اعضای انتخاب شده جمعیت نسل بعدی را تشکیل می‌دهند و چرخه مذکور در این بخش، تا محقق شدن شرایط خاتمه تکرار می‌شود.

مجموعه جواب‌های نامغلوب بدست آمده از حل مسئله بهینه‌سازی چندهدفه، غالباً به نام جبهه پارتو بهینه^۲ شناخته می‌شوند. هیچ‌کدام از این جواب‌ها بر دیگری ارجحیت ندارند و می‌توان هر کدام را به عنوان یک تصمیم بهینه در نظر گرفت. شکل ۳-۱۲ نمایشی از جبهه پارتو بهینه و جمعیتی از راه‌حل‌ها را در کمینه‌سازی دو تابع هدف در این تحقیق ارائه می‌دهد.

¹ binary tournament selection

² Pareto-optimal front



شکل ۳-۱۲. مثالی از راه‌حل‌های مغلوب و بهینه پارتو در یک فضای جستجوی دو هدفه

۳-۳-۲ تابع هدف

همان‌طور که قبلاً بیان شد در روش‌های پیشنهادی MOGA-SVM و MOGA-ANFIS بهینه‌سازی دو تابع هدف مد نظر است:

(۱) دقت کلی: دقت مدل طبقه‌بندی بر روی مجموعه داده تست که به عنوان رایج‌ترین روش

برای ارزیابی یک مدل، تخمینی از توانایی تعمیم‌دهی آن نیز می‌باشد (Suttorp and Igel, 2006).

(۲) تعداد ویژگی‌های ورودی به مدل: یافتن حداقل تعداد ویژگی‌های با قدرت تمییز بالا و حذف ویژگی‌های تکراری و نامناسب علاوه بر کاهش هزینه محاسباتی و پیچیدگی مدل، می‌تواند عملکرد طبقه‌بندی‌کننده را نیز بهبود بخشد. ویژگی‌های زیاد توانایی تعمیم ضعیف طبقه‌بندی‌کننده را به دنبال خواهد داشت.

۳-۳-۱ سیستم استنتاج عصبی - فازی تطبیقی

نظریه فازی برای اولین بار توسط پروفسور Zadeh در سال ۱۹۶۵ معرفی گردید و سپس در بسیاری از فرآیندهای صنعتی و مسائل مختلف مهندسی با موفقیت مورد استفاده قرار گرفت. Jang در سال ۱۹۹۳، با استفاده از توانایی استنتاج سیستم فازی و قابلیت یادگیری و انطباق‌پذیری شبکه عصبی، سیستم استنتاج عصبی - فازی تطبیقی (ANFIS) را ارائه داد. در این سیستم‌ها کلیه پارامترهای مربوط به قوانین فازی را می‌توان با استفاده از خاصیت یادگیری شبکه‌های عصبی تنظیم

کرد. به طور کلی در طراحی مدل ANFIS ابتدا یک سیستم استنتاج فازی^۱ (FIS) پایه ایجاد شده، و سپس با الگوریتم‌های آموزشی موجود مانند پس انتشار و یا hybrid پارامترها به گونه‌ای تنظیم می‌شوند که اختلاف خروجی مدل با مقدار واقعی حداقل شود.

روش‌های تقسیم‌بندی شبکه‌ای^۲ و خوشه‌بندی کاهشی^۳ از جمله روش‌های طراحی FIS پایه می‌باشند. تفاوت عمده این دو روش در چگونگی تعیین تابع عضویت^۴ فازی است. در روش تقسیم‌بندی شبکه‌ای نوع و تعداد تابع عضویت بردار اطلاعات ورودی توسط کاربر تعیین می‌شود. در روش خوشه‌بندی کاهشی مشخصات تابع عضویت با توجه به اطلاعات ورودی توسط خود مدل تعیین می‌شود، اما در این روش نیز پارامتری مهم و تاثیرگذار تحت عنوان محدوده نفوذ^۵ خواهیم داشت که باید توسط کاربر تعیین شود. در این تحقیق با توجه به معایب ذکر شده در دو روش قبل و زمانبر بودن آن‌ها از روش مبتنی بر خوشه‌بندی فازی (Fuzzy C-Means) برای طراحی استفاده شده است (Bezdek, 1981). در این روش، داده‌ها براساس شباهتشان به چند گروه (خوشه) تقسیم شده و سپس مدل فازی با تعداد قواعد برابر با تعداد خوشه‌ها، برای تمییز دادن هر یک از خوشه‌ها ایجاد می‌گردد. شرح کامل این روش در پیوست (ب) ارائه شده است. در شکل ۳-۱۳ ساختار ANFIS با دو ورودی x و y و یک خروجی f نشان داده شده است.

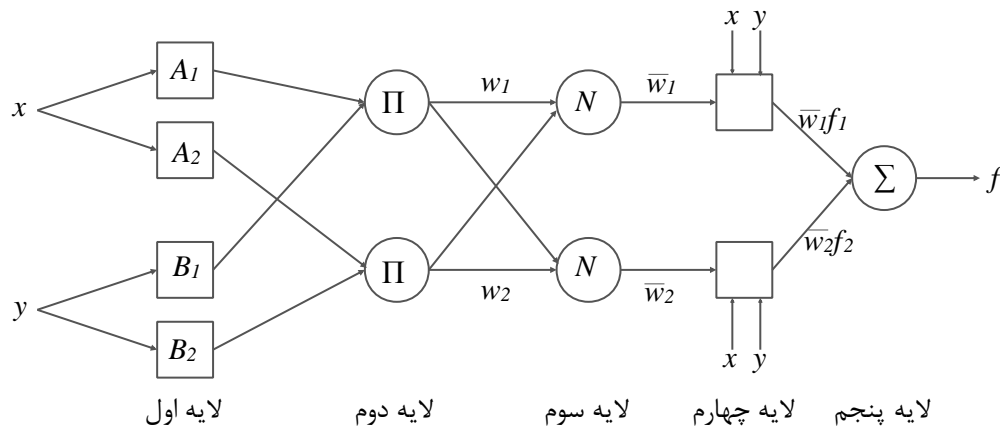
¹ Fuzzy Inference System

² grid partitioning

³ subtractive clustering

⁴ membership function

⁵ range of influence



شکل ۳-۱۳. ساختار ANFIS با دو ورودی و یک خروجی (Jang, 1993)

قوانین سیستم فازی در ANFIS از نوع تاکاگی سوگنو مرتبه اول و به صورت زیر در نظر گرفته می‌شوند.

Rule i: If x is A_i and y is B_i , then $f_i = p_i x + q_i y + r_i$

که در آن A_i و B_i مجموعه‌های فازی هستند و p_i ، q_i و r_i پارامترهایی هستند که در طی فرآیند آموزش تعیین می‌شوند. ساختار ANFIS از پنج لایه تشکیل می‌شود. لایه اول مربوط به محاسبه توابع عضویت می‌باشد و خروجی O_i^1 مقادیر عضویت هر ورودی نسبت به توابع عضویت مختلف مربوط به آن ورودی است.

$$O_i^1 = \mu_{A_i}(x) \quad i = 1, 2 \quad (16-3)$$

$$O_i^1 = \mu_{B_{i-2}}(y) \quad i = 3, 4 \quad (17-3)$$

که x و y ، ورودی‌ها به گره i هستند و توابع عضویت فازی معمولاً به صورت رابطه (۱۸-۳) انتخاب می‌شوند.

$$\mu_{A_i} = e^{\frac{-(x-c_i)^2}{2\sigma_i^2}} \quad i = 1, 2 \quad (18-3)$$

در این رابطه c_i و σ_i پارامترهای بخش مقدم قوانین فازی و به ترتیب نشان‌دهنده میانگین و انحراف معیار تابع گوسین می‌باشند. لایه دوم مربوط به تشکیل قوانین فازی می‌باشد. در این لایه

هیچ‌گونه تنظیم یا تطبیقی روی پارامترها صورت نمی‌گیرد، مقادیر ورودی به هر گره در هم ضرب شده و حاصل که وزن قانون‌ها و به عبارتی میزان تاثیر هر قانون در خروجی نهایی می‌باشد، بدست می‌آید.

$$O_i^2 = w_i = \mu_{A_i}(x)\mu_{B_i}(y) \quad (19-3)$$

لایه سوم لایه نرمالسازی می‌باشد. وزن نسبی قوانین به صورت رابطه (۲۰-۳) در نظر گرفته می‌شود.

$$O_i^3 = \bar{w}_i = \frac{w_i}{w_1 + w_2} \quad (20-3)$$

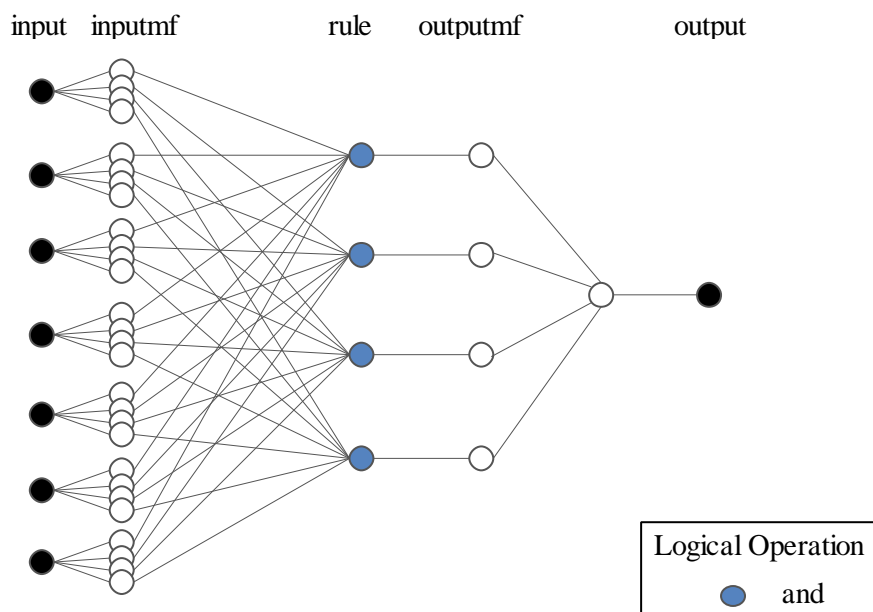
خروجی لایه چهارم از ضرب خروجی لایه سوم در یک چندجمله‌ای مرتبه اول تشکیل شده و از رابطه (۲۱-۳) محاسبه می‌شود. در این رابطه، پارامترهای p_i ، q_i و r_i پارامترهای بخش تالی قوانین در مدل فازی تاکاگی سوگنو هستند.

$$O_i^4 = \bar{w}_i f_i = \bar{w}_i (p_i x + q_i y + r_i) \quad (21-3)$$

در لایه پنجم، تنها گره موجود در این لایه که وظیفه جمع‌بندی تمامی ورودی‌های به این گره را بر عهده دارد، خروجی نهایی مدل را مطابق رابطه (۲۲-۳) محاسبه می‌کند.

$$O_i^5 = \sum_i \bar{w}_i f_i = \frac{\sum_i w_i f_i}{\sum_i w_i} \quad (22-3)$$

لازم به ذکر است که یکی از مشخصه‌های مهم مدل ANFIS نوع تابع عضویت در نظر گرفته شده برای ورودی‌های مدل می‌باشد. از جمله این توابع می‌توان به توابع عضویت دوزنقه‌ای، مثلثی و گوسین اشاره کرد. برای انتخاب نوع تابع عضویت، مدل ANFIS برای هر کدام از این توابع به صورت جداگانه آموزش می‌بیند. در پایان میزان خطای مدل‌ها با هم مقایسه می‌شود و تابعی که کمترین میزان خطا را داشته باشد به عنوان تابع عضویت انتخاب خواهد شد. در این تحقیق، توابع عضویت ورودی از نوع توابع عضویت گوسین تعریف شده‌اند. ساختار کلی ANFIS مورد استفاده در روش MOGA-ANFIS با فرض انتخاب ۷ ویژگی PolSAR در شکل ۳-۱۴ نمایش داده شده است. اپراتور "and" نشان‌دهنده عملگر ضرب است.



شکل ۳-۱۴. ساختار ANFIS مورد استفاده در این تحقیق با ۷ ویژگی ورودی

در این ساختار، ۴ تابع عضویت (به تعداد کلاس‌ها) به هر ورودی اختصاص یافته و ۴ قانون فازی نیز برای توصیف فرآیند و ساخت مدل تعریف شده است. همچنین به ازای هر قاعده، یک تابع عضویت خروجی خطی استفاده شده است.

۳-۴ روش‌های مبنا

در این تحقیق به منظور ارزیابی روش‌های پیشنهادی از دو روش مبنا استفاده شده است. اولین روش که به طور رایج برای طبقه‌بندی داده PolSAR استفاده می‌شود، طبقه‌بندی‌کننده ویشارت بر مبنای ۹ المان ماتریس کواریانس (Lee *et al.*, 2001) می‌باشد. ماتریس کواریانس پلاریمتریک Z را می‌توان بوسیله توزیع مختلط چند متغیره^۱ ویشارت توصیف کرد. اگر $C_m = E(Z|w_m)$ ماتریس کواریانس میانگین برای کلاس w_m و $|C_m|$ دترمینان این ماتریس باشد، براساس طبقه‌بندی‌کننده

¹ multivariate complex

حداکثر احتمال و توزیع مختلط ویشارت، معیار فاصله ویشارت به صورت رابطه (۳-۲۳) در نظر گرفته می‌شود.

$$d_m = \ln|C_m| + \text{Tr}(C_m^{-1}Z) \quad (۳-۲۳)$$

در این صورت پیکسل به کلاس $w_i, i \in \{1, 2, \dots, k\}$ تعلق دارد اگر

$$d_m^{(i)} \leq d_m^{(j)} \quad \forall w_j \neq w_i \quad (۳-۲۴)$$

طبقه‌بندی با SVM در حالتی که انتخاب ویژگی صورت نگرفته است یعنی با مجموعه ویژگی کامل، دیگر روش مبنای مورد استفاده در این تحقیق می‌باشد.

فصل چهارم: پیاده‌سازی الگوریتم‌ها و بررسی نتایج

۱-۴ مقدمه

در این فصل ابتدا مجموعه داده مورد استفاده و مراحل پیش‌پردازش آن معرفی شده و سپس نتایج پیاده‌سازی الگوریتم‌های ارائه شده در فصل قبل مورد بررسی قرار می‌گیرد. در نهایت ویژگی‌های بهینه انتخابی در بهبود طبقه‌بندی پوشش زمین منطقه مطالعاتی معرفی شده و به تحلیل و بررسی برخی از آنها خواهیم پرداخت.

لازم به ذکر است در این تحقیق از نرم‌افزارهای MATLAB 7.13، ENVI 4.2، PCI Geomatics 2012 و PolSARpro 4.2 استفاده شده است.

۲-۴ مجموعه داده و پیش‌پردازش

به منظور ارزیابی عملکرد روش‌های پیشنهادی، تصویر پلاریمتریک شهر سانفرانسیسکو در سال ۲۰۰۸ مربوط به سنجنده رادارست ۲ در باند C با طول موج ۵/۵۵ سانتی‌متر مورد استفاده قرار گرفته است. این داده در مد ^۱FQ9 با فرمت ^۲SLC و با قدرت تفکیک مکانی در جهت رنج ^۳۱۱/۱ متر در برد نزدیک تا ۱۰/۵ متر در برد دور جمع‌آوری شده است. ابعاد تصویر ۱۴۰۰×۸۰۰ پیکسل است که ترکیب رنگی Pauli آن و تصویر Google Earth منطقه در شکل ۱-۴ نشان داده شده است.

منطقه مورد مطالعه شامل ۴ کلاس اصلی آب، ساختمان، پوشش گیاهی (شامل جنگل و پوشش گیاهی متراکم) و جاده می‌باشد. تعداد نمونه‌های آموزش و تست در هر کلاس که با استفاده از تصویر Pauli و تصویر Google Earth انتخاب شده‌اند، در جدول ۱-۴ ارائه شده است.


^۱ fine quad

^۲ Singe Look Complex

^۳ range resolution



(ب)



(الف)

شکل ۴-۱. منطقه سانفرانسیسکو. (الف) تصویر Google Earth منطقه، (ب) تصویر Pauli RGB منطقه که در آن $|S_{hh} - S_{vv}|$ با رنگ قرمز، $|S_{hv}|$ با رنگ سبز و $|S_{hh} + S_{vv}|$ با رنگ آبی نشان داده شده است.

جدول ۴-۱. تعداد نمونه‌های آموزش و تست

تعداد پیکسل برای آموزش	تعداد پیکسل برای تست	کلاس
۵۹	۳۱۲	آب
۵۵	۳۱۸	ساختمان
۶۱	۳۱۱	پوشش گیاهی
۶۵	۳۱۹	جاده

مراحل پیش‌پردازش شامل کاهش نویز اسپکل و استخراج ویژگی‌های PolSAR می‌باشد. اسپکل تفسیر تصویر را پیچیده می‌کند و کارایی انتخاب ویژگی و طبقه‌بندی را کاهش می‌دهد. بنابراین، کاهش اسپکل گامی مهم برای استخراج اطلاعات مفید از تصاویر پلاریمتریک محسوب می‌شود. فیلترهای مختلفی برای کاهش اثر نویز اسپکل بکار برده می‌شود. فیلترهای اسپکل باید به بهترین توازن ممکن بین کاهش نویز در مناطق همگن و حفظ جزئیات مکانی برسند (Foucher and Lopez- Martinez, 2009). در این تحقیق از فیلتر refined Lee استفاده شده است (Lee *et al.*, 1999). این فیلتر به طور موثر اطلاعات پلاریمتریک و کیفیت تصویر را حفظ می‌کند و اثر نویز را در مناطق همگن کاهش می‌دهد.

برای بررسی نتایج الگوریتم‌های پیشنهادی، ابتدا استخراج ویژگی‌های پلاریمتری که شرح آن‌ها در فصل دوم بیان شد، انجام گرفت. ۱۰۵ ویژگی استخراج شده از تصویر منطقه سانفرانسیسکو در جدول ۲-۴ ارائه شده است. در این جدول برای مثال نماد "H_shannon"، "asym" و "ped" به ترتیب توصیف‌گر ویژگی انتروپی شانون، عدم تقارن پلاریزاسیون و ارتفاع پداستال می‌باشد.

جدول ۲-۴. ویژگی‌های پلاریمتری مورد استفاده در این تحقیق

تعداد	نماد	توصیف	ویژگی
۳	[S]	scattering matrix elements	ویژگی‌های اصلی
۸	[T]	coherency matrix elements	
۶	[C]	covariance matrix elements	
۳	[Krog] _{Ks} , [Krog] _{Kd} , [Krog] _{Kh}	Krogager	ویژگی‌های تجزیه
۹	[Huy]	Huynen	
۹	[Bar]	Barnes	
۹	[Clou]	Cloude	
۹	[Holm]	Holm	
۳	[Vanzyl] _{odd} , [Vanzyl] _{dbl} , [Vanzyl] _{vol}	Van Zyl	
۱۹	H, A, A12, alpha, beta, lambda, gamma, delta, HA, (1-H)A, H(1-A), (1-H)(1-A), SERD, DERD, asym, RVI, ped, A_luen, H_shannon	Cloude-Pottier	
۳	[Free] _{odd} , [Free] _{dbl} , [Free] _{vol}	Freeman-Durden	
۴	[Yama] _{odd} , [Yama] _{dbl} , [Yama] _{vol} , [Yama] _{hix}	Yamaguchi	
۴	[Touzi] _{alpha} , [Touzi] _{phi} , [Touzi] _{psi} , [Touzi] _{tau}	Touzi	
۱	SPAN	SPAN	تفکیک‌کننده‌های PolSAR
۲	[pow]	received power extrema	
۱	fract	fractional polarization	
۲	[dop]	degree of polarization extrema	
۲	[scat]	scattered intensity extrema	
۲	[pol]	polarized intensity extrema	
۱	[unpol]	unpolarized intensity extrema	
۴	CCC, Ro12, Ro13, Ro23	correlation coefficients	
۱	V	coefficient of variation	

لازم به ذکر است از آنجا که المان‌های قطری ماتریس کواریانس به عنوان ویژگی‌های ماتریس پراکندگی بکار گرفته می‌شوند، تنها دامنه و فاز ۳ المان بالامثلثی ماتریس کواریانس به عنوان ویژگی‌های اصلی در این مطالعه استفاده شده است. همچنین دامنه ۵ المان قطری و بالامثلثی و فاز ۳ المان بالامثلثی ماتریس همبستگی از دیگر ویژگی‌های اصلی می‌باشد و از آنجا که سومین المان قطری از ماتریس همبستگی ($[T]_{33}$) دو برابر دومین المان قطری ماتریس کواریانس ($[C]_{22}$) می‌باشد، این ویژگی در نظر گرفته نشده است (Maghsoudi et al., 2012).

در مورد روش‌های تجزیه ناهمدوس ابتدا برای کاهش اسپکل، المان‌های ماتریس همبستگی با استفاده از فیلتر refined Lee با اندازه 5×5 فیلتر شده و سپس ویژگی‌ها استخراج شدند، اما در مورد ویژگی‌های همدوس، به منظور حفظ اطلاعات فاز، فیلتر کردن بعد از استخراج ویژگی انجام شده است. از آنجایی که ویژگی‌های بدست آمده دارای بازه متفاوتی هستند به عنوان مثال زاویه آلفا در بازه $[0, 90]$ و انتروپی در بازه $[0, 1]$ قرار دارند، لذا در این مرحله مقادیر ویژگی‌ها با استفاده از روش نرمالسازی خطی به بازه $[0, 1]$ تبدیل شدند.

۴-۳ نتایج پیاده‌سازی الگوریتم‌های پیشنهادی

مطابق با آنچه که در فصل سوم بیان شد، ابتدا الگوریتم‌های طبقه‌بندی تک‌هدفه GMLP و GASVM پیاده‌سازی شدند. در ابتدای شروع به کار الگوریتم‌ها، یک جمعیت اولیه از جواب‌ها شامل ۱۰۰ کروموزوم به صورت تصادفی ایجاد می‌شود. در GMLP هر ژن در هر کروموزوم معادل با یکی از ویژگی‌های استخراج شده از تصویر می‌باشد و دارای مقدار باینری صفر یا یک است که یک به معنی انتخاب شدن ویژگی مربوطه می‌باشد. بنابراین در این روش هر کروموزوم شامل ۱۰۵ ژن برابر با تعداد کل ویژگی‌های PolSAR است.

لازم به ذکر است که برای تعیین ساختار مناسب شبکه عصبی MLP، نوع تابع فعالسازی و تعداد نرون‌های لایه میانی به صورت سعی و خطا تعیین شد، و از الگوریتم آموزشی گرادینان نزولی، به علت کارایی و سادگی کاربرد، استفاده گردید. شبکه MLP طراحی شده شامل سه لایه می‌باشد. تعداد نرون لایه ورودی برابر با تعداد ژن‌هایی که دارای مقدار یک هستند، تعداد نرون لایه میانی برابر با ۵ و لایه

خروجی شامل یک نرون ارائه‌دهنده برچسب کلاس در نظر گرفته شده است. همچنین از تابع فعالسازی سیگموید (تانژانت هایپربولیک) (شکل ۳-۴) در لایه میانی و لایه خروجی استفاده شده است.

همان‌طور که قبلاً اشاره شد، در این تحقیق بهینه‌سازی پارامترهای SVM همزمان با انتخاب ویژگی انجام شده است. لذا در روش GASVM با انتخاب تابع کرنل گوسین و در نظر گرفتن بازه $\{2^{-7}, 2^{-6}, \dots, 2^7\}$ برای C و γ و با توجه به اینکه با تنها ۳ بیت می‌توان اعداد ۰, ..., ۷ را کد کرد و در نظر گرفتن ۱ بیت برای علامت مثبت و منفی، تعداد ۸ ژن از کروموزوم‌های تشکیل شده در GA علاوه بر ۱۰۵ ژن ویژگی به این پارامترها اختصاص داده شده است.


در این دو روش تنها از دقت کلی طبقه‌بندی برای ارزیابی راه‌حل‌ها استفاده گردید. روش انتخاب رقابتی برای تشکیل جمعیت جدید اتخاذ شد. عمل تقاطع با نرخ ۰/۸ و با روش ماسک انجام گرفت و مقدار جهش ژنی ۵ درصد تعداد کل ژن‌ها انتخاب شد. شرط توقف نیز تعداد تکرار ۵۰ در نظر گرفته شد.

در جدول ۳-۴ مقایسه‌ای از بهترین نتایج حاصل از دو روش GASVM و GAMLGP، طبقه‌بندی‌کننده SVM با مجموعه ویژگی کامل و طبقه‌بندی‌کننده ویشارت آمده است. نتایج نشان می‌دهد که در روش GASVM تعداد ویژگی‌های کمتری در راه‌حل انتخاب شده نسبت به روش GAMLGP وجود دارد. در راه‌حل نهایی، GAMLGP به ۵۶ ویژگی، یعنی ۵۳ درصد مجموعه ویژگی کامل و GASVM به ۳۷ ویژگی یعنی ۳۵ درصد کل ویژگی‌ها رسیده است. علاوه بر کاهش تعداد ویژگی‌های انتخابی، وارد کردن SVM در فرآیند انتخاب ویژگی افزایش دقت طبقه‌بندی را نیز در مقایسه با MLP و SVM با مجموعه ویژگی کامل به دنبال داشت. لازم به ذکر است که با استفاده از GASVM هزینه محاسباتی نسبت به GAMLGP به طور قابل توجهی کاهش یافت.


جدول ۳-۴. مقایسه‌ای از نتایج روش‌های تک‌هدفه و روش‌های مبنا

الگوریتم	دقت کلی (%)	تعداد ویژگی‌ها
Wishart	۷۵/۳۲	۹
SVM	۹۰/۴	۱۰۵
GAMLP	۸۷/۳۸	۵۶
GASVM	۹۳/۶۵	۳۷


نقشه طبقه‌بندی نهایی حاصل از روش‌های ویشارت، SVM، GASVM، GAMLP و نحوه نمایش رنگی کلاس‌های طبقه‌بندی شده در شکل ۲-۴ تا شکل ۵-۴ ارائه شده است.




شکل ۲-۴. نتیجه طبقه‌بندی نهایی حاصل از الگوریتم Wishart



شکل ۳-۴. نتیجه طبقه‌بندی نهایی حاصل از SVM با مجموعه ویژگی کامل




شکل ۴-۴. نتیجه طبقه‌بندی نهایی حاصل از GASVM



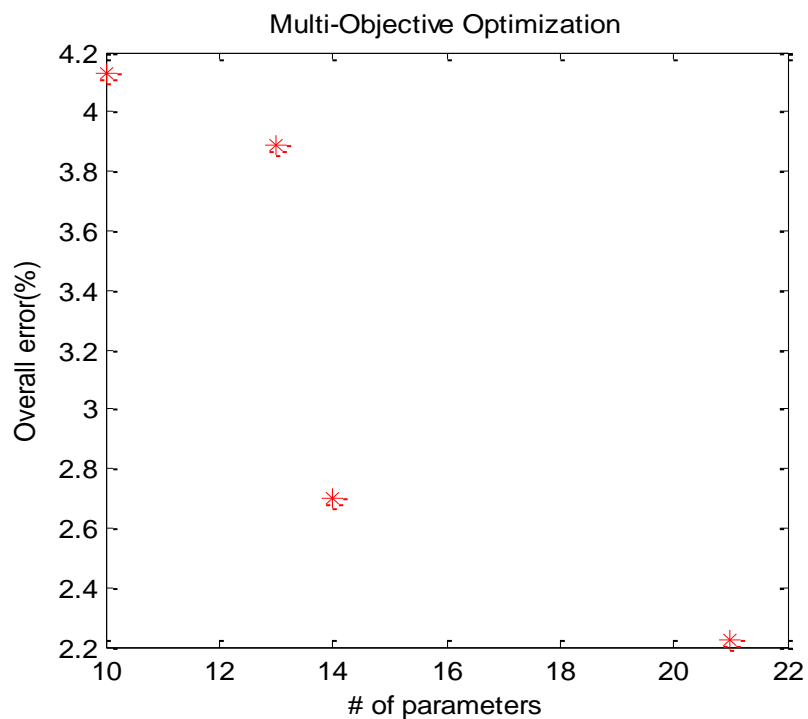
شکل ۴-۵. نتیجه طبقه‌بندی نهایی حاصل از GAMLP

از آنجا که روش‌های تک‌هدفه تنها دقت طبقه‌بندی را در نظر می‌گیرند، ممکن است زیرمجموعه ویژگی انتخاب شده همچنان شامل ویژگی‌های اضافی باشد. به منظور پیاده‌سازی روش‌های چندهدفه، در مرحله جستجو تا حد امکان سعی شد تنظیمات NSGA-II مشابه با GA باشد. در روش MOGA-ANFIS نیز همان‌طور که قبلاً اشاره شد، برای ایجاد FIS پایه از روش خوشه‌بندی فازی (FCM) استفاده شده و تابع عضویت ورودی از نوع گوسین بکار گرفته شد. از الگوریتم hybrid نیز که ترکیبی از روش گرادیان نزولی و روش حداقل مربعات خطا می‌باشد، برای آموزش مدل استفاده شده است که روش گرادیان نزولی برای تنظیم پارامترهای غیرخطی بخش مقدم و روش حداقل مربعات خطا برای تعیین پارامترهای خطی بخش تالی قوانین بکار می‌روند.

مجموعه راه‌حل‌های نامغلوب ارائه شده در MOGA-SVM و MOGA-ANFIS به ترتیب در شکل ۴-۶ و شکل ۴-۷ نشان داده شده است.



شکل ۴-۶. مجموعه پارتو بهینه در MOGA-SVM



شکل ۴-۷. مجموعه پارتو بهینه در MOGA-ANFIS

همان‌طور که قبلاً بیان شد، در روش‌های چندهدفه تنها یک راه‌حل بهینه حاصل نمی‌شود و می‌توان با نظر کارشناس و یا بررسی اطلاعات جانبی هر کدام از راه‌حل‌های جبهه اول (F_1) را مطابق با نیاز کاربر به عنوان یک راه‌حل بهینه در نظر گرفت. در این تحقیق، در MOGA-SVM با توجه به شکل ۴-۶ راه‌حل با کمترین خطا به عنوان راه‌حل انتخابی از F_1 در نظر گرفته شد. ویژگی‌های پلاریمتری راه‌حل انتخابی در جدول ۴-۴ ارائه شده است. در این جدول، برای مثال $[Bar]_{13mod}$ نشان‌دهنده دامنه المان سطر اول و ستون سوم ماتریس Barnes می‌باشد و $[Krog]_{kh}$ به پراکندگی helix از تجزیه Krogager اشاره دارد.

جدول ۴-۴. ویژگی‌های PolSAR راه‌حل انتخابی در MOGA-SVM

زیرمجموعه ویژگی بهینه			
A_luen	H(1-A)	HA	H_shannon
RVI	SERD	$[T]_{12pha}$	$[Bar]_{13mod}$
$[Bar]_{13pha}$	$[Clou]_{13pha}$	$[Bar]_{22mod}$	$[Clou]_{33mod}$
$[Touzi]_{psi}$	$[Vanzyl]_{odd}$	$[Krog]_{kh}$	$[pow]_{max}$

راه‌حل‌های پارتو نشان داده شده در شکل ۴-۷ با استفاده از MOGA-ANFIS در جدول ۴-۵ ارائه شده است.

جدول ۴-۵. دقت کلی و ضریب کاپا به ازای ترکیبات مختلف ویژگی‌های بهینه در الگوریتم MOGA-ANFIS

تعداد ویژگی	کاپا	دقت کلی (%)	زیرمجموعه ویژگی‌های بهینه	راه‌حل
۲۱	۰/۹۷	۹۷/۷۸	A_luen H_shannon RVI SERD	۱
			$[Bar]_{12mod}$ $[Free]_{vol}$ $[Clou]_{13pha}$ $[Clou]_{22mod}$	
			$[T]_{23mod}$ $[Holm]_{23pha}$ $[Holm]_{33mod}$ $[Touzi]_{alpha}$	
			$[Touzi]_{psi}$ $[Vanzyl]_{vol}$ $[Yama]_{vol}$ $[S]_{12}$	

	[S] ₂₂	[Krog] _{kh}	[Krog] _{ks}	[dop] _{min}			
	Ro13						
۲	alpha	A	H_shannon	[Free] _{vol}	۹۷/۳	۰/۹۶۴	۱۴
	[Bar] _{13pha}	[T] _{23mod}	[Holm] _{13mod}	[Huy] _{22mod}			
	[Vanzyl] _{vol}	[Yama] _{vol}	[S] ₁₂	[Krog] _{kh}			
	[dop] _{min}	[scat] _{min}					
۳	A12	[Free] _{vol}	RVI	SERD	۹۶/۱۱	۰/۹۵	۱۳
	[T] _{23mod}	[Holm] _{12mod}	[Vanzyl] _{vol}	[S] ₁₂			
	[S] ₂₂	[Krog] _{kh}	[dop] _{max}	[scat] _{min}			
	[unpol] _{min}						
۴	A12	DERD	[Free] _{vol}	lambda	۹۵/۸۷	۰/۹۴۵	۱۰
	[T] _{23pha}	[Holm] _{11mod}	[Clou] _{13mod}	[Vanzyl] _{vol}			
	[Yama] _{vol}	[unpol] _{min}					

با توجه به جدول ۴-۵ و بررسی‌های انجام شده راه‌حل با ۱۴ ویژگی به عنوان ترکیب ویژگی‌های PolSAR بهینه با استفاده از الگوریتم MOGA-ANFIS انتخاب شد.

در جدول ۴-۶ ماتریس خطای^۱ روش GASVM و در جدول ۴-۷ و جدول ۴-۸ ماتریس خطای دو روش چندهدفه حاصل مقایسه پیکسل به پیکسل داده‌های مرجع و نتایج طبقه‌بندی نشان داده شده است. ستون‌های این ماتریس معرف داده‌های مرجع و سطرهای آن بیانگر نتایج طبقه‌بندی است. با توجه به این جداول می‌توان دریافت که هر دو روش چندهدفه از دقت بالایی برای مجموعه داده تست برخوردارند، ولی با این وجود سیستم ANFIS نتایج بهتری بویژه در کلاس جاده ارائه می‌دهد که این می‌تواند به علت قابلیت ANFIS در استخراج دانش از اطلاعات عددی باشد. لازم به ذکر است

¹ confusion matrix

که استفاده از ANFIS در فرآیند انتخاب ویژگی هزینه محاسباتی نسبتاً بالاتری در مقایسه با بکارگیری SVM به دنبال داشت.

جدول ۴-۶. ماتریس خطای طبقه‌بندی، دقت تولیدکننده، دقت کاربر، دقت کلی و ضریب کاپا در GASVM

دقت تولیدکننده (%)	جاده	پوشش گیاهی	ساختمان	آب	کلاس
۱۰۰	۰	۰	۰	۳۱۲	آب
۹۹/۲۹	۳۰	۹	۲۷۹	۰	ساختمان
۸۶/۸۳	۱	۳۱۰	۰	۰	پوشش گیاهی
۹۰	۲۷۹	۳۸	۲	۰	جاده
	۸۷/۴۶	۹۹/۶۸	۸۷/۷۴	۱۰۰	دقت کاربر (%)
دقت کلی: ۹۳/۶۵ درصد ضریب کاپا: ۰/۹۱۵					


جدول ۴-۷. ماتریس خطای طبقه‌بندی، دقت تولیدکننده، دقت کاربر، دقت کلی و ضریب کاپا حاصل از راه‌حل انتخابی در MOGA-SVM

دقت تولیدکننده (%)	جاده	پوشش گیاهی	ساختمان	آب	کلاس
۱۰۰	۰	۰	۰	۳۱۲	آب
۹۹	۱۶	۶	۲۹۶	۰	ساختمان
۹۰/۸۸	۲	۳۰۹	۰	۰	پوشش گیاهی
۹۴/۱۷	۲۹۱	۲۵	۳	۰	جاده
	۹۱/۲۲	۹۹/۳۶	۹۳/۰۸	۱۰۰	دقت کاربر (%)
دقت کلی: ۹۵/۸۷ درصد ضریب کاپا: ۰/۹۴۵					


جدول ۸-۴. ماتریس خطای طبقه‌بندی. دقت تولید کننده، دقت کاربر، دقت کلی و ضریب کاپا حاصل از راه‌حل انتخابی در MOGA-ANFIS

دقت تولیدکننده (%)	جاده	پوشش گیاهی	ساختمان	آب	کلاس
۱۰۰	۰	۰	۰	۳۱۲	آب
۹۷/۷۳	۰	۱۷	۳۰۱	۰	ساختمان
۹۲/۷۷	۳	۳۰۸	۰	۰	پوشش گیاهی
۹۹/۰۳	۳۰۵	۷	۷	۰	جاده
	۹۵/۶۱	۹۹/۰۳	۹۴/۶۵	۱۰۰	دقت کاربر (%)
دقت کلی: ۹۷/۳ درصد ضریب کاپا: ۰/۹۶۴					

نقشه طبقه‌بندی نهایی حاصل از راه‌حل انتخابی در MOGA-SVM و MOGA-ANFIS و نحوه نمایش رنگی کلاس‌های طبقه‌بندی شده به ترتیب در شکل ۸-۴ و شکل ۹-۴ نمایش داده شده است.




شکل ۸-۴. نتیجه طبقه‌بندی نهایی حاصل از MOGA-SVM




شکل ۴-۹. نتیجه طبقه‌بندی نهایی حاصل از MOGA-ANFIS

شکل ۴-۱۰ و شکل ۴-۱۱ مقایسه روش‌های چندهدفه و سایر روش‌ها را به ترتیب از نظر دقت طبقه‌بندی و تعداد ویژگی‌های PolSAR ارائه می‌دهد. در کل نتایج نشان می‌دهد که روش‌های چندهدفه عملکرد بهتری از جهات مختلف دارند. در راه‌حل انتخابی، MOGA-SVM به ۱۶ ویژگی و MOGA-ANFIS به ۱۴ ویژگی رسیده است که علاوه بر کاهش تعداد ویژگی‌های بهینه بهبود دقت طبقه‌بندی را نیز در مقایسه با سایر روش‌ها به دنبال داشته است.



شکل ۴-۱۰. مقایسه روش‌های مختلف طبقه‌بندی از نظر دقت کلی



شکل ۴-۱۱. مقایسه روش‌های مختلف طبقه‌بندی از نظر تعداد ویژگی

۴-۴ سایر تحقیقات انجام شده با استفاده از ویژگی‌ها و الگوریتم‌های مختلف بر روی تصویر پلاریمتریک منطقه شهری سانفرانسیسکو

شکل ۴-۱۲ نتیجه طبقه‌بندی بدست آمده توسط Zhang و همکاران در سال ۲۰۰۹ را نشان می‌دهد. آن‌ها با استفاده از یک طبقه‌بندی‌کننده تلفیقی از PCA و شبکه عصبی منطقه را به ۳ کلاس پوشش گیاهی (رنگ آبی)، شهری (رنگ سبز) و آب (رنگ قرمز) طبقه‌بندی کردند. تصویر مورد استفاده از سنجنده AirSAR در باند L و پارامترهای تجزیه Cloude-Pottier از جمله ویژگی‌های PolSAR بکار رفته می‌باشد. در این تحقیق با وجود تعداد کلاس‌های کم و اندازه مجموعه آموزشی بزرگ (بیش از ۲۶۰۰۰ پیکسل)، آشکار است که بخش‌های زیادی در منطقه به اشتباه طبقه‌بندی شده است.




شکل ۴-۱۲. نتیجه طبقه‌بندی‌کننده ترکیبی از PCA و شبکه عصبی (Zhang et al., 2009)

در سال ۲۰۱۲، Kiranyaz و همکاران با استفاده از روشی مبتنی بر شبکه جمعی از طبقه‌بندی‌کننده‌های باینری و ویژگی‌هایی مانند پارامترهای ماتریس همبستگی و ماتریس کواریانس استخراج شده از تصویر سنجنده AirSAR تفکیک کلاس‌های آب (فیروزه‌ای)، شهری (بنفش)، جنگل (زرد)، مناطق هموار (سبز) و کوه/صخره (آبی) را مورد بررسی قرار دادند. نتیجه حاصل از این تحقیق در شکل ۴-۱۳ ارائه شده است.




شکل ۴-۱۳. نتیجه حاصل از روش پیشنهادی در (Kiranyaz *et al.*, 2012)

نتیجه بدست آمده از روش ترکیبی شبکه‌های عصبی با تابع پایه شعاعی (RBF) و الگوریتم بهینه‌سازی ازدحام ذرات (PSO) ارائه شده توسط Ince و همکاران (2012) به منظور طبقه‌بندی تصویر پلاریمتریک سنجنده AirSAR در شکل ۴-۱۴ نشان داده شده است. همان‌طور که مشاهده می‌شود ۳ کلاس آب، شهری و پوشش گیاهی با استفاده از روش پیشنهادی از یکدیگر تفکیک شده‌اند.



شکل ۴-۱۴. نتیجه طبقه‌بندی‌کننده ترکیبی از PSO و شبکه عصبی RBF (Ince *et al.*, 2012)

در سال ۲۰۱۱، Haddadi و همکاران روشی بر مبنای الگوریتم ژنتیک و شبکه‌های عصبی MLP در انتخاب بهترین ویژگی‌ها از ۵۷ پارامتر استخراج شده از تصویر سنجنده AirSAR پیشنهاد کردند. نقشه نهایی در شکل ۴-۱۵ ارائه شده است.




شکل ۴-۱۵. نتیجه طبقه‌بندی‌کننده ترکیبی از GA و MLP (Haddadi et al., 2011)

همان‌طور که مشاهده شد، مقایسه نتایج بدست آمده در این پایان‌نامه و تحقیقات پیشین نشان‌دهنده عملکرد بسیار خوب روش‌های ارائه شده در طبقه‌بندی منطقه شهری سانفرانسیسکو و همچنین پتانسیل اطلاعاتی بالای داده پلاریمتریک رادارست ۲ می‌باشد. در این تحقیق علاوه بر تفکیک مناسب کلاس‌های پوششی مختلف در مقایسه با تحقیقات قبلی به نتایج خوبی نیز در تشخیص کلاس جاده از تصاویر پلاریمتریک رسیدیم.

۴-۵ تحلیل و بررسی برخی ویژگی‌های بهینه انتخاب شده در طبقه‌بندی پوشش زمین شهری



به دلیل ماهیت تصادفی الگوریتم ژنتیک، در دفعات مختلف اجرای الگوریتم‌ها، مجموعه ویژگی‌های کاملاً مشابه حاصل نخواهد شد، اما مجموعه ویژگی‌های بدست آمده تقریباً معادل با یکدیگر هستند. با محاسبه فراوانی ویژگی‌ها در تکرارهای مختلف الگوریتم‌های چندهدفه می‌توان ویژگی‌هایی را که اطلاعات خوبی برای طبقه‌بندی دارند مشخص کرد. در واقع بهترین ویژگی‌ها در بیشتر دفعات اجرای الگوریتم و در اغلب راه‌حل‌های ارائه شده در جبهه پارتو ظاهر می‌شود. مطابق این نتایج با استفاده از الگوریتم MOGA-SVM، ویژگی‌های انتروپی شانون، SERD، HA، RVI، $[Bar]_{13mod}$ ، $[Krog]_{Kh}$ ، $[Bar]_{13pha}$ ، $[pow]_{max}$ ، $[dop]_{max}$ و با استفاده از الگوریتم MOGA-ANFIS، انتروپی شانون، α ، $[S]_{12}$ ، $[Vanzyl]_{vol}$ ، $[Krog]_{Kh}$ ، $[S]_{22}$ ، $[pow]_{min}$ ویژگی‌های بهینه برای طبقه‌بندی منطقه سانفرانسیسکو می‌باشند. این ویژگی‌ها در شکل ۴-۱۶ و شکل ۴-۱۷ نشان داده شده است.




SERD





H_shannon


[Bar]_{13mod}

HA





RVI

[Krog]_{Kh}



شکل ۴-۱۶. ویژگی‌های پلاریمتریک بهینه حاصل از MOGA-SVM برای طبقه‌بندی پوشش زمین





شکل ۴-۱۷. برخی ویژگی‌های پلاریمتریک بهینه حاصل از MOGA-ANFIS در طبقه‌بندی پوشش زمین

در ادامه به بررسی تعدادی از این ویژگی‌ها پرداخته خواهد شد. همان‌طور که در شکل ۴-۱۶ و شکل ۴-۱۷ مشاهده می‌شود هر یک از ویژگی‌ها می‌توانند یک یا بیشتر از یک کلاس را از سایر کلاس‌ها تفکیک کنند. با بکارگیری تعدادی ویژگی می‌توان از توان تفکیک‌پذیری هر کدام از آن‌ها استفاده کرد و از طرفی نقاط ضعف آن‌ها را با ویژگی‌های دیگر جبران کرد و نهایتاً عملکرد طبقه‌بندی کلی را بهبود بخشید.

در طبقه‌بندی براساس زیرمجموعه ویژگی بهینه علاوه بر تعیین انواع کلاس‌های پوششی زمین در منطقه، درک ماهیت فیزیکی ویژگی‌ها برحسب مکانیزم‌های پراکندگی از کلاس‌های مختلف اهمیت زیادی دارد. هر یک از ویژگی‌ها می‌تواند اطلاعات خاصی را از مکانیزم‌های پراکندگی ارائه دهد.

در الگوریتم MOGA-SVM، ویژگی‌های حاصل از تجزیه Cloude-Pottier عملکرد خوبی را از خود نشان دادند. این الگوریتم تجزیه به فرض توزیع آماری خاصی وابسته نیست و محدودیت‌های فیزیکی اعمال شده توسط مدل‌های چند متغیره را ندارد (Lee and Pottier, 2009). انتروپی شانون ($H_{shannon}$) یکی از این ویژگی‌ها می‌باشد که غالباً در تکرارهای مختلف و در همه الگوریتم‌ها در مجموعه ویژگی بهینه ارائه می‌شود. همان‌طور که در شکل ۴-۱۶ نیز مشاهده می‌شود، انتروپی شانون ویژگی مناسبی برای تشخیص مرزها و تغییرات بین کلاس‌ها می‌باشد و می‌تواند عملکرد خوبی در

استخراج راه از تصاویر PolSAR داشته باشد.

اختلاف نسبی مقادیر ویژه تک انعکاسی (SERD) که از تجزیه مقادیر ویژه ماتریس همبستگی با در نظر گرفتن فرض تقارن انعکاسی بدست می‌آید به مشخصه‌های محیط طبیعی مانند زبری سطح حساس است. SERD پارامتری مهم برای محیط با انتروپی زیاد، به منظور تعیین ماهیت و اهمیت مکانیزم‌های پراکندگی مختلف می‌باشد. ویژگی HA با داشتن ترکیبی از اطلاعات انتروپی (H) و ناهمسانگردی (A)، توصیف‌کننده دو مکانیزم پراکندگی با احتمال یکسان است. شاخص گیاهی رادار (RVI) که برای آنالیز پراکندگی مناطق گیاهی استفاده می‌شود، در این تحقیق برای تفکیک منطقه پوشش گیاهی از سایر کلاس‌ها انتخاب شده است.

با قرار گرفتن مولفه فاز المان سطر اول و ستون سوم تجزیه Barnes ([Barnes]_{13pha}) در بین ویژگی‌های بهینه، نشان داده شد که اختلاف فاز دو کانال در رادار پلاریمتری نیز می‌تواند به عنوان ویژگی در طبقه‌بندی بکار گرفته شود.

این مطالعه نشان داد که، علاوه بر اینکه یک تجزیه هدف ناهمدوس مانند Barnes عملکرد خوبی در طبقه‌بندی دارد، ویژگی‌های تجزیه همدوس مانند پراکندگی helix از تجزیه Krogager (Kh) نیز، که بر روی تک پیکسل‌ها عمل می‌کنند، می‌توانند اطلاعات مفیدی برای طبقه‌بندی پوشش زمین فراهم کنند. مولفه helix که اولین بار توسط Krogager معرفی شد، برای توصیف مناطقی با لبه‌ها و گوشه‌های تیز^۱ مانند سازه‌های ساخت بشر استفاده می‌شود. این مولفه نوعی پراکندگی چندگانه از پرش جلو و عقب بین ساختمان‌های بلند است که نهایتاً به سمت ماهواره برمی‌گردد. همچنین این مولفه مربوط به فرض عدم تقارن انعکاسی^۲ می‌باشد که غالباً در مناطق شهری پیچیده رخ می‌دهد و تقریباً برای پراکنده‌سازهای غیرمنفرد طبیعی وجود ندارد. بنابراین، این ویژگی برای توصیف اهداف ساخت بشر در منطقه شهری مناسب است. همان‌طور که در شکل ۴-۱۶ نیز مشاهده می‌شود، تصویر Kh پاسخ روشنی را در منطقه شهری نشان می‌دهد.

بحث مهم مطرح در مناطق شهری برقرار نبودن فرض تقارن انعکاسی است. همان‌طور که قبلاً نیز

^۱ sharp

^۲ non-reflection symmetric

به آن اشاره شد فرض تقارن انعکاسی در محیط‌های طبیعی برقرار است و براساس آن وابستگی بین پاسخ‌های copol و crosspol نزدیک به صفر می‌باشد ($\langle S_{HH}S_{HV}^* \rangle \approx \langle S_{HV}S_{VV}^* \rangle$). از آنجا که طبقه‌بندی پوشش زمین در این تحقیق بر روی منطقه‌ای شهری انجام شده است وجود ویژگی‌هایی مانند پراکندگی helix برای در نظر گرفتن وابستگی‌های copol و crosspol در این مناطق ضروری است.

ماکزیمم توان دریافتی ($[pow]_{max}$) و ماکزیمم درجه پلاریزاسیون ($[dop]_{max}$) به عنوان تفکیک‌کننده‌های PolSAR انتخاب شده‌اند. مناطقی که تراکم ساختمانی بالاتری دارند (سمت راست منطقه) مقادیر بالای $[pow]_{max}$ را به خود اختصاص داده‌اند. منطقه شهری، که در آن بخش زیادی از سطح زمین بوسیله جاده‌ها و ساختمان‌ها پوشیده شده است و کلاس آب مقدار درجه پلاریزاسیون بالایی دارند، به این علت که در این مناطق پراکندگی تک انعکاسی و دو انعکاسی غالب هستند. از طرفی، به علت تاثیرات پراکندگی چندگانه، منطقه با پوشش گیاهی متراکم مقادیر درجه پلاریزاسیون پائینی دارد.

ویژگی‌های بهینه حاصل از الگوریتم MOGA-ANFIS، ترکیبی از پارامترهای فیزیکی (مانند پراکندگی حجمی از تجزیه VanZyl) و پارامترهای ریاضی (مانند ویژگی α از تجزیه Cloude-Pottier) هستند.

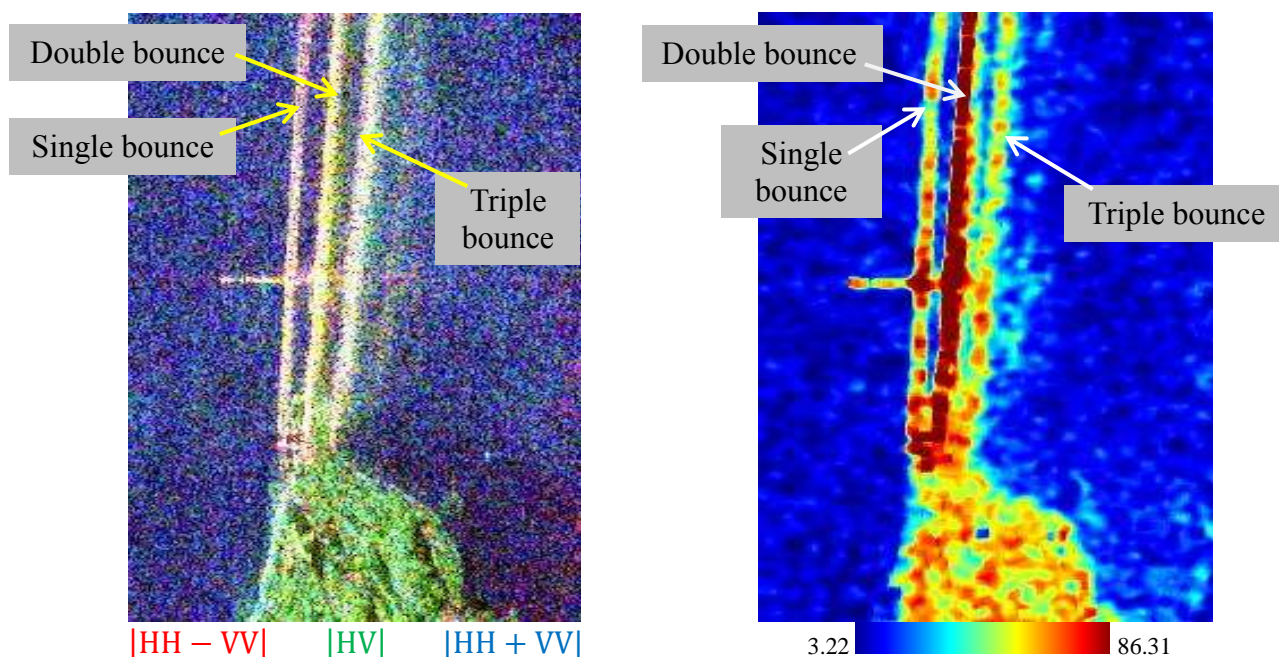
ویژگی‌های با پراکندگی حجمی غالباً در بین ویژگی‌های انتخابی برای تفکیک مناطق با پوشش گیاهی متراکم مانند پارک Golden Gate (نوار مستطیلی بزرگ در پائین تصویر) و پوشش‌های گیاهی اطراف ساختمان‌ها ارائه می‌شود.

ویژگی α نوع مکانیزم پراکندگی را مشخص می‌کند. به طور کلی در مناطق شهری و پارک‌ها مقادیر متوسط و زیاد و در اقیانوس‌ها به علت پراکنش غالب سطحی مقدار کم این ویژگی ارائه شده است. از آنجا که در این تحقیق ویژگی α عملکرد بسیار خوبی داشت، در ادامه به بررسی این ویژگی در محدوده پل Golden Gate واقع شده در قسمت شمالی تصویر پرداخته شده است.

پل‌ها یکی از المان‌های اصلی شهرها محسوب می‌شوند و پایش این بخش‌های ارتباطی مهم برای


بسیاری از کاربردها مانند مدیریت بحران ضروری است. استخراج ساختار پل در داده SAR با قابلیت تصویربرداری در شرایط آب و هوایی مختلف و در طول شبانه روز می‌تواند موضوع مهمی در کاربردهای نظامی و عمرانی باشد. در حالتی که پل‌ها روی آب قرار گرفته باشند انواع مختلفی از پراکندگی می‌تواند رخ دهد. در این حالت معمولاً سه ساختار موازی شامل پراکندگی تک انعکاسی (انعکاس مستقیم)، دو انعکاسی (بین پل و آب و یا برعکس)، و نهایتاً بازتاب سه‌گانه^۱ (آب، بخش‌های پائینی پل و مجدداً آب) که پراکندگی متوسطی از مولفه‌های تک انعکاسی و دو انعکاسی را ارائه می‌دهد، مشاهده می‌شود. در بعضی مواقع المان‌هایی مانند پایه‌های پل نیز قابل شناسایی هستند.

در شکل ۴-۱۸ ویژگی alpha به همراه سه مکانیزم پراکندگی در محدوده پل Golden Gate و در شکل ۴-۱۹ نتیجه طبقه‌بندی نهایی این پل با استفاده از الگوریتم MOGA-ANFIS نشان داده شده است.



شکل ۴-۱۸. پل Golden Gate. سمت راست: ویژگی آلفا، سمت چپ: ترکیب رنگی Pauli

^۱ triple reflection



شکل ۴-۱۹. نتیجه طبقه‌بندی پل در MOGA-ANFIS

علاوه بر ارتباط صحیح نوع مکانیزم پراکندگی تعیین شده توسط ویژگی α و نتیجه طبقه‌بندی ارائه شده برای پل Golden Gate، بررسی‌ها حاکی از پتانسیل اطلاعاتی بالای این ویژگی در قسمت‌های دیگر تصویر نیز می‌باشد. در شکل ۴-۱۹، منطقه اطراف آب در سمت چپ به رنگ قرمز مشاهده می‌شود که نشان‌دهنده سهم بیشتر پراکندگی دو انعکاسی (سطح آب و ساقه گیاهان آبی که بالای خط آب رشد می‌کنند) نسبت به مکانیزم‌های پراکندگی دیگر است. این منطقه به علت شباهت پراکندگی با ساختمان در این کلاس قرار گرفته است.

فصل پنجم: نتیجه گیری و پیشنهادات

۵-۱ بحث و نتیجه‌گیری

با توجه به اینکه طبقه‌بندی پوشش زمین یکی از کاربردهای مهم تصاویر پلاریمتریک SAR محسوب می‌شود، در این پایان‌نامه پتانسیل داده پلاریمتریک رادارست ۲ به منظور بهبود طبقه‌بندی پوشش زمین در منطقه شهری مورد بررسی قرار گرفت. در این راستا، تعیین ویژگی‌های بهینه PolSAR از تصویر منطقه شهری سانفرانسیسکو در قالب روش‌های بهینه‌سازی تک‌هدفه و چندهدفه انجام گرفت.

ابتدا الگوریتم‌های تک‌هدفه GMLP و GASVM با حداکثرسازی دقت طبقه‌بندی مورد بررسی قرار گرفت. سپس الگوریتم‌های چندهدفه با بهینه‌سازی دقت طبقه‌بندی و تعداد ویژگی‌های انتخابی ارائه شد. در الگوریتم‌های پیشنهادی بهترین ویژگی‌ها بر مبنای توابع هدف از میان ۱۰۵ ویژگی پلاریمتری انتخاب و برای طبقه‌بندی تصویر استفاده شد.

پس از استخراج بهترین پارامترها، عمل طبقه‌بندی با پارامترهای بدست آمده انجام گرفت. نتایج حاصل از الگوریتم‌های تک‌هدفه نشان داد که SVM در مقایسه با MLP عملکرد بهتری هم از نظر دقت و هم از نظر هزینه محاسباتی به دنبال دارد. لازم به ذکر است که هزینه محاسباتی بالای بکارگیری MLP در نتیجه استفاده از الگوریتم آموزشی گرادیان مینا و تعداد زیاد نرون‌های ورودی برابر با ویژگی‌های انتخابی می‌باشد. در الگوریتم‌های GMLP و GASVM به ترتیب متوسط دقت ۸۷/۳۸ و ۹۳/۶۵ به ازای ۵۶ و ۳۷ ویژگی PolSAR حاصل شد.

مقایسه GASVM و SVM با مجموعه ویژگی کامل نشان داد کاهش ابعاد فضای ویژگی ورودی، کارایی یادگیری طبقه‌بندی‌کننده SVM را بهبود می‌دهد.

در ادامه الگوریتم‌های چندهدفه برای بهبود روش‌های تک‌هدفه هم از نظر دقت و هم از نظر تعداد ویژگی‌های بهینه، بکار گرفته شدند. روش‌های پیشنهادی مجموعه‌ای از راه‌حل‌های نامغلوب تحت عنوان جبهه بهینه پارتو ارائه کردند که منجر به برقراری بهترین تعادل بین تعداد ویژگی‌های PolSAR، دقت طبقه‌بندی و هزینه محاسباتی شد.

برای الگوریتم MOGA-SVM تعداد ویژگی ۱۶ و دقت کلی ۹۵/۸۷ و برای الگوریتم MOGA-

ANFIS تعداد ویژگی ۱۴ و دقت کلی ۹۷/۳ حاصل شد. نتایج حاصل مؤید این مطلب است که علاوه بر توانایی تفکیک بالای SVM در طبقه‌بندی تصاویر PolSAR که در تحقیقات قبلی نیز به اثبات رسیده بود، طبقه‌بندی‌کننده ANFIS هم، حتی در ابعاد داده‌های ورودی زیاد، می‌تواند عملکرد مناسبی در طبقه‌بندی تصاویر پلاریمتریک داشته باشد.

مقایسه MOGA-SVM و MOGA-ANFIS از نظر هزینه محاسباتی نشان داد که استفاده از SVM به دلیل بکارگیری FCM در سیستم ANFIS به صرفه‌تر است. همچنین به طور کلی در این تحقیق، الگوریتم‌هایی که در آن‌ها از طبقه‌بندی‌کننده SVM استفاده شده است با توجه به زمانبر بودن تشکیل مدل در شبکه عصبی، بسیار سریع‌تر عمل می‌کنند.

مقایسه نتایج حاصل از الگوریتم‌های چندهدفه با دیگر الگوریتم‌ها نشان داد که روش‌های چندهدفه علاوه بر افزایش دقت، کاهش تعداد ویژگی‌های بهینه حاصل و در نتیجه کاهش هزینه محاسباتی را نیز به دنبال خواهند داشت. بنابراین اطلاعات زیاد لزوماً بهترین نتایج را فراهم نمی‌کنند.

با محاسبه فراوانی ویژگی‌ها در تکرارهای مختلف الگوریتم‌های چندهدفه مناسب‌ترین ویژگی‌های PolSAR بدست آمد و نشان داده شد که برخی ویژگی‌ها تاثیر قابل توجه‌تری در تشخیص اهداف طبیعی و ساخت بشر دارند. مطابق این نتایج با استفاده از MOGA-SVM ویژگی‌های انتروپی شانون، SERD، HA، RVI، پراکندگی helix از تجزیه Krogager، دامنه و فاز المان سطر اول و ستون سوم تجزیه Barnes، و مولفه ماکزیمم توان دریافتی و درجه پلاریزاسیون و با استفاده از MOGA-ANFIS، انتروپی شانون، alpha، المان سطر اول و ستون دوم ماتریس پراکندگی، پراکندگی حجمی از تجزیه VanZyl، پراکندگی helix از تجزیه Krogager، المان آخر ماتریس پراکندگی، و مولفه مینیمم توان دریافتی در تکرارهای مختلف بدست آمدند که ویژگی‌های مناسب برای طبقه‌بندی می‌باشند.

با توجه به زمانبر بودن انتخاب داده‌های آموزشی ترجیح داده می‌شود که الگوریتم مورد استفاده به کمترین داده آموزشی نیاز داشته باشد. الگوریتم‌های پیشنهادی علاوه بر توانایی رویارویی با ابعاد زیاد فضای ورودی در طبقه‌بندی، به داده‌های آموزشی زیادی نیازمند نیست.

با استفاده از این تحقیق نشان داده شد که داده پلاریمتریک رادارست ۲ در باند C نتایج خوبی را

در طبقه‌بندی پوشش زمین منطقه شهری از خود نشان می‌دهد. همچنین با توجه به نتایج، الگوریتم عملکرد خوبی در تشخیص ساختمان و جاده در محیط پیچیده شهری دارد. دو کلاس جاده و آب با وجود شباهت‌های پراکندگی زیاد قابل تفکیک با داده رادارست ۲ بوسیله الگوریتم‌های پیشنهادی هستند. علاوه بر شناسایی مناطق جنگلی، الگوریتم‌ها پتانسیل خوبی در تمییز پوشش‌های گیاهی اطراف ساختمان‌ها دارند.

۵-۲ پیشنهادات

با توجه به نتایج حاصل از این تحقیق پیشنهاداتی به شرح زیر برای کارهای آینده ارائه می‌گردد. در این تحقیق از تصویر پلاریمتری فضا برد سنجنده رادارست ۲ استفاده شد. در سال‌های اخیر با پرتاب موفقیت‌آمیز ماهواره‌های پلاریمتری مانند TerraSAR-X، پلاریمتری وارد عرصه جدیدی با داده‌های وسیع در باند X شده است. باند X (در صورت وجود داده پلاریمتری) با داشتن فرکانس بالا می‌تواند جزئیات دقیق‌تر و بیشتری را از سطح عوارض فراهم آورد. بنابراین پیشنهاد می‌شود علاوه بر تست الگوریتم‌های پیشنهادی روی تصاویر دیگری از ماهواره رادارست ۲ در مناطق شهری، کشاورزی و ... عملکرد الگوریتم‌ها در تصویری از این باند نیز مورد آزمون قرار گیرد. همچنین مقایسه طبقه‌بندی داده‌های پلاریمتری در سه باند L، C و X می‌تواند مد نظر قرار گیرد.

با توجه به قرار گرفتن زمین‌های با پوشش گیاهی کم (مانند زمین ورزشی در پارک Golden Gate)، در کلاس پوشش گیاهی (شامل جنگل و پوشش‌های گیاهی متراکم) با استفاده از الگوریتم MOGA-SVM، و در کلاس جاده با استفاده از الگوریتم MOGA-ANFIS برای شناسایی این زمین‌ها پیشنهاد می‌شود کلاس‌ها به تعداد بیشتری افزایش یابد و کارایی الگوریتم‌ها با تعداد کلاس بیشتر مورد بررسی قرار گیرد.

از آنجا که ویژگی‌های پلاریمتریک اینترفرومتری راداری (POLInSAR) می‌توانند اطلاعات مربوط به ساختار و پیچیدگی عوارض را به خوبی فراهم کنند، و ویژگی‌های texture ممکن است تغییرپذیری مکانی یک کلاس زمینی خاص را بهتر ارائه دهند، وارد کردن این ویژگی‌ها نیز در فرآیند طبقه‌بندی یک مسیر باز پژوهشی است که می‌تواند در آینده مورد توجه قرار گیرد.

عملکرد الگوریتم‌های تکاملی مانند GA وابستگی زیادی به پارامترهای آن دارد. معمولاً راه‌حل دقیق و مناسبی برای تنظیم این پارامترها در دسترس نیست و این کار با سعی و خطا صورت می‌گیرد که موجب اتلاف وقت می‌شود. استفاده از ابزارهای فازی جهت رفع این مشکل پیشنهاد می‌شود.

معمولاً ارزیابی کیفیت نقشه طبقه‌بندی با استفاده از معیارهای بدست آمده از ماتریس خطا انجام می‌شود. متأسفانه این معیارها اطلاعاتی راجع به تغییرپذیری مکانی در کیفیت طبقه‌بندی فراهم نمی‌کنند. آگاهی از عدم قطعیت داده پوشش زمینی امکان تفسیر بهتری از نتایج روش‌های طبقه‌بندی را فراهم می‌کنند. علاوه بر این استفاده از نقشه‌های عدم قطعیت برای پس پردازش نتایج طبقه‌بندی می‌تواند بهبود نقشه‌های طبقه‌بندی را فراهم آورد. بنابراین پیشنهاد می‌شود با بکارگیری SVM احتمالاتی و معیارهای عدم قطعیت، میزان قطعیت نتایج دو طبقه‌بندی‌کننده SVM و ANFIS مورد ارزیابی قرار گیرد.

مراجع

صالحی، م.، ۱۳۹۱. بررسی و ارزیابی استخراج پارامترهای مستقل از داده‌های پلاریمتری راداری، سمینار کارشناسی ارشد، گروه مهندسی سنجش از دور، دانشکده‌ی مهندسی نقشه‌برداری، دانشگاه صنعتی خواجه نصیرالدین طوسی.

- Ainsworth, T., Cloude, S., and Lee, J. 2002, Eigenvector analysis of polarimetric SAR data. *Geoscience and Remote Sensing Symposium, IGARSS '02. 2002 IEEE International*, vol.1, pp. 626 - 628.
- Alberga, V., Krogager, E., Chandra, M., and Wanielik, G. 2004, Potential of coherent decompositions in SAR polarimetry and interferometry. *Geoscience and Remote Sensing Symposium, IGARSS '04. Proceedings. 2004 IEEE International*, vol.3, pp. 1792 - 1795.
- Allain, S., Ferro-Famil, L., and Pottier, E. 2004, Two novel surface model based inversion algorithms using multi-frequency polSAR data. *Geoscience and Remote Sensing Symposium, IGARSS '04. Proceedings. 2004 IEEE International*, 2, pp. 823-826.
- Atkinson, P.M., Tatnall, A.R.L. 1997, Neural Networks in Remote Sensing, *Int. J. Remote Sens.*, vol 18, no. 4, pp. 699-709.
- Ban, Y., and Hu, H. 2007, RADARSAT Fine-Beam SAR Data for Land-Cover Mapping and Change Detection in the Rural-Urban Fringe of the Greater Toronto Area. *Proceedings, Urban Remote Sensing Joint Event, 2007*.
- Barnes, R. M. 1988, Roll invariant decompositions for the polarization covariance matrix. *Proceeding of the polarimetric technology workshop*.
- Bezdek, J.C. 1981, Pattern Recognition with Fuzzy Objective Function Algorithms, Kluwer Academic Pub, MA, USA.
- Bishop, C. M. 1996, *Neural Networks for Pattern Recognition*. Oxford University Press, USA.
- Borgeaud, M., Nghiem, S., Shin, R., and Kong, J. 1989, Theoretical Models for Polarimetric Microwave Remote Sensing of Earth Terrain. *Journal of Electromagnetic Waves and Applications*, 3(1), 61-81.
- Burges, C. J. 1998, A Tutorial on Support Vector Machines for Pattern Recognition. *Data Mining and Knowledge Discovery*, 2, 121-167.
- Carlos, Alan, C., and Christiansen, A. D. 2000, Multiobjective Optimization of Trusses using Genetic Algorithms. *Computers and Structures*, 75, 647-660.
- Chang, G., and Oh, Y. 2007, Polarimetric SAR Image Classification Based on the Degree of Polarization and Co-polarized Phase-Difference Statistics. *Microwave Conference, APMC 2007. Asia-Pacific*, pp. 1-4.

- Chen, C., Chen, K., and Lee, J. 2003, The use of fully polarimetric information for the fuzzy neural classification of SAR images. *Geoscience and Remote Sensing, IEEE Transactions on*, 41(9), 2089-2100.
- Cloude, S. 1985, Radar target decomposition theorems. *Institute of Electrical Engineering and Electronics Letter*, 21(1), 22-24.
- Cloude, S., and Pottier, E. 1996, A review of target decomposition theorems in radar polarimetry. *Geoscience and Remote Sensing, IEEE Transactions on*, 34(2), 498-518.
- Cloude, S., and Pottier, E. 1997, An entropy based classification scheme for land applications of polarimetric SAR. *Geoscience and Remote Sensing, IEEE Transactions on*, 35(1), 68-78.
- Dash, M., and Liu, H. 2003, Consistency-based search in feature selection. *Artificial Intelligence*, 151, 155-176.
- Deb, K., Pratap, A., Agarwal, S., and Meyarivan, T. 2002, A fast and elitist multiobjective genetic algorithm: NSGA-II. *Trans. Evol. Comp*, 6(2), 182-197.
- Durden, S., van Zyl, J., and Zebker, H. 1989, Modeling and observation of the radar polarization signature of forested areas. *Geoscience and Remote Sensing, IEEE Transactions on*, 27(3), 290-301.
- Durden, S., van Zyl, J., and Zebker, H. 1990, The unpolarized component in polarimetric radar observations of forested areas. *Geoscience and Remote Sensing, IEEE Transactions on*, 28(2), 268-271.
- Elachi, C., and van Zyl, J. 2006, *Introduction To The Physics and Techniques of Remote Sensing*. John Wiley and Sons.
- Emmanouilidis, C., Hunter, A., MacIntyre, J. 2000, A multiobjective evolutionary setting for feature selection and a commonality-based crossover operator, *Proc Congress on Evol Comput*, vol. 1, pp 309-316.
- Evans, D., Farr, T., van Zyl, J., and Zebker, H. 1988, Radar polarimetry: analysis tools and applications. *Geoscience and Remote Sensing, IEEE Transactions on*, 26(6), 774-789.
- Ferro-Famil, L., Pottier, E., and Lee, J. 2001, Unsupervised classification of multifrequency and fully polarimetric SAR images based on the H/A/Alpha-Wishart classifier. *Geoscience and Remote Sensing, IEEE Transactions on*, 39(11), 2332-2342.
- Foody, G., and Mathur, A. 2004, A relative evaluation of multiclass image classification by support vector machines. *Geoscience and Remote Sensing, IEEE Transactions on*, 42(6), 1335-1343.
- Foucher, S., and Lopez-Martinez, C. 2009, An Evaluation of PolSAR Speckle Filters. *IEEE International Geoscience and Remote Sensing Symposium, IGARSS 2009, July 12-17, 2009, University of Cape Town, Cape Town, South Africa, Proceedings*, pp. 845-848.
- Franceschetti, G., Iodice, A., and Riccio, D. 2002, A canonical problem in electromagnetic backscattering from buildings. *IEEE T. Geoscience and Remote Sensing*, 40(8), 1787-1801.

- Freeman, A., and Durden, S. 1998, A three-component scattering model for polarimetric SAR data. *Geoscience and Remote Sensing, IEEE Transactions on*, 36(3), 963-973.
- Frohlich, H., Chapelle, O., and Scholkopf, B. 2003, Feature selection for support vector machines by means of genetic algorithm. *Tools with Artificial Intelligence, 2003. Proceedings. 15th IEEE International Conference on*, pp. 142-148.
- Haddadi, A., Sahebi, M., and Mansourian, A. 2011, Polarimetric SAR feature selection using a genetic algorithm. *Canadian Journal of Remote Sensing*, 37(1), 27-36.
- Hajnsek, I., Pottier, E., and Cloude, S. 2003, Inversion of surface parameters from polarimetric SAR. *Geoscience and Remote Sensing, IEEE Transactions on*, 41(4), 727-744.
- Hara, Y., Atkins, R., Yueh, S., Shin, R., and Kong, J. 1994, Application of neural networks to radar image classification. *Geoscience and Remote Sensing, IEEE Transactions on*, 32(1), 100-109.
- Hellmann, M. 2001, *SAR polarimetry tutorial (beta version 0.1a)*.
- Holland, J. H. 1975, *Adaptation in Natural and Artificial Systems*. Ann Arbor, MI, USA: University of Michigan Press.
- Holm, W., and Barnes, R. 1988, On radar polarization mixed target state decomposition techniques. *Radar Conference, Proceedings of the 1988 IEEE National*, pp. 249-254.
- Hsu, C.-W., and Lin, C.-J. 2002, A comparison of methods for multi-class support vector machines. *A comparison of methods for multi-class support vector machines*, 13, 415-425.
- Hsu, C.-W., Chang, C.-C., and Lin, C.-J. 2003, *A Practical Guide to Support Vector Classification*. Tech. rep., Department of Computer Science, National Taiwan University.
- Huang, C., Townshend, J. R., and Davis, L. S. 2002, An assessment of support vector machines for land cover classification. *International Journal of Remote Sensing*, 23, 725-749.
- Huynen, J. 1970, *Phenomenological Theory of Radar Targets*. Ph.D. dissertation, University, Delft, The Netherlands.
- Igel, C. 2005, Multi-objective model selection for support vector machines. *Proceedings of the Third international conference on Evolutionary Multi-Criterion Optimization*, Berlin, Heidelberg: Springer-Verlag, pp. 534-546.
- Ince, T., Kiranyaz, S., and Gabbouj, M. 2012, Evolutionary RBF classifier for polarimetric SAR images. *Expert Syst. Appl.*, 39(5), 4710-4717.
- Ishibuchi, H., Nojima, Y., and Doi, T. 2006, Comparison between Single-Objective and Multi-Objective Genetic Algorithms: Performance Comparison and Performance Measures. *Evolutionary Computation, CEC 2006. IEEE Congress on*, pp. 1143-1150.
- Jain, A., and Zongker, D. 1997, Feature selection: Evaluation, application, and small sample performance, *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 19, no. 2, pp. 153-158.

- Jang, J. 1993, ANFIS: Adaptive-Network-Based Fuzzy Inference System. *IEEE Transactions on Systems, Man, and Cybernetics*, 23, 665-685.
- Kim, Y., and van Zyl, J. 2000, On the relationship between polarimetric parameters. *Geoscience and Remote Sensing Symposium, Proceedings. IGARSS 2000. IEEE International*, vol.3, pp. 1298 -1300.
- Kiranyaz, S., Ince, T., Uhlmann, S., Gabbouj, M. 2012, Collective Network of Binary Classifier Framework for Polarimetric SAR Image Classification: An Evolutionary Approach, *Systems, Man, and Cybernetics, Part B: Cybernetics*, IEEE Transactions on, vol.42, no.4, pp.1169-1186.
- Kohavi, R., and John, G. 1997, Wrappers for Feature Subset Selection. *Artificial Intelligence*, 97, 273-324.
- Kozlov, A., Ligthart, L., and Logvin, A. 2004, Mathematical and Physical Modeling of Microwave Scattering and Polarimetric Remote Sensing. *Kluwer Academic Publisher*, 1-106.
- Krogager, E. 1990, New decomposition of the radar target scattering matrix. *Electronics Letters*, 26, 1525-1527.
- Krogager, E., and Freeman, A. 1994, Three component break-downs of scattering matrices for radar target identification and classification. *PIERS*, Noordwijk, The Netherlands.
- Kudo, M., and Sklansky, J. 2000, Comparison of algorithms that select features for pattern classifiers, *Pattern Recogn.*, vol. 33, pp. 25-41.
- Lardeux, C., Frison, P., Tison, C., Souyris, J., Stoll, B., Fruneau, B. 2009, Support Vector Machine for Multifrequency SAR Polarimetric Data Classification. *Geoscience and Remote Sensing, IEEE Transactions on*, 47(12), 4143-4152.
- Lee, J., and Pottier, E. 2009, Polarimetric Radar Imaging from basic to application. *CRC press*.
- Lee, J., Grunes, M., and de Grandi, G. 1999, Polarimetric SAR speckle filtering and its implication for classification. *Geoscience and Remote Sensing, IEEE Transactions on*, 37(5), 2363-2373.
- Lee, J., Schuler, D., and Ainsworth, T. 2000, Polarimetric SAR data compensation for terrain azimuth slope variation. *Geoscience and Remote Sensing, IEEE Transactions on*, 38(5), 2153-2163.
- Lee, J.-S., Grunes, M. R., and Pottier, E. 2001, Quantitative comparison of classification capability: fully polarimetric versus dual and single-polarization SAR. *IEEE T. Geoscience and Remote Sensing*, 39(11), 2343-2351.
- Luneburg, E. 2001, Foundations of the mathematical theory of polarimetry. *Technical report, EML Consultants, Final Report Phase I*.
- Maghsoudi, Y. 2012, *Analysis of Radarsat-2 Full Polarimetric Data for Forest Mapping*. Ph.D. dissertation, Department of Geomatics Engineering, University of Calgary, Alberta, Canada.
- Maghsoudi, Y., Collins, M., and Leckie, D. 2012, Polarimetric classification of boreal forest using nonparametric feature selection and multiple classifiers.

- International Journal of Applied Earth Observation and Geoinformation*, 19, 139-150.
- Mansouri, B. S. 2010, Fully Polarimetric Sar Parameters And Correlation With Target-Sensor Orientation And Building Height. *8th International Workshop on Remote Sensing for Disaster Management September 30 to October 1, 2010, Tokyo, Japan*.
- Mattia, F., Le Toan, T., Souyris, J.-C., De Carolis, C., Floury, N., Posa, F. 1997, The effect of surface roughness on multifrequency polarimetric SAR data. *Geoscience and Remote Sensing, IEEE Transactions on*, 35(4), 954-966.
- Melgani, F., and Bruzzone, L. 2004, Classification of hyperspectral remote sensing images with support vector machines. *Geoscience and Remote Sensing, IEEE Transactions on*, 42(8), 1778-1790.
- Morio, J., Refregier, P., Goudail, F., Dubois-Fernandez, P., and Dupuis, X. 2007, Application of information theory measures to polarimetric and interferometric SAR images. *PSIP, 5th International Conference on Physics in Signal and Image Processing, Mulhouse, France*.
- Mountrakis, G., Im, J., and Ogole, C. 2011, Support vector machines in remote sensing: A review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 66, 247-259.
- Narzisi, G. 2007, An Experimental Multi-Objective Study of the SVM Model Selection problem. *Courant Institute of Mathematical Sciences*.
- Nghiem, S., Yueh, S., Kwok, R., and Li, F. 1992, Symmetry properties in polarimetric remote sensing. *Radio Science*, 27(5), 693-711.
- Pottier, E. 1993, Dr. J. R. Huynen's main contributions in the development of polarimetric radar techniques and how the 'Radar Targets Phenomenological Concept' becomes a theory. *SPIE*, 1748, 72-85.
- Pottier, E., and Ferro-Famil, L. 2005, Polarimetric Decompositions. PolSARPro v3.0-Radar Polarimetry.
- Pottier, E., and Lee, J. S. 1999, Application of the H/A/Alpha polarimetric decomposition theorem for unsupervised classification of fully polarimetric SAR data based on the Wishart distribution. *Proc. 3 rd EUSAR 2000 conference. Paris*.
- Pottier, E., and Saillard, J. 1991, On radar polarization target decomposition theorems with application to target classification by using neural network method. *Antennas and Propagation, 1991. ICAP 91., Seventh International Conference on (IEE)*, vol.1, pp. 265 -268.
- Pudil, P., Novovicova, J., and Kittler, J. 1994, Floating search methods for feature selection, *Pattern Recognit. Lett.*, vol. 15, no. 11, pp. 1119-1125.
- Qi, Z., Yeh, A., Li, X., and Lin, Z. 2012, A novel algorithm for land use and land cover classification using RADARSAT-2 polarimetric SAR data. *Remote Sensing of Environment*, 118, 21-39.
- Refregier, P., and Morio, J. 2006, Shannon entropy of partially polarized and partially coherent light with Gaussian fluctuations. *JOSAA*, 23(12), 3036-3044.

- Shimoni, M., Borghys, D., Heremans, R., Perneel, C., and Acheroy, M. 2009, Fusion of PolSAR and PolInSAR data for land cover classification. *International Journal of Applied Earth Observation and Geoinformation*, 11(3), 169-180.
- Small, D. 1991, *Information Content of Polarimetric Synthetic Aperture Radar Data*. Master's thesis, Univ. British Columbia, Canada.
- Suttorp, T., and Igel, C. 2006, Multi-objective Optimization of Support Vector Machines. In *Multi-objective Machine Learning*, Springer-Verlag, Vol. 16, pp. 199-220.
- Touzi, R. 2007, Target Scattering Decomposition in Terms of Roll-Invariant Target Parameters. *Geoscience and Remote Sensing, IEEE Transactions on*, 45(1), 73-84.
- Touzi, R., Deschamps, A., and Rother, G. 2009, Phase of Target Scattering for Wetland Characterization Using Polarimetric C-Band SAR. *Geoscience and Remote Sensing, IEEE Transactions on*, 47(9), 3241-3261.
- Touzi, R., Goze, S., Le Toan, T., Lopes, A., and Mougin, E. 1992, Polarimetric discriminators for SAR images. *Geoscience and Remote Sensing, IEEE Transactions on*, 30(5), 973-980.
- Van Zyl, J.J., Zebker, H.A., and Elachi, C. 1987, *Imaging radar polarization signatures*, *Radio Science*, vol. 22, pp. 529-543.
- Van Zyl, J. 1989, Unsupervised classification of scattering behavior using radar polarimetry data. *Geoscience and Remote Sensing, IEEE Transactions on*, 27(1), 36-45.
- Van Zyl, J. 1992, Application of Cloude's target decomposition theorem to polarimetric imaging radar data. in *Proceedings SPIE Conference on Radar Polarimetry, San Diego, CA, 1748*, 184-212.
- Vapnik, V. N. 1995, *The nature of statistical learning theory*. New York: Springer-Verlag.
- Yamaguchi, Y., Moriyama, T., Ishido, M., and Yamada, H. 2005, Four-component scattering model for polarimetric SAR image decomposition. *Geoscience and Remote Sensing, IEEE Transactions on*, 43(8), 1699-1706.
- Yang, W., Jiaguo, L., and Changyao, Z. 2007, Algorithm of target classification based on target decomposition and support vector machine. *Synthetic Aperture Radar, APSAR 2007. 1st Asian and Pacific Conference on*, pp. 770-774.
- Zadeh, L. A. 1965, Fuzzy Sets. *Information Control*, 8, 338-353.
- Zebker, H., and Van Zyl, J. 1991, Imaging radar polarimetry: a review. *Proceedings of the IEEE*, 79(11), 1583-1606.
- Zhang, Y. D., Wu, L., and Wei, G. 2009, A new classifier for polarimetric sar images, *Progress Electromagn. Res.*, vol. 94, pp. 83-104.
- Zhu, Z., Ong, Y.-S., and Dash, M. 2007, Wrapper-Filter Feature Selection Algorithm Using a Memetic Framework. 37(1), 70-76.

پیوست‌ها

پیوست (الف): پارامترهای SERD و DERD

دو پارامتر SERD و DERD از ماتریس همبستگی با فرض تقارن انعکاسی که با رابطه (ض-۱) بیان می‌شود، حاصل می‌شوند.

$$T_3 = \frac{1}{2} \begin{bmatrix} \langle |S_{hh} + S_{vv}|^2 \rangle & \langle (S_{hh} + S_{vv})(S_{hh} - S_{vv})^* \rangle & 0 \\ \langle (S_{hh} - S_{vv})(S_{hh} + S_{vv})^* \rangle & \langle |S_{hh} - S_{vv}|^2 \rangle & 0 \\ 0 & 0 & 4\langle |S_{hv}|^2 \rangle \end{bmatrix} \quad (\text{ض-۱})$$

در این حالت امکان استخراج مقادیر ویژه^۱ NOS از ماتریس T مطابق روابط (ض-۲)، (ض-۳) و (ض-۴) وجود دارد.

$$\lambda_{1NOS} = \frac{1}{2} \left\{ \langle |S_{hh}|^2 \rangle + \langle |S_{vv}|^2 \rangle + \sqrt{(\langle |S_{hh}|^2 \rangle - \langle |S_{vv}|^2 \rangle)^2 + 4\langle |S_{hh}S_{vv}^*|^2 \rangle} \right\} \quad (\text{ض-۲})$$

$$\lambda_{2NOS} = \frac{1}{2} \left\{ \langle |S_{hh}|^2 \rangle + \langle |S_{vv}|^2 \rangle - \sqrt{(\langle |S_{hh}|^2 \rangle - \langle |S_{vv}|^2 \rangle)^2 + 4\langle |S_{hh}S_{vv}^*|^2 \rangle} \right\} \quad (\text{ض-۳})$$

$$\lambda_{3NOS} = 2 \{ \langle |S_{hv}|^2 \rangle \} \quad (\text{ض-۴})$$

اولین و دومین مقدار ویژه به ضرایب پراکندگی co-pol و همبستگی بین کانال‌های افقی و قائم ρ_{hh-vv} وابسته هستند. در این حالت رابطه $\lambda_{1NOS} \geq \lambda_{2NOS}$ همواره برقرار است. سومین مقدار ویژه متناظر با کانال crosspol و مربوط به پراکندگی چندگانه از سطوح ناهموار می‌باشد. مطابق با تجزیه Cloude-Pottier از زاویه α_i برای مشخص کردن مکانیزم پراکندگی استفاده می‌شود:

$$\alpha_i = \arctan \left(\frac{|S_{hh} - S_{vv}|}{|S_{hh} + S_{vv}|} \right) \quad (\text{ض-۵})$$

در این صورت روابط زیر برقرار است:

$$\text{if } \frac{|S_{hh} - S_{vv}|}{|S_{hh} + S_{vv}|} < 1 \rightarrow \alpha_i < \frac{\pi}{4} \rightarrow \mathcal{R}(S_{hh}S_{vv}^*) > 0 \rightarrow \text{Single Reflection} \quad (\text{ض-۶})$$

$$\text{if } \frac{|S_{hh} - S_{vv}|}{|S_{hh} + S_{vv}|} > 1 \rightarrow \alpha_i > \frac{\pi}{4} \rightarrow \mathcal{R}(S_{hh}S_{vv}^*) < 0 \rightarrow \text{Double Reflection} \quad (\text{ض-۷})$$

با اعمال شرط تعامد بین بردارهای ویژه مختلف:

^۱ Non-Ordered in Size

$$(S_{hh1} + S_{vv1})(S_{hh2} + S_{vv2})^* + (S_{hh1} - S_{vv1})(S_{hh2} - S_{vv2})^* = 0 \quad (\text{ض-۸})$$

$$\alpha_1 + \alpha_2 = \frac{\pi}{2}$$

که λ_D و λ_S دو مقدار ویژه متناظر با مکانیزم پراکندگی تک انعکاسی و دو انعکاسی می باشند و به صورت زیر در نظر گرفته می شوند.

$$\alpha_1 \leq \frac{\pi}{4} \Rightarrow \alpha_2 \geq \frac{\pi}{4} : \begin{cases} \lambda_S = \lambda_{1NOS} \\ \lambda_D = \lambda_{2NOS} \end{cases} \quad (\text{ض-۹})$$

$$\alpha_1 \geq \frac{\pi}{4} \Rightarrow \alpha_2 \leq \frac{\pi}{4} : \begin{cases} \lambda_S = \lambda_{2NOS} \\ \lambda_D = \lambda_{1NOS} \end{cases} \quad (\text{ض-۱۰})$$

با استفاده از مقادیر ویژه NOS، دو پارامتر SERD و DERD به منظور مقایسه اهمیت نسبی مکانیزم های پراکندگی مختلف به صورت زیر تعریف می شود.

$$SERD = \frac{\lambda_S - \lambda_{3NOS}}{\lambda_S + \lambda_{3NOS}} \quad -1 < SERD < 1 \quad (\text{ض-۱۱})$$

$$DERD = \frac{\lambda_D - \lambda_{3NOS}}{\lambda_D + \lambda_{3NOS}} \quad -1 < DERD < 1 \quad (\text{ض-۱۲})$$

پیوست (ب): روش خوشه‌بندی Fuzzy C-Means (FCM)

در این پژوهش به منظور طراحی FIS پایه در مدل استنتاج فازی تاکاگی سوگنو از خوشه‌بندی فازی به روش C-Means استفاده شده است. خوشه‌بندی یکی از روش‌های طبقه‌بندی نظارت نشده و فرایندی خودکار است که در طی آن، مجموعه داده‌هایی معین، به مجموعه‌ای از کلاس‌ها یا خوشه‌ها تقسیم می‌شود. هدف از طبقه‌بندی داده‌ها به کمک چنین فرایندی جداسازی آن‌ها به قسمی است که دو داده در یک خوشه تا حد امکان به هم شبیه باشند و دو داده در دو خوشه متفاوت تا حد امکان متمایز از یکدیگر باشند.

مدل‌های خوشه‌بندی را می‌توان به دو دسته تقسیم کرد: خوشه‌بندی قطعی یا سخت که هر داده فقط به یک خوشه تعلق دارد، و خوشه‌بندی فازی یا نرم که در آن هر داده به یک خوشه معین با مقدار عضویت بین ۰ و ۱ تعلق دارد. وقتی که مرز بین خوشه‌ها واضح و مشخص نیست، و یک داده به بیش از یک خوشه تعلق دارد، خوشه‌بندی فازی مناسب‌تر به نظر می‌رسد. بیشتر مدل‌های خوشه‌بندی فازی بر مبنای تابع هدف هستند. این مدل‌ها با کمینه کردن یک تابع هدف در پی برآورد طبقه‌بندی بهینه‌اند. در خوشه‌بندی مبتنی بر تابع هدف، معمولاً هر خوشه به وسیله نمونه اولیه‌ای بیان می‌شود که اغلب فقط شامل مرکز خوشه است. به عبارت دیگر، نماینده هر خوشه میانگین داده‌های وابسته به آن خوشه خواهد بود.

یکی از موفق‌ترین مدل‌های خوشه‌بندی فازی FCM است که برای خوشه‌بندی داده‌های سنجش از دور نیز استفاده می‌شود. در واقع این مدل، نسخه بهبود یافته C-Means است. در مدل C-Means هر پیکسل می‌تواند فقط به یک خوشه تعلق داشته باشد، در حالی که در FCM هر پیکسل می‌تواند به چند خوشه با مقدار عضویت بین ۰ و ۱ تعلق داشته باشد. در این روش ماتریس عضویت U به صورت تصادفی تولید می‌شود به گونه‌ای که رابطه (ض-۱۳) برقرار باشد.

$$\sum_{i=1}^c u_{ij} = 1, \forall j = 1, \dots, n \quad (\text{ض-۱۳})$$

به عبارتی مجموع درجه عضویت هر داده به خوشه‌ها ۱ باشد. در مدل FCM باید تابع هدف رابطه (ض-۱۴) کمینه شود:

$$J(U, c_1, c_2, \dots, c_c) = \sum_{i=1}^c J_i = \sum_{i=1}^c \sum_{j=1}^n u_{ij}^m d_{ij}^2, \quad 1 \leq m \leq \infty \quad (\text{ض-۱۴})$$

که در آن c تعداد خوشه ها، n تعداد پیکسل ها، $u_{ij} \in [0, 1]$ عضویت پیکسل x_j به خوشه c_i مرکز i امین خوشه و d_{ij} فاصله بین پیکسل x_j و مرکز خوشه c_i است. پارامتر m به عنوان میزان فازی سازی شناخته شده که معمولاً برابر با ۲ در نظر گرفته می شود و داریم:

$$c_i = \frac{\sum_{j=1}^n u_{ij}^m x_j}{\sum_{j=1}^n u_{ij}^m}, \quad 1 \leq i \leq c \quad (\text{ض-۱۵})$$

$$u_{ij} = \frac{1}{\sum_{k=1}^c \left(\frac{d_{ij}}{d_{kj}} \right)^{2/(m-1)}} \quad (\text{ض-۱۶})$$

در FCM ابتدا ماتریس عضویت U به صورت تصادفی با شرط برقراری رابطه (ض-۱۳) مقداردهی می شود. سپس مراکز با استفاده از رابطه (ض-۱۵) و تابع هدف از رابطه (ض-۱۴) محاسبه می شود. درجه عضویت های جدید را با استفاده از رابطه (ض-۱۶) محاسبه کرده و ماتریس U جدید تشکیل می شود. براساس ماتریس U ، مراکز مجدداً محاسبه شده و مراحل قبل تا رسیدن به شرط توقف تکرار می شود.

Abstract

Land cover classification is one of the most important applications of polarimetric SAR images, especially in urban areas. There are numerous features that can be extracted from these images for the use of their high potential, hence feature selection plays an important role in PolSAR image classification. In this study, three main steps are used to improve the classification: 1) feature extraction in the form of three categories, namely original data features, target decomposition features, and SAR discriminators; 2) feature selection in the framework of the single and multi-objective optimization; and 3) classification using the best subset of features. In single objective methods, we employ genetic algorithms (GAs) and support vector machines (SVMs) or multi-layer perceptron (MLP) neural network in order to maximize classification accuracy. Then the new methods are proposed to perform an efficient land cover classification based on the multi-objective optimization approach. The objectives are to minimize the error of classification and the number of selected PolSAR parameters. In the proposed methods, NSGA-II optimization algorithm is employed as the search tool and Support Vector Machine (SVM) or Adaptive Neuro Fuzzy Inference System (ANFIS) is used in the evaluation step. The implementation results on the Radarsat-2 San Francisco Bay urban area image showed that the proposed methods outperform the other approaches tested against them.

Keywords: Polarimetry data, classification, multiobjective optimization, SVM, ANFIS